




معهد الحسن الثاني للزراعة والبيطرة
INSTITUT AGRONOMIQUE ET VÉTÉRINAIRE HASSAN II

Cartographie des zones propices à l'intégration de l'agriculture urbaine et périurbaine.



Réalisée par :

LAMRABET Oumayma (43)

Anass el hafidy (24)

Hafssa Boukaddour (13)

Youness El jilali (25)

SIFA Abdelghafour (55)

Encadrée par :

Pr. MOUSSAOUI Asmaa

Pr. SEBARI Imane

Année universitaire : 2024/2025

TABLE DES MATIÈRES

Liste des figures	2
Liste des tableaux	3
I. Introduction.....	4
II. Méthodologie.....	4
1. Zone d'étude: Ksar El-Kébir.....	4
a. Avantage naturelle :	4
b. Avantage démographique et économique :	5
2. Acquisition des images Sentinel-2 : RGB et multispectrale	5
3. Choix des classes	6
4. Création et export des zones d'entraînement pour la classification supervisée	6
a. Random Forest	8
b. SVM	9
5. Classification non supervisée par K-means	11
7. Validation de la classification de l'image	12
a. Validation quantitative.....	12
b. Validation qualitative.....	14
8. Indices	14
9. Indices utilisés :.....	16
a. SMI.....	16
b. SOC Index (Soil Organic Carbon) : Lié à la décomposition de la MO.....	17
c. Ferric Iron Index : Détection des oxydes de fer.	19
d. Fusion des indices via une analyse multicritère (MCDA)	20
10. Superposition des cartes de propension et d'occupation du sol pour l'identification des zones prioritaires à l'agriculture urbaine.....	22
III. Conclusion.....	24
Les annexes	25
Les références	51

Liste des figures

Figure 1:Image RGB	6
Figure 2: Image multispectral	6
Figure 3: Les zones d'entrainement.....	7
Figure 4: Résultat de classification	7
Figure 5: Les zones d'entrainement.....	8
Figure 6: Classification par Random Forest	9
Figure 7: Classification par SVM	11
Figure 8: Classification non supervisée par K-means	11
Figure 9: Les zones de validation	12
Figure 10: Résultat de calcul de SMI.....	17
Figure 11:Résultat de calcul de SOC	18
Figure 12: Signature spectral du sol, Végétation et eau	19
Figure 13: Résultat de calcul de Fe	20
Figure 14: Résultat de superposition.....	21
Figure 15: Ajout de NDVI	22
Figure 16: Résultat final (RF).....	23
Figure 17: Résultat final (SVM)	23

Liste des tableaux

Tableau 1: Type de cultures	5
Tableau 2: les indices d'humidité du sol	14
Tableau 3: les indices de Fertilité et Matière Organique (MO).....	15
Tableau 4: Les indices de Salinité du Sol.....	15
Tableau 5: Les indices de Texture du Sol (Argile, Sable, Limon)	15
Tableau 6: les indices de Minéraux du Sol.....	16
Tableau 7: Interprétation de SMI.....	17
Tableau 8: Interprétation SOC	18
Tableau 9: Interprétation de FE	19

I. Introduction

L'agriculture urbaine et périurbaine (AUP) s'impose aujourd'hui comme une solution stratégique face aux nombreux enjeux engendrés par l'urbanisation rapide, les menaces pesant sur la sécurité alimentaire, ainsi que les impacts croissants des changements climatiques. En rapprochant les lieux de production des zones de consommation, l'AUP contribue à réduire les coûts de transport, les émissions de gaz à effet de serre, et à favoriser une alimentation plus fraîche et accessible. Elle permet également une valorisation optimale des espaces urbains vacants, délaissés ou faiblement exploités, tout en créant des opportunités économiques, sociales et écologiques. Par ailleurs, l'agriculture en milieu urbain et périurbain renforce la résilience des villes en favorisant une meilleure autonomie alimentaire, en améliorant le cadre de vie, et en apportant des réponses innovantes aux défis environnementaux.

Toutefois, le succès de l'intégration de l'AUP repose sur une planification rigoureuse et adaptée, nécessitant l'identification précise des zones les plus favorables à son développement. Cette démarche implique la prise en compte d'un ensemble de critères variés, incluant des facteurs environnementaux (qualité du sol, disponibilité en eau, exposition), sociaux (accessibilité, acceptabilité sociale, besoins alimentaires) et spatiaux (occupation du sol, proximité des infrastructures, contraintes physiques). Dans cette optique, les technologies de télédétection et les systèmes d'information géographique (SIG) se révèlent être des outils essentiels. Ils permettent d'analyser de manière fine et exhaustive les dynamiques territoriales, de produire des cartographies à haute valeur ajoutée, et d'orienter les décideurs vers une gestion durable et efficace des ressources foncières en milieu urbain et périurbain.

En outre, l'AUP joue un rôle croissant dans les politiques publiques de transition écologique et de planification territoriale, en lien avec les objectifs de développement durable (ODD). Elle favorise également l'inclusion sociale en impliquant les communautés locales dans des projets participatifs, éducatifs et productifs. Grâce aux avancées technologiques et à la disponibilité croissante des données spatiales, il est désormais possible de modéliser les zones les plus aptes à accueillir ce type d'agriculture. Cela ouvre la voie à une meilleure intégration de l'AUP dans les stratégies urbaines, en tenant compte à la fois des contraintes territoriales et des opportunités à saisir.

II. Méthodologie

1. Zone d'étude: Ksar El-Kébir

La ville de Ksar El-Kébir, située dans le nord-ouest du Maroc à la région de Tanger-Tétouan-Al Hoceima, constitue un terrain d'étude pertinent pour l'intégration de l'agriculture urbaine et périurbaine

a. Avantage naturelle :

✓ Localisation :

Elle se trouve dans une plaine fertile, bénéficiant d'un climat favorable et de la proximité de l'oued Loukkos, ce qui lui confère un fort potentiel agricole.

✓ Ressources en Eau Abondantes :

Oued Loukkos : Un des fleuves les plus importants du nord du Maroc, permettant l'irrigation des terres agricoles.

Barrages et retenues d'eau : Le barrage d'Oued El Makhazine (en aval) contribue à la régulation des ressources hydriques.

Nappe phréatique : Des réserves souterraines exploitables pour l'agriculture.

✓ Sols Fertiles et Diversifiés :

Plaines alluviales : Riches en limons, favorables aux céréales (blé, maïs) et aux légumineuses.

Terrains périurbains : Possibilité de développer l'agriculture urbaine et périurbaine (serres, jardins communautaires).

✓ Climat Méditerranéen Favorable :

Précipitations modérées (600-800 mm/an), concentrées en hiver.

Hivers doux et étés chauds : Adapté aux cultures diversifiées (légumes d'hiver, fruits d'été).

✓ Cultures et Productions Agricoles Potentielles :

Tableau 1: Type de cultures

Type de culture	Exemples	Potentiel à Ksar El-Kébir
Céréales	Blé, orge, maïs	Fort (plaines fertiles)
Maraîchage	Tomates, pommes de terre, oignons	Très fort (irrigation disponible)
Arboriculture	Olives, agrumes, amandes	Zones collinaires adaptées

b. Avantage démographique et économique :

La croissance démographique et l'extension urbaine rapide exercent une pression sur les espaces agricoles en périphérie. Cependant, la ville dispose encore de nombreuses friches et terrains non bâtis pouvant être valorisés pour des projets agricoles durables ce qui provoque :

✓ Avantage socio-économique :

L'agriculture urbaine pourrait répondre à plusieurs enjeux locaux, notamment la lutte contre le chômage et l'insécurité alimentaire. Elle permettrait aussi de créer des emplois, d'améliorer le cadre de vie et de renforcer la cohésion sociale.

En plus les habitants de Ksar El-Kébir ont une forte culture agricole, profondément ancrée dans leur histoire et leur mode de vie.

✓ Proximité des Marchés Urbains :

Accès à Tanger, Larache et Tétouan : Débouchés commerciaux pour les produits frais.

Infrastructures routières (Autoroute A1, Route nationale N1) facilitant le transport agricole.

✓ Bon échantillon d'initiation :

Ville moyenne : Le choix de cette ville vise également à appuyer une planification territoriale plus durable et résiliente. Ksar El-Kébir, en tant que ville moyenne, représente un cas d'étude reproductible dans d'autres contextes similaires au Maroc. Ce projet contribuera à démontrer l'importance de la télédétection comme outil stratégique pour le développement urbain durable.

Disponibilité des données : La zone de Ksar El-Kébir bénéficie d'une documentation relativement riche mais inégalement répartie concernant son potentiel agricole. Les données disponibles proviennent principalement des rapports de la Direction Régionale de l'Agriculture, d'études universitaires (notamment de l'INRA de Tanger) et de projets de développement territorial. Les images satellites Sentinel-2 fournissent des informations actualisées sur l'occupation des sols, tandis que les archives historiques locales témoignent de la tradition rizicole de la plaine du Loukkos .

La première étape de ce travail a consisté à délimiter la zone d'étude, à savoir la ville de Ksar El-Kébir. La zone a été définie à l'aide de ses coordonnées géographiques

2. Acquisition des images Sentinel-2 : RGB et multispectrale

Nous avons choisi d'utiliser une image RGB (Rouge, Vert, Bleu) dans ce projet car elle offre une représentation en couleurs naturelles qui est immédiatement compréhensible et intuitive. Cette visualisation facilite la lecture et l'interprétation du paysage, notamment pour distinguer facilement les zones urbaines, périurbaines, agricoles ou naturelles dans leur contexte réel. Elle est particulièrement utile pour la localisation précise des zones d'étude et la présentation claire des résultats à un public qui peut ne pas être expert en télédétection.

Nous avons choisi Sentinel-2 car :

- ✓ Résolution spatiale élevée (10 m pour les bandes visibles et proches infrarouges) adaptée à la cartographie urbaine et périurbaine,
- ✓ Fréquence de revisite rapide (5 jours à l'équateur), permettant d'avoir des images récentes et de bonne qualité,
- ✓ Gratuité et accessibilité des données via Google Earth Engine,
- ✓ Disponibilité des bandes spectrales nécessaires pour calculer divers indices utiles à l'analyse de l'occupation du sol.



Figure 1:Image RGB



Figure 2: Image multispectral

3. Choix des classes

Nous avons choisi les classes Bâtiment, Route, Sol nu, Végétation et eau car elles représentent les éléments essentiels du paysage de Ksar El-Kébir. Elles permettent d'identifier les zones urbanisées, les terrains disponibles, la couverture végétale et les ressources en eau, ce qui est crucial pour localiser les espaces favorables à l'agriculture urbaine et périurbaine.

4. Création et export des zones d'entraînement pour la classification supervisée

Afin de préparer la classification supervisée, nous avons dessiné manuellement des zones d'entraînement sous forme de points pour chaque classe d'occupation du sol (agriculture, bâtiment, eau, route et sol nu) dans Google Earth Engine. Ces points ont ensuite été convertis en objets FeatureCollection étiquetés, puis

exportés vers l'espace **Assets** de la plateforme pour être utilisés comme données d'apprentissage dans les algorithmes de classification.




Figure 3: Les zones d'entraînement

Lorsque les zones d'entraînement sont constituées uniquement de points isolés, cela limite la capacité de l'algorithme à saisir pleinement la variabilité spatiale et spectrale des différentes classes. Cette approche restreinte peut ainsi provoquer une classification imprécise, conduisant à une image mal classée où certaines zones sont incorrectement identifiées, ce qui compromet la fiabilité globale des résultats cartographiques.




Figure 4: Résultat de classification

C'est pourquoi il est préférable de créer des polygones plutôt que de simples points, afin de mieux représenter la diversité spatiale des classes et d'améliorer la précision de la classification.



Figure 5: Les zones d'entraînement

Ensuite, ces polygones sont importés et sauvegardés dans les Assets de Google Earth Engine à l'aide d'un code Prétraitement et Classification supervisée par les méthodes Random Forest et Support Vector Machine

Pour cartographier l'occupation du sol et identifier les zones propices à l'intégration de l'agriculture urbaine et périurbaine, nous avons appliqué deux méthodes de classification supervisée : Random Forest (RF) et Support Vector Machine (SVM). Ces algorithmes sont largement utilisés en télédétection pour leur robustesse et leur capacité à gérer des données multispectrales complexes

a. Random Forest

La méthode Random Forest est un algorithme d'apprentissage automatique de type *ensemble*, fondé sur la génération d'un grand nombre d'arbres de décision construits de manière indépendante à partir de sous-échantillons aléatoires des données d'entraînement. Chaque arbre produit une prédiction individuelle, et la classification finale est déterminée par un vote majoritaire parmi l'ensemble des arbres. Cette technique, en combinant plusieurs modèles faibles pour en créer un modèle robuste, permet de réduire considérablement le risque de sur-apprentissage (*overfitting*), tout en conservant une grande précision sur des données complexes.

L'un des principaux avantages de Random Forest réside dans sa capacité à bien gérer les jeux de données contenant du bruit, des valeurs manquantes ou des variables redondantes. Il est aussi bien adapté aux cas où le nombre de variables explicatives est élevé, comme dans les analyses d'images satellitaires comportant plusieurs bandes spectrales ou indices dérivés. De plus, Random Forest offre des outils intégrés pour évaluer l'importance relative de chaque variable dans le processus de classification, ce qui constitue un atout précieux pour l'interprétation des résultats et l'optimisation des modèles. Grâce à sa robustesse, sa flexibilité et ses bonnes performances générales, il s'est imposé comme une méthode de référence dans les applications de classification supervisée, notamment dans le domaine de la télédétection et de l'analyse géospatiale.

Étapes du traitement :

✚ Chargement des données d'entraînement

Les polygones représentant les différentes classes d'occupation du sol (agriculture, bâtiment, eau, route, sol nu) sont importés depuis les **Assets**.

✚ Attribution des étiquettes de classe

Chaque FeatureCollection est associée à une valeur numérique représentant la classe (0 à 4), à l'aide de la propriété "class".

✚ Fusion des classes

Les différents ensembles de polygones sont fusionnés en une seule collection appelée `trainingZones` qui servira pour l'échantillonnage.

✚ Définition de la zone d'étude

La géométrie de la zone d'étude est définie à l'aide de coordonnées précises correspondant à la ville de **Ksar El-Kébir**, puis visualisée sur la carte.

✚ Prétraitement de l'image Sentinel-2 (niveau surface)

Une image Sentinel-2 entre juin et août 2024 est filtrée par date et couverture nuageuse, puis nettoyée des pixels perturbés à l'aide de la couche `SCL` (Scene Classification Layer).

✚ Réhaussement du contraste

Un réétalonnage linéaire (stretching) entre les percentiles 2 et 98 est appliqué pour améliorer la qualité visuelle et le contraste de l'image.

✚ Entraînement du classifieur Random Forest

L'algorithme Random Forest est entraîné sur l'ensemble d'apprentissage avec 100 arbres de décision, en utilisant les bandes spectrales comme variables d'entrée.

✚ Classification de l'image

L'image multispectrale prétraitée est classée à l'aide du modèle entraîné. Chaque pixel reçoit une étiquette correspondant à l'une des cinq classes..

✚ Exportation des résultats

L'image classée est exportée à la fois vers Google Drive et vers les Assets, tout comme les polygones d'entraînement utilisés.




Figure 6: Classification par Random Forest

b. SVM

La méthode Support Vector Machine (SVM) est un classifieur supervisé qui cherche à définir un hyperplan optimal séparant les classes avec une marge maximale. Elle est particulièrement adaptée aux

jeux de données à haute dimensionnalité et avec peu d'échantillons d'apprentissage. Grâce à l'utilisation de fonctions noyaux (*kernels*), SVM peut modéliser des frontières de décision complexes **et** non linéaires, ce qui en fait un outil performant pour les classifications difficiles. Bien qu'elle soit sensible aux paramètres et au bruit, SVM reste une méthode robuste pour la classification de données géospatiales. Dans le domaine de la télédétection, SVM a montré de très bonnes performances, notamment pour la classification d'images à haute résolution. Sa capacité à gérer des données multidimensionnelles le rend particulièrement utile pour l'analyse des bandes spectrales. De plus, il offre une bonne généralisation même avec un nombre restreint d'exemples d'apprentissage. SVM est ainsi largement utilisé dans les études comparatives de classificateurs pour évaluer la précision des résultats.

Étapes du traitement :

✚ **Chargement des polygones d'entraînement**

Les polygones correspondant aux cinq classes (agriculture, bâtiment, eau, route, sol nu) sont importés depuis les **Assets** de l'utilisateur. Ces polygones représentent les zones d'apprentissage pour l'algorithme.

✚ **Attribution des classes**

À chaque collection de polygones est associée une étiquette (*class*) allant de 0 à 4, correspondant aux catégories d'occupation du sol.

✚ **Fusion des classes**

L'ensemble des polygones étiquetés est fusionné en une seule collection appelée *trainingZones* qui sera utilisée pour l'échantillonnage de l'image.

✚ **Définition de la zone d'étude**

Une géométrie polygonale est définie pour délimiter la zone autour de **Ksar El-Kébir**, permettant de restreindre les traitements aux limites d'intérêt.

✚ **Prétraitement de l'image Sentinel-2**

Une image Sentinel-2 de niveau **Surface Reflectance** est sélectionnée entre juin et août 2024, avec moins de 10 % de couverture nuageuse. Les pixels perturbés (nuages, ombres, surfaces d'eau, etc.) sont masqués à l'aide de la bande SCL.

✚ **Réhaussement du contraste**

Un étirement linéaire entre les percentiles 2 et 98 améliore le contraste de l'image, facilitant la distinction des classes dans les bandes spectrales.

✚ **Entraînement du classifieur SVM**

Un classifieur **SVM avec noyau RBF** (Radial Basis Function) est entraîné sur l'ensemble d'apprentissage. Ce noyau permet de gérer des séparations non linéaires, ce qui le rend particulièrement adapté aux données multispectrales.

✚ **Application du modèle SVM**

L'image entière est classée en appliquant le modèle SVM entraîné. Chaque pixel reçoit une étiquette de classe selon sa signature spectrale.

✚ **Exportation vers Google Drive**

L'image classée est exportée vers Google Drive dans un dossier spécifié, afin de la récupérer localement.

✚ **Exportation vers les Assets**

Une copie de l'image classée est également sauvegardée dans les **Assets GEE**, utile pour une utilisation ultérieure dans d'autres scripts.

✚ **Sauvegarde des polygones d'entraînement**

Les polygones utilisés pour l'apprentissage sont exportés pour assurer la reproductibilité de l'étude.




Figure 7: Classification par SVM

5. Classification non supervisée par K-means

En complément des méthodes supervisées (Random Forest et SVM), une classification non supervisée a été effectuée à l'aide de l'algorithme K-means. Cette approche, ne nécessitant pas de données d'entraînement, regroupe les pixels de l'image satellitaire en classes spectrales similaires uniquement sur la base de leurs caractéristiques radiométriques. Elle permet d'explorer la structure naturelle des données et d'identifier des regroupements potentiels au sein du paysage de la zone d'étude, à savoir la région urbaine et périurbaine de Ksar El-Kébir.




Figure 8: Classification non supervisée par K-means

Néanmoins, cette méthode peut parfois produire des résultats de classification imprécis ou erronés, en particulier lorsqu'elle est utilisée sans données de référence fiables ou dans des environnements caractérisés par une forte complexité spatiale. C'est pourquoi les méthodes supervisées sont souvent privilégiées, car elles permettent d'entraîner les algorithmes à partir de données d'apprentissage soigneusement sélectionnées. En intégrant ces informations de terrain, ces méthodes offrent une meilleure précision et une plus grande cohérence dans les résultats obtenus. Elles s'avèrent donc plus adaptées pour les applications géospatiales nécessitant une interprétation fine et rigoureuse des classes.

7. Validation de la classification de l'image

a. Validation quantitative

Création des zones de validation

La création des zones de validation est une étape cruciale dans le processus d'évaluation de la classification d'images satellite. Ces zones, généralement constituées de polygones représentatifs des différentes classes d'occupation du sol, servent à vérifier la précision des résultats obtenus par les algorithmes de classification. Elles doivent être indépendantes des zones utilisées pour l'entraînement afin d'éviter tout biais dans l'évaluation. La délimitation des zones de validation peut s'appuyer sur des données de terrain, des images haute résolution ou des cartes existantes. Dans ce projet, les zones de validation ont été créées manuellement dans Google Earth Engine sous forme de collections de polygones pour chaque classe, puis étiquetées avec les codes correspondants avant d'être fusionnées en une seule collection pour faciliter l'évaluation.




Figure 9: Les zones de validation

Pour valider une classification, trois indicateurs clés sont utilisés :

- ✚ **Matrice de confusion** : C'est un tableau qui compare les classes réelles et les classes prédites. Il montre où les erreurs de classification ont lieu, en indiquant combien d'échantillons ont été correctement ou incorrectement classés.
- ✚ **Précision globale** : Elle mesure le pourcentage total d'échantillons bien classés, donnant une idée générale de la qualité de la classification.
- ✚ **Coefficient Kappa** : Cette mesure corrige la précision globale en prenant en compte les résultats dus au hasard. Elle varie entre -1 et 1, où 1 indique une classification parfaite.

Le résultat pour la classification par `random_forest` :

```
✓ Matrice de confusion :  
▼ List (5 elements)  
  ▶ 0: [670,0,0,8,22]  
  ▶ 1: [0,70,0,2,5]  
  ▶ 2: [0,0,7,0,0]  
  ▶ 3: [0,10,0,12,0]  
  ▶ 4: [0,0,0,14,165]
```

🎯 Précision globale :
0.9380710659898477

📊 Kappa :
0.8693395323753522

La matrice de confusion montre la répartition des classes réelles (lignes) versus les classes prédites (colonnes). Par exemple, la première ligne indique que sur 700 échantillons d'agriculture, 670 ont été correctement classés, tandis que 8 ont été confondus avec la classe route, et 22 avec la classe sol nu

- ✓ AGRICULTURE est très bien reconnue (670 corrects sur 700).
- ✓ BATIMENT montre quelques confusions avec SOLNU et ROUTE.
- ✓ EAU est parfaitement détectée.
- ✓ ROUTE présente des confusions avec BATIMENT.
- ✓ SOLNU est bien classée mais 14 pixels sont confondus avec ROUTE..

La précision globale est élevée, à environ 93,8 %, ce qui signifie que près de 94 % des pixels ont été correctement classés, reflétant une bonne performance du modèle.

Le coefficient Kappa est de 0,87, ce qui indique un accord substantiel entre la classification et les données de référence, en tenant compte des classifications aléatoires. Une valeur proche de 1 montre une classification très fiable.

En résumé, ces résultats montrent que la classification est globalement précise avec une faible confusion entre les classes, validant ainsi la robustesse du modèle utilisé.

Le résultat pour la classification par SVM :

```
✓ Matrice de confusion SVM :  
▼ List (5 elements)  
  ▶ 0: [671,0,0,0,29]  
  ▶ 1: [0,72,0,1,4]  
  ▶ 2: [0,0,7,0,0]  
  ▶ 3: [0,9,0,13,0]  
  ▶ 4: [1,0,0,1,177]
```

🎯 Précision globale SVM :
0.9543147208121827

📊 Kappa SVM :
0.9027147682603227

La matrice de confusion présente la répartition des classes réelles (lignes) par rapport aux classes prédites (colonnes). Par exemple, la première ligne montre que sur 700 échantillons d'agriculture, 671 ont été correctement classés, tandis que 29 ont été confondus avec la classe sol nu.

- ✓ AGRICULTURE est très bien classée, malgré 29 pixels confondus avec SOLNU.

- ✓ BATIMENT est presque parfaitement identifié, avec très peu de confusions.
- ✓ EAU est parfaitement reconnue.
- ✓ ROUTE présente quelques confusions avec BATIMENT.
- ✓ SOLNU est très bien détectée avec seulement quelques erreurs mineures.

La précision globale est élevée, à environ 95,4 %, ce qui signifie que plus de 95 % des pixels ont été correctement classés, témoignant d'une excellente performance du modèle.

Le coefficient Kappa est de 0,90, indiquant un très bon accord entre la classification et les données de terrain, en tenant compte des chances de classification aléatoire. Une valeur proche de 1 traduit une classification fiable et robuste.

En résumé, ces résultats confirment que la classification par SVM est précise et efficace, avec peu de confusions entre les classes, validant la pertinence et la robustesse du modèle employé.

b. Validation qualitative

Après la validation quantitative basée sur la matrice de confusion, il est important de procéder à une validation qualitative afin d'affiner l'analyse et de mieux comprendre les erreurs éventuelles de classification. Cette étape consiste à comparer visuellement la carte classifiée avec des images satellites ou des connaissances terrain, ce qui permet de détecter des zones mal classées et d'identifier les causes possibles.

Par exemple, lors de l'observation de la carte classifiée, on peut constater que certains pixels correspondant à des bâtiments ont été incorrectement classés dans la classe eau. Cette confusion peut être due à des ombres portées, des surfaces réfléchissantes ou une résolution spatiale limitée, qui brouillent la distinction entre les classes. De telles erreurs qualitatives sont fréquentes et montrent la nécessité d'un ajustement éventuel des paramètres du modèle ou d'une meilleure qualité des données d'entrée.

Après avoir entraîné les deux modèles sur les mêmes données d'apprentissage, les résultats ont été comparés à l'aide d'indicateurs de performance tels que l'exactitude globale (Overall Accuracy) et le coefficient de Kappa. Les résultats ont montré que la méthode SVM a fourni une classification plus précise que Random Forest, avec une meilleure capacité de discrimination entre les différentes classes. Cette performance supérieure peut s'expliquer par la capacité de SVM à modéliser efficacement les frontières complexes entre les classes, même avec un nombre limité d'échantillons d'entraînement. Ainsi, la méthode SVM a été retenue pour la suite de l'étude.

8. Indices

La classification d'images satellitaires nécessite souvent le calcul d'indices spectraux, qui améliorent grandement la précision et l'efficacité du processus. Ces indices, dérivés de combinaisons mathématiques des valeurs des différents canaux spectraux (rouge, vert, bleu, infrarouge proche, etc.), permettent de mettre en évidence des informations spécifiques difficilement perceptibles sur les images brutes. Ils transforment des données multispectrales complexes en indicateurs plus simples et plus interprétables, facilitant ainsi la discrimination entre différentes classes d'objets.

L'utilisation d'indices calculés dans la classification d'images satellitaires offre de nombreux avantages, notamment une meilleure précision, une simplification du traitement des données et une interprétation facilitée des résultats.

Les indices sont :

- ✓ **Humidité du Sol**

Tableau 2: les indices d'humidité du sol

Indice	Formule	Capteurs/Satellites	Utilité
NDWI	$(B3 - B8)/(B3 + B8)$	Sentinel-2 (B3=Vert, B8=NIR)	Eau dans le sol/végétation.
MSI (Moisture	B11/B8	Sentinel-2 (B11=SWIR, B8=NIR)	Stress hydrique (sol/végétation).

Stress Index)			
SMI (Soil Moisture Index)	$(B8A - B11)/(B8A + B11)$	Sentinel-2 (B8A=Narrow NIR)	Humidité des sols nus.
SWI (Soil Water Index)	Basé sur les données radar (Sentinel-1)	Sentinel-1 (SAR)	Humidité superficielle (pénétration micro-ondes).

✓ Fertilité et Matière Organique (MO)

Tableau 3: les indices de Fertilité et Matière Organique (MO)

Indice	Formule	Capteurs	Utilité
NDVI	$(B8 - B4)/(B8 + B4)$	Sentinel-2 (B4=Rouge, B8=NIR)	Santé végétale (indirect pour la fertilité).
OSAVI (Optimized SAVI)	$(1.16 \times (B8 - B4))/(B8 + B4 + 0.16)$	Sentinel-2	Amélioration du NDVI pour les sols nus.
SOC Index (Soil Organic Carbon)	Basé sur les bandes SWIR (B11, B12)	Sentinel-2, Landsat 8	Estimation du carbone organique.
CRI (Carotenoid Reflectance Index)	$(1/B2) - (1/B3)$	Hyperspectral	Lié à la décomposition de la MO.

✓ Salinité du Sol

Tableau 4: Les indices de Salinité du Sol

Indice	Formule	Capteurs	Utilité
SI (Salinity Index)	$\sqrt{(B4 \times B8)}$	Sentinel-2 (B4=Rouge, B8=NIR)	Détection des sols salins.
NDSI (Normalized Difference Salinity Index)	$(B4 - B11)/(B4 + B11)$	Sentinel-2 (B11=SWIR)	Cartographie de la salinité.
SVI (Salinity Vegetation Index)	$B8/B4$	Sentinel-2	Interaction végétation/salinité.

✓ Texture du Sol (Argile, Sable, Limon)

Tableau 5: Les indices de Texture du Sol (Argile, Sable, Limon)

Indice	Formule	Capteurs	Utilité
Clay Index	$B11/B12$	Sentinel-2 (B11, B12=SWIR)	Teneur en argile (réflectance SWIR).
Sand Index	$(B4 - B12)/(B4 + B12)$	Sentinel-2	Proportion de sable.
Silt Index	Combinaison de bandes VIS-SWIR	Hyperspectral	Estimation du limon.

✓ Minéraux du Sol

Tableau 6: les indices de Minéraux du Sol

Indice	Formule	Capteurs	Utilité
Ferric Iron Index	B6/B5	Landsat 8 (B6=SWIR2, B5=SWIR1)	Détection des oxydes de fer.
Carbonate Index	(B6 + B7)/B5	Landsat 8	Présence de carbonates (calcaire).
AlOH Group Index	(B11/B12) × 100	Sentinel-2	Minéraux argileux (kaolinite).

9. Indices utilisés :

Le choix de l'indice dépendra de l'objectif de la classification et des caractéristiques spécifiques des données satellitaires utilisées. Dans notre étude nous s'intéressant à trois principaux indices qui sont : SMI (Soil Moisture Index) , SOC Index (Soil Organic Carbon) et Ferric Iron Index .

C'est trois indices sont choisis car un sol propice à l'agriculture en général est évalué par la teneur en eau , matière organique et minéraux en suspension .

a. SMI

Le Soil Moisture Index (SMI) est un indice spectral calculé à partir des bandes Sentinel-2 , c'est un indice utilisé pour estimer l'humidité du sol à partir des données satellitaires. Il repose sur la réflectance des surfaces dans différentes bandes spectrales, notamment dans le **proche infrarouge (NIR)** et l'**infrarouge à onde courte (SWIR)** en se basant sur la formule suivante :

$$SMI = \frac{B8A - B11}{B8A + B11}$$

- B8A correspond à la bande proche-infrarouge (NIR, 865 nm),
- B11 correspond à la bande infrarouge à ondes courtes (SWIR, 1610 nm).
- Cet indice exploite la différence normalisée entre la réflectance NIR et SWIR pour estimer la teneur en eau du sol.

Interprétation des valeurs /

- ✓ Des valeurs élevées de SMI indiquent un sol humide (plus de réflectance en NIR que SWIR),
- ✓ Des valeurs faibles ou négatives indiquent un sol sec (plus d'absorption en SWIR liée à la faible humidité).
- ✓ Le SMI est utile pour cartographier l'humidité relative des sols, notamment en agriculture ou en gestion des ressources en eau.

Seuils typiques :

Pour faciliter son interprétation, les valeurs continues de SMI sont classées en quatre catégories qualitatives :

- ✓ Très humide : $SMI > 0.4$
- ✓ Modéré : $0.2 < SMI \leq 0.4$
- ✓ Sec : $0.0 < SMI \leq 0.2$
- ✓ Très sec : $SMI \leq 0.0$

Chaque pixel est ainsi associé à une classe codée de 1 à 4, ce qui permet une cartographie claire de la variation spatiale de l'humidité du sol.

Tableau 7: Interprétation de SMI

SMI	Interprétation
0.4 à 1.0	Sol très humide (zones saturées en eau).
0.2 à 0.4	Humidité modérée (sol bien drainé).
0.0 à 0.2	Sol sec (manque d'eau).
< 0.0	Sol très sec ou rocheux.

Résultats :




Figure 10: Résultat de calcul de SMI

Interprétation :

Les zones bâties sont plus réfléchissantes dans le SWIR et moins réfléchissantes dans le NIR, ce qui donne un SMI très faible à négatif, ce qui explique la couleur mauve dans cette zone.

Les zones humides (très humide ou modéré) s'intersectent avec les zones agricoles et celle du sol nu.

b. SOC Index (Soil Organic Carbon) : Lié à la décomposition de la MO.

Le **Soil Organic Carbon (SOC)** : représente la quantité de carbone présente dans le sol sous forme de matière organique.

La formule mathématique est :

$$Soc = \frac{B11 - B8A}{B11 + B8A}$$

Cette formule calcule essentiellement un indice de différence normalisée (NDI) entre :

- B11 (bande SWIR - 1610 nm)
- B8A (bande proche infrarouge étroite - 865 nm)

Des valeurs élevées de SOC indiquent un sol plus riche en matière organique (plus de réflectance en SWIR que NIR),

Des valeurs faibles ou négatives indiquent un sol pauvre en MO
Le SOC est utile pour cartographier la teneur en matière organique des sols, notamment en agriculture

Seuils typiques :

Chaque pixel est ainsi associé à une classe codée de 1 à 4, ce qui permet une cartographie claire de la variation spatiale e la teneur en matière organique .

Tableau 8: Interprétation SOC

Classe SOC	Plage de valeurs	Interprétation
Très faible	≤ 0.0	Teneur en carbone très basse
Faible	$0.0 < SOC \leq 0.1$	Teneur en carbone faible
Élevé	$0.1 < SOC \leq 0.3$	Teneur en carbone modérée à élevée
Très élevé	> 0.3	Teneur en carbone très élevée

Résultats :




Figure 11:Résultat de calcul de SOC

Interprétation :

- ✓ Les valeurs très faibles du SOC sont superposées avec les zones cultivées car la réflectance de végétation dans le SWIR est faible par rapport au NIR .
- ✓ Les valeurs faibles de couleur jaunes sont liées aux bâtiments principalement , car Les zone bâtis sont plus réfléchissante dans le SWIR que dans le NIR .
- ✓ Les zones sol nue ont un SOC élevé car la réflectance dans le SWIR est plus grande que celle dans le NIR




Figure 12: Signature spectrale du sol, Végétation et eau

Utilisation des bandes SWIR et NIR pour le SOC

Castaldi et al. (2019) ont montré que les bandes SWIR (B11, B12) de Sentinel-2 sont sensibles au carbone organique du sol

c. Ferric Iron Index : Détection des oxydes de fer.

Le Ferric Iron Index est un indice spectral utilisé en télédétection pour estimer la concentration en oxydes de fer (Fe_2O_3) dans les sols et les roches. Il permet de détecter les minéraux riches en fer (hématite, goéthite). Le FII est calculé en utilisant la formule suivante :

$$SMI = \frac{B4 - B3}{B4 + B3}$$

Les bandes utilisées et interprétation :

- **B4 (Rouge, 665 nm)** : Sensible à l'absorption par les oxydes de fer.
- **B3 (Vert, 560 nm)** : Réfléchit davantage en présence de fer.

Applications : Cartographie géologique, études pédologiques, exploration minière.

Seuils typiques :

Tableau 9: Interprétation de FE

Classe	Plage de valeurs	Interprétation
Très faible	≤ 0.0	Teneur négligeable en oxydes de fer
Faible	$0.0 < \text{Fe} \leq 0.2$	Teneur faible en fer
Élevé	$0.2 < \text{Fe} \leq 0.4$	Teneur modérée à élevée
Très élevé	> 0.4	Teneur très élevée en fer

Résultats :





Figure 13: Résultat de calcul de Fe

Interprétation :

- ✓ Les valeurs très faible (négative) du FII sont situés dans les terrains agricoles car la réflectance de la végétation pour la bande rouge est faible par rapport à celle pour la bande vert .
- ✓ De même pour l'eau voir le graphe ci-dessous .
- ✓ L'indice FII est élevé dans les zones bâtis , route et sol nue .



d. Fusion des indices via une analyse multicritère (MCDA)

L'analyse multicritère (MCDA) constitue une approche robuste pour intégrer plusieurs variables environnementales en vue d'identifier les zones les plus propices à l'agriculture urbaine et périurbaine. Dans ce contexte, les trois indices clés — le SOC (indice de contenu organique du sol), le SMI (indice d'humidité du sol) et le FI (indice de fertilité) — sont d'abord **normalisés** pour les ramener à une échelle commune (par exemple de 0 à 1), garantissant leur comparabilité. Ensuite, des **poids** sont attribués à chaque indice selon leur influence relative sur la pratique agricole, par exemple : 40 % pour le SOC, 35 %

pour le SMI, et 25 % pour le FI, en s'appuyant sur des jugements d'experts ou des méthodes comme l'analyse hiérarchique des processus (AHP).

L'étape suivante consiste à **agréger les indices normalisés** à l'aide d'une formule de **somme pondérée** :

$$\text{Score} = \text{SOC_norm} \times 0.4 + \text{SMI_norm} \times 0.35 + \text{FI_norm} \times 0.25.$$

Enfin, la carte résultante est **classifiée en niveaux de propension** (par exemple : «Très propice», «Propice», «Modéré», «Peu propice»), offrant ainsi une cartographie synthétique et décisionnelle des zones à fort potentiel pour l'agriculture urbaine. Cette méthode permet une prise de décision éclairée basée sur une approche objective et spatialement explicite.

Le résultat :



Figure 14: Résultat de superposition

- ✓ Les zones très propices et propices coïncident principalement avec des zones de sol nu et certaines **zones** agricoles, ce qui valide la cohérence entre la classification multicritère et le potentiel d'intégration de l'agriculture urbaine et périurbaine.
- ✓ Les zones urbaines (bâtiments et routes) sont majoritairement classées comme peu propices, ce qui est attendu en raison de leur fort taux d'imperméabilisation et de la faible disponibilité foncière pour des usages agricoles.
- ✓ Les zones moyennement propices apparaissent fréquemment en périphérie urbaine ou dans des zones de transition entre espaces agricoles et bâtis. Elles représentent des secteurs stratégiques pour des projets pilotes, des jardins communautaires ou des actions de reconversion

L'analyse repose uniquement sur trois indices biophysiques (SOC, SMI, Fe), qui, bien qu'importants, ne suffisent pas à capturer toute la complexité du tissu urbain. Pour réduire les erreurs de classification et mieux distinguer les zones bâties, végétalisées ou en friche, il serait pertinent de compléter ces critères avec des indicateurs plus adaptés au contexte urbain, tels que :

- **NDVI** (Normalized Difference Vegetation Index), pour détecter la végétation active ;
- **NDBI** (Normalized Difference Built-up Index), pour repérer les zones imperméabilisées ;
- **LST** (Land Surface Temperature), qui peut indiquer les îlots de chaleur urbains ou la présence de végétation dense.

Losque on ajout NDVI le résultat sera



Figure 15: Ajout de NDVI

- ✓ Les zones très propices et propices coïncident principalement avec des zones de sol nu et certaines zones agricoles, ce qui valide la cohérence entre la classification et le potentiel d'intégration de l'agriculture.
- ✓ Les zones urbaines (bâtiment et routes) sont majoritairement classées comme peu propices, ce qui est attendu vu l'imperméabilisation du sol et la faible disponibilité foncière.
- ✓ Les zones moyennement propices se trouvent souvent en périphérie urbaine ou dans des zones de transition entre agriculture et bâti. Elles peuvent être considérées comme des zones à fort potentiel pour des projets pilotes ou de reconversion.

10. Superposition des cartes de propension et d'occupation du sol pour l'identification des zones prioritaires à l'agriculture urbaine

La superposition spatiale de la carte de propension à l'agriculture urbaine (issue de l'analyse multicritère MCDA) avec la carte d'occupation du sol permet de valider la cohérence des résultats obtenus et d'identifier les zones réellement exploitables. Cette analyse croisée met en évidence que les zones classées comme « très propices » et « propices » correspondent majoritairement à des espaces de sol nu ou agricoles, confirmant leur potentiel pour des projets d'agriculture urbaine. À l'inverse, les zones bâties et les infrastructures routières sont en grande majorité classées comme « peu propices », en raison de l'imperméabilisation du sol et de la faible disponibilité foncière. Les zones « moyennement propices » localisées en périphérie urbaine ou en frange des zones agricoles constituent des espaces stratégiques pour initier des projets pilotes ou des démarches de reconversion progressive. Cette superposition constitue ainsi une étape clé pour orienter les décisions d'aménagement et prioriser les interventions en faveur de l'agriculture urbaine et périurbaine.

Le Résultat :




Figure 16: Résultat final (RF)




Figure 17: Résultat final (SVM)

À la lumière des résultats obtenus — une prédominance de zones peu propices (souvent urbanisées) et modérément propices (avec incertitude sur leur potentiel réel) — il est recommandé de :

- ✓ Compléter les indices utilisés (SOC, SMI, Fe) par d'autres indicateurs plus spécifiques au contexte urbain, tels que le NDVI (végétation), le NDBI (taux d'imperméabilisation), ou la température de surface (LST), pour mieux distinguer les zones bâties, végétalisées ou en friche.

- ✓ Intégrer des données sur l'usage du sol, issues d'images satellites ou de données cadastrales, pour mieux identifier les espaces réellement exploitables (terrains vagues, toits plats, espaces non bâtis).
- ✓ Pondérer les critères selon leur importance pour l'agriculture urbaine à travers une méthode comme l'AHP ou en concertation avec des acteurs locaux, afin de mieux refléter les priorités (accessibilité, disponibilité foncière, proximité des consommateurs).
- ✓ Prendre en compte la dynamique urbaine, via des séries temporelles, pour anticiper l'évolution des zones à fort potentiel.
- ✓ Distinguer plusieurs formes d'agriculture urbaine (friches, jardins partagés, toitures), en produisant une typologie des opportunités selon les caractéristiques spatiales identifiées.

III. Conclusion

Ce travail a permis de mettre en œuvre une méthode de classification supervisée des occupations du sol à partir d'images Sentinel-2, en utilisant un classifieur SVM performant. Grâce à des données d'entraînement bien définies, couvrant différentes classes telles que l'agriculture, les bâtiments, les plans d'eau, les routes et les sols nus, nous avons pu obtenir une classification précise de la zone d'étude à Ksar El-Kébir.

L'intégration des indices environnementaux clés (NDVI, SMI, SOC, FI) a ensuite permis d'identifier avec précision les zones propices à l'agriculture urbaine et périurbaine, en se basant sur la présence de sols nus favorables et des conditions de végétation et humidité adéquates.

Cette approche combinant traitement d'images satellite, apprentissage automatique et analyse multi-critères fournit un outil efficace pour guider les politiques d'aménagement urbain durable et le développement de l'agriculture urbaine. Elle ouvre également la voie à un suivi régulier et à une gestion optimisée des espaces agricoles périurbains dans des régions semi-arides comme Ksar El-Kébir.

Les annexes

Délimitation de la zone :

Le code suivant permet de délimiter la zone d'étude autour de la ville de Ksar El-Kébir en définissant un polygone géographique dans Google Earth Engine :

```
var zone = ee.Geometry.Polygon([
  [[-5.93139, 35.00583],
    [-5.90056, 35.00556],
    [-5.89944, 34.98111],
    [-5.92972, 34.98167]]
]);
Map.centerObject(zone, 13);
Map.addLayer(zone, {color: 'red'}, 'Zone étude');
```

Création et export des zones d'entraînement pour la classification supervisée

les polygones sont importés et sauvegardés dans les Assets de Google Earth Engine à l'aide du code suivant :

```
// === 1. Ajouter une propriété 'landcover' à chaque polygone ===
var fc_BATIMENT = ee.FeatureCollection(BATIMENT).map(function(feature) {
  return feature.set('landcover', 1);
});
var fc_EAU = ee.FeatureCollection(EAU).map(function(feature) {
  return feature.set('landcover', 2);
});
var fc_AGRICULTURE = ee.FeatureCollection(AGRICULTURE).map(function(feature) {
  return feature.set('landcover', 0);
});
var fc_ROUTE = ee.FeatureCollection(ROUTE).map(function(feature) {
  return feature.set('landcover', 3);
});
var fc_SOLNU = ee.FeatureCollection(SOLNU).map(function(feature) {
  return feature.set('landcover', 4);
});
// === 2. Fusionner toutes les classes dans une seule FeatureCollection ===
var trainingPolygons = fc_AGRICULTURE
  .merge(fc_BATIMENT)
  .merge(fc_EAU)
  .merge(fc_ROUTE)
  .merge(fc_SOLNU);
// === 3. Exporter vers les Assets ===
// Remplace 'ton_nom_utilisateur' par ton ID Earth Engine
Export.table.toAsset({
  collection: fc_AGRICULTURE,
  description: 'Export_AGRICULTURE',
  assetId: 'users/ton_nom_utilisateur/AGRICULTURE'
});
Export.table.toAsset({
  collection: fc_BATIMENT,
  description: 'Export_BATIMENT',
  assetId: 'users/ton_nom_utilisateur/BATIMENT'
});
Export.table.toAsset({
  collection: fc_EAU,
```

```

description: 'Export_EAU',
assetId: 'users/ton_nom_utilisateur/EAU'
});
Export.table.toAsset({
collection: fc_ROUTE,
description: 'Export_ROUTE',
assetId: 'users/ton_nom_utilisateur/ROUTE'
});
Export.table.toAsset({
collection: fc_SOLNU,
description: 'Export_SOLNU',
assetId: 'users/ton_nom_utilisateur/SOLNU'
});

```

Random Forest :

Le code ci-dessous met en œuvre un processus complet de classification supervisée d'une image Sentinel-2, en s'appuyant sur l'algorithme Random Forest :

```

// === 1. Charger les polygones d'entraînement depuis les Assets ===
var agriculture = ee.FeatureCollection('users/lamrabetoumayma10/AGRICULTURE');
var batiment    = ee.FeatureCollection('users/lamrabetoumayma10/BATIMENT');
var eau         = ee.FeatureCollection('users/lamrabetoumayma10/EAU');
var route       = ee.FeatureCollection('users/lamrabetoumayma10/ROUTE');
var solnu       = ee.FeatureCollection('users/lamrabetoumayma10/SOLNU');

// === 2. Ajouter la classe à chaque FeatureCollection ===
var fc_agriculture = agriculture.map(function(f) { return f.set('class', 0); });
var fc_batiment    = batiment.map(function(f) { return f.set('class', 1); });
var fc_eau         = eau.map(function(f) { return f.set('class', 2); });
var fc_route       = route.map(function(f) { return f.set('class', 3); });
var fc_solnu       = solnu.map(function(f) { return f.set('class', 4); });

// === 3. Fusionner toutes les classes dans un seul FeatureCollection ===
var trainingZones = fc_agriculture
  .merge(fc_batiment)
  .merge(fc_eau)
  .merge(fc_route)
  .merge(fc_solnu);

// === 4. Définir la zone d'étude ===
var zone = ee.Geometry.Polygon([
  [
    [-5.93139, 35.00583],
    [-5.90056, 35.00556],
    [-5.89944, 34.98111],
    [-5.92972, 34.98167]
  ]
]);
Map.centerObject(zone, 13);
Map.addLayer(zone, {color: 'red'}, 'Zone d'étude');

// === 5. Prétraitement Sentinel-2 SR ===
function maskS2(image) {
  var scl = image.select('SCL');

```



```

    var mask = scl.neq(3).and(scl.neq(8)).and(scl.neq(9)).and(scl.neq(10)).and(scl.neq(1));
    return image.updateMask(mask).copyProperties(image, ['system:time_start']);
}

var image = ee.ImageCollection('COPERNICUS/S2_SR')
    .filterBounds(zone)
    .filterDate('2024-06-01', '2024-08-01')
    .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 10))
    .map(maskS2)
    .select(['B2', 'B3', 'B4', 'B8', 'B11']) // Bleu, Vert, Rouge, NIR, SWIR
    .median()
    .clip(zone);

// === 6. Réhaussement de contraste corrigé ===
function linearStretch(image, pmin, pmax) {
    var percentiles = image.reduceRegion({
        reducer: ee.Reducer.percentile([pmin, pmax]),
        geometry: zone,
        scale: 10,
        maxPixels: 1e9
    });
    var bands = image.bandNames();

    var stretchedBands = bands.map(function(bandName) {
        bandName = ee.String(bandName);
        var band = image.select(bandName);
        var min = ee.Number(percentiles.get(bandName.cat('_p').cat(pmin.toString())));
        var max = ee.Number(percentiles.get(bandName.cat('_p').cat(pmax.toString())));
        min = ee.Algorithms.If(min, min, 0);
        max = ee.Algorithms.If(max, max, 1);
        return band.clamp(min, max).unitScale(min, max).rename(bandName);
    });

    var stretched = ee.ImageCollection(stretchedBands).toBands().rename(bands);
    return stretched;
}

var enhanced = linearStretch(image, 2, 98);
Map.addLayer(enhanced, {bands: ['B4', 'B3', 'B2'], min: 0, max: 1}, 'RGB réhaussé');

// === 7. Échantillonnage et préparation du classifieur ===
var training = enhanced.sampleRegions({
    collection: trainingZones,
    properties: ['class'],
    scale: 10
});

var withRandom = training.randomColumn('random');
var trainingSet = withRandom.filter(ee.Filter.lt('random', 0.7));
var testSet = withRandom.filter(ee.Filter.gte('random', 0.7));

```

```

// === 8. Entraînement Random Forest ===
var classifieur = ee.Classifier.smileRandomForest(100).train({
  features: trainingSet,
  classProperty: 'class',
  inputProperties: enhanced.bandNames()
});

// === 9. Classification finale ===
var classified = enhanced.classify(classifieur);
Map.addLayer(classified, {
  min: 0,
  max: 4,
  palette: ['008000', 'FF0000', '0000FF', '000000', 'C2B280']
}, 'Classification');

// === 10. Évaluation ===
var validated = testSet.classify(classifieur);
var cm = validated.errorMatrix('class', 'classification');
print('Matrice de confusion', cm);
print('Précision globale (%)', cm.accuracy().multiply(100));

// === 11. Export vers Google Drive ===
Export.image.toDrive({
  image: classified,
  description: 'Classification_Ksar_Drive',
  folder: 'GEE_exports',
  region: zone,
  scale: 10,
  maxPixels: 1e13
});

// === 12. Export vers les Assets ===
Export.image.toAsset({
  image: classified,
  description: 'Classification_Ksar_Asset',
  assetId: 'users/lamrabetoumayma10/Classification_KsarElKebir',
  region: zone,
  scale: 10,
  maxPixels: 1e13
});

// === 13. Export des polygones d'entraînement ===
Export.table.toAsset({
  collection: trainingZones,
  description: 'TrainingZones_Ksar',
  assetId: 'users/lamrabetoumayma10/TrainingZones_Ksar'
});

// === 14. Ajouter une légende à la carte ===
var legend = ui.Panel({
  style: {
    position: 'bottom-left',

```

```

        padding: '8px 15px'
    }
});

var legendTitle = ui.Label({
    value: 'Légende des classes',
    style: {
        fontWeight: 'bold',
        fontSize: '14px',
        margin: '0 0 8px 0',
        padding: '0'
    }
});
legend.add(legendTitle);

var palette = ['008000', 'FF0000', '0000FF', '000000', 'C2B280'];
var names = ['Agriculture', 'Bâtiment', 'Eau', 'Route', 'Sol nu'];

var makeLegendItem = function(color, name) {
    var colorBox = ui.Label({
        style: {
            backgroundColor: '#' + color,
            padding: '8px',
            margin: '0 8px 0 0'
        }
    });
    var description = ui.Label({
        value: name,
        style: {
            margin: '0 0 4px 0'
        }
    });

    return ui.Panel({
        widgets: [colorBox, description],
        layout: ui.Panel.Layout.Flow('horizontal')
    });
};

for (var i = 0; i < names.length; i++) {
    legend.add(makeLegendItem(palette[i], names[i]));
}

Map.add(legend);

```

SVM :

Le code suivant met en œuvre une classification supervisée à l'aide de l'algorithme SVM (Support Vector Machine) :

```

// ==== 1. Charger les polygones d'entraînement depuis les Assets (noms en MAJUSCULES) ====
var AGRICULTURE = ee.FeatureCollection('users/lamrabetoumayma10/AGRICULTURE');
var BATIMENT = ee.FeatureCollection('users/lamrabetoumayma10/BATIMENT');

```

```

var EAU      = ee.FeatureCollection('users/lamrabetoumayma10/EAU');
var ROUTE    = ee.FeatureCollection('users/lamrabetoumayma10/ROUTE');
var SOLNU    = ee.FeatureCollection('users/lamrabetoumayma10/SOLNU');

// === 2. Ajouter la classe à chaque FeatureCollection ===
var fc_agriculture = AGRICULTURE.map(function(f) { return f.set('class', 0); });
var fc_batiment    = BATIMENT.map(function(f) { return f.set('class', 1); });
var fc_eau         = EAU.map(function(f) { return f.set('class', 2); });
var fc_route       = ROUTE.map(function(f) { return f.set('class', 3); });
var fc_solnu       = SOLNU.map(function(f) { return f.set('class', 4); });

// === 3. Fusionner toutes les classes dans un seul FeatureCollection ===
var trainingZones = fc_agriculture
  .merge(fc_batiment)
  .merge(fc_eau)
  .merge(fc_route)
  .merge(fc_solnu);

// === 4. Définir la zone d'étude ===
var zone = ee.Geometry.Polygon([
  [
    [-5.93139, 35.00583],
    [-5.90056, 35.00556],
    [-5.89944, 34.98111],
    [-5.92972, 34.98167]
  ]
]);
Map.centerObject(zone, 13);
Map.addLayer(zone, {color: 'red'}, 'Zone d\'étude');

// === 5. Prétraitement Sentinel-2 SR ===
function maskS2(image) {
  var scl = image.select('SCL');
  var mask = scl.neq(3).and(scl.neq(8)).and(scl.neq(9)).and(scl.neq(10)).and(scl.neq(1));
  return image.updateMask(mask).copyProperties(image, ['system:time_start']);
}

var image = ee.ImageCollection('COPERNICUS/S2_SR')
  .filterBounds(zone)
  .filterDate('2024-06-01', '2024-08-01')
  .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 10))
  .map(maskS2)
  .select(['B2', 'B3', 'B4', 'B8', 'B11']) // Bleu, Vert, Rouge, NIR, SWIR
  .median()
  .clip(zone);

// === 6. Réhaussement de contraste corrigé ===
function linearStretch(image, pmin, pmax) {
  var percentiles = image.reduceRegion({
    reducer: ee.Reducer.percentile([pmin, pmax]),
    geometry: zone,

```



```

    scale: 10,
    maxPixels: 1e9
  });

  var bands = image.bandNames();

  var stretchedBands = bands.map(function(bandName) {
    bandName = ee.String(bandName);
    var band = image.select(bandName);
    var min = ee.Number(percentiles.get(bandName.cat('_p').cat(pmin.toString())));
    var max = ee.Number(percentiles.get(bandName.cat('_p').cat(pmax.toString())));
    min = ee.Algorithms.If(min, min, 0);
    max = ee.Algorithms.If(max, max, 1);
    return band.clamp(min, max).unitScale(min, max).rename(bandName);
  });

  var stretched = ee.ImageCollection(stretchedBands).toBands().rename(bands);
  return stretched;
}

var enhanced = linearStretch(image, 2, 98);
Map.addLayer(enhanced, {bands: ['B4', 'B3', 'B2'], min: 0, max: 1}, 'RGB réhaussé');

// === 7. Échantillonnage et préparation du classifieur ===
var training = enhanced.sampleRegions({
  collection: trainingZones,
  properties: ['class'],
  scale: 10
});

var withRandom = training.randomColumn('random');
var trainingSet = withRandom.filter(ee.Filter.lt('random', 0.7));
var testSet = withRandom.filter(ee.Filter.gte('random', 0.7));

// === 8. Entraînement SVM ===
var svmClassifier = ee.Classifier.libsvm({
  kernelType: 'RBF',
  gamma: 0.5,
  cost: 10
}).train({
  features: trainingSet,
  classProperty: 'class',
  inputProperties: enhanced.bandNames()
});

// === 9. Classification finale ===
var classified = enhanced.classify(svmClassifier);
Map.addLayer(classified, {
  min: 0,
  max: 4,
  palette: ['008000', 'FF0000', '0000FF', '000000', 'C2B280']
}, 'Classification SVM');

```

```

// === 10. Évaluation ===
var validated = testSet.classify(svmClassifier);
var cm = validated.errorMatrix('class', 'classification');
print('Matrice de confusion SVM', cm);
print('Précision globale SVM (%)', cm.accuracy().multiply(100));

// === 11. Export vers Google Drive ===
Export.image.toDrive({
  image: classified,
  description: 'Classification_Ksar_SVM_Drive',
  folder: 'GEE_exports',
  region: zone,
  scale: 10,
  maxPixels: 1e13
});

// === 12. Export vers les Assets ===
Export.image.toAsset({
  image: classified,
  description: 'Classification_Ksar_SVM_Asset',
  assetId: 'users/lamrabetoumayma10/Classification_KsarElKebir_SVM',
  region: zone,
  scale: 10,
  maxPixels: 1e13
});

// === 13. Export des polygones d'entraînement ===
Export.table.toAsset({
  collection: trainingZones,
  description: 'TrainingZones_Ksar',
  assetId: 'users/lamrabetoumayma10/TrainingZones_Ksar'
});

// === 14. Légende dynamique ===
var legend = ui.Panel({
  style: {
    position: 'bottom-left',
    padding: '8px 15px'
  }
});

legend.add(ui.Label({
  value: 'Légende des classes',
  style: {
    fontWeight: 'bold',
    fontSize: '14px',
    margin: '0 0 8px 0',
    padding: '0'
  }
}));

```

```

var palette = ['008000', 'FF0000', '0000FF', '000000', 'C2B280'];
var names = ['Agriculture', 'Bâtiment', 'Eau', 'Route', 'Sol nu'];

names.forEach(function(name, i) {
  var colorBox = ui.Label("", {
    backgroundColor: '#' + palette[i],
    padding: '8px',
    margin: '0 8px 0 0'
  });

  var label = ui.Label(name, {margin: '0 0 4px 0'});

  var item = ui.Panel({
    widgets: [colorBox, label],
    layout: ui.Panel.Layout.Flow('horizontal')
  });

  legend.add(item);
});

Map.add(legend);
K means :
// === 0. ZONE D'ÉTUDE ===
var geometry = ee.Geometry.Polygon([
  [-5.931389, 35.005833],
  [-5.900556, 35.005556],
  [-5.899444, 34.981111],
  [-5.929722, 34.981667]
]);

Map.centerObject(geometry, 14);
Map.addLayer(geometry, {color: 'red'}, 'Zone d'étude');

// === 1. IMAGE SENTINEL-2 (AVRIL-JUIN 2024) ===
var s2 = ee.ImageCollection("COPERNICUS/S2_SR")
  .filterBounds(geometry)
  .filterDate('2024-04-01', '2024-06-01')
  .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 10))
  .median()
  .clip(geometry);

// === 2. CORRECTION ATMOSPHÉRIQUE SIMPLE (DOS corrigé) ===
function dos(image) {
  var dark = image.reduceRegion({
    reducer: ee.Reducer.percentile([1]),
    geometry: geometry,
    scale: 10,
    maxPixels: 1e13
  });
  var darkImg = ee.Image.constant(dark.values(image.bandNames()))
    .rename(image.bandNames());
  return image.subtract(darkImg);
}

```

```

}
s2 = dos(s2);

// === 3. CALCUL DES INDICES SPECTRAUX ===
var ndvi = s2.normalizedDifference(['B8', 'B4']).rename('NDVI');
var ndbi = s2.normalizedDifference(['B11', 'B8']).rename('NDBI');
var ndwi = s2.normalizedDifference(['B3', 'B8']).rename('NDWI');

// === 4. MASQUE NDVI (filtrage des zones non végétales) ===
var ndvi_mask = ndvi.gte(0.2); // Seulement les zones végétales ou cultivables
s2 = s2.updateMask(ndvi_mask);

// === 5. IMAGE POUR CLASSIFICATION (bandes + indices) ===
var input = s2.select(['B2', 'B3', 'B4', 'B8', 'B11'])
    .addBands(ndvi).addBands(ndbi).addBands(ndwi);

// === 6. CLASSIFICATION K-MEANS (5 CLASSES) ===
var training = input.sample({
    region: geometry,
    scale: 10,
    numPixels: 5000,
    seed: 123
});

var clusterer = ee.Clusterer.wekaKMeans(5).train(training);
var classified = input.cluster(clusterer);

// === 7. VISUALISATION + LÉGENDE COULEUR ===
var palette = ['#d7191c', '#fdae61', '#ffffbf', '#a6d96a', '#1a9850'];
var vis = {min: 0, max: 4, palette: palette};
Map.addLayer(classified, vis, 'K-means Classification');

// === 8. EXPORT VERS GOOGLE DRIVE ===
Export.image.toDrive({
    image: classified,
    description: 'Classification_KMeans_5classes',
    folder: 'GEE_Exports',
    region: geometry,
    scale: 10,
    maxPixels: 1e13
});

Export.image.toDrive({
    image: ndvi,
    description: 'NDVI_Index',
    folder: 'GEE_Exports',
    region: geometry,
    scale: 10,
    maxPixels: 1e13
});

```

[Classification non supervisée par arbre de décision \(CART\)](#)

// 1. DÉFINITION DE LA ZONE D'ÉTUDE (selon les 4 points donnés)


```

var zone = ee.Geometry.Polygon([[
  [-5.931389, 35.005833], // Point 1
  [-5.900556, 35.005556], // Point 2
  [-5.899444, 34.981111], // Point 3
  [-5.929722, 34.981667] // Point 4
]]);

Map.centerObject(zone, 15);
Map.addLayer(zone, {color: 'red'}, 'Zone d\'étude');

// 2. CHARGER L'IMAGE SENTINEL-2 (Juin 2024)
var image = ee.ImageCollection('COPERNICUS/S2_SR')
  .filterBounds(zone)
  .filterDate('2024-06-01', '2024-06-30')
  .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 10))
  .median()
  .clip(zone);

// Visualisation RGB
Map.addLayer(image, {bands: ['B4', 'B3', 'B2'], min: 0, max: 3000}, 'RGB');

// 3. ÉCHANTILLONS D'ENTRAÎNEMENT AVEC BUFFER (20 m pour couvrir plusieurs pixels)
var buffer = 20;

var solNu = ee.FeatureCollection([
  ee.Feature(ee.Geometry.Point([-5.9215, 34.9970]).buffer(buffer), {'class': 0})
]);
var construction = ee.FeatureCollection([
  ee.Feature(ee.Geometry.Point([-5.9125, 34.9955]).buffer(buffer), {'class': 1})
]);
var eau = ee.FeatureCollection([
  ee.Feature(ee.Geometry.Point([-5.9180, 34.9930]).buffer(buffer), {'class': 2})
]);
var vegetation = ee.FeatureCollection([
  ee.Feature(ee.Geometry.Point([-5.9265, 34.9865]).buffer(buffer), {'class': 3})
]);
var route = ee.FeatureCollection([
  ee.Feature(ee.Geometry.Point([-5.9135, 34.9900]).buffer(buffer), {'class': 4})
]);

// Fusion des échantillons
var samples = solNu.merge(construction).merge(eau).merge(vegetation).merge(route);

// 4. EXTRACTION DES PIXELS D'ENTRAÎNEMENT
var bands = ['B2', 'B3', 'B4', 'B5', 'B6', 'B7', 'B8', 'B11', 'B12'];
var training = image.select(bands).sampleRegions({
  collection: samples,
  properties: ['class'],
  scale: 10
});

// 5. ENTRAÎNEMENT DU CLASSIFIEUR CART

```

```
var classifier = ee.Classifier.smileCart().train({
  features: training,
  classProperty: 'class',
  inputProperties: bands
});
```

// 6. CLASSIFICATION DE L'IMAGE

```
var classified = image.select(bands).classify(classifier);
```

// 7. VISUALISATION

```
var palette = ['brown', 'grey', 'blue', 'green', 'black'];
Map.addLayer(classified, {min: 0, max: 4, palette: palette}, 'Classification');
```

// 8. EXPORT VERS GOOGLE DRIVE

```
Export.image.toDrive({
  image: classified,
  description: 'Classification_Agriculture_Urbain',
  folder: 'GEE_Exports',
  region: zone,
  scale: 10,
  fileFormat: 'GeoTIFF',
  maxPixels: 1e13
});
```

[Validation de classification RF :](#)

Les points de valisation :

// === 1. Ajouter une propriété 'landcover' à chaque polygone ===

```
var fc_BATIMENT = ee.FeatureCollection(BATIMENT_VAR).map(function(feature) {
  return feature.set('landcover', 1);
});
```

```
var fc_EAU = ee.FeatureCollection(EAU_VAR).map(function(feature) {
  return feature.set('landcover', 2);
});
```

```
var fc_AGRICULTURE = ee.FeatureCollection(AGRICULTURE_VAR).map(function(feature) {
  return feature.set('landcover', 0);
});
```

```
var fc_ROUTE = ee.FeatureCollection(ROUTE_VAR).map(function(feature) {
  return feature.set('landcover', 3);
});
```

```
var fc_SOLNU = ee.FeatureCollection(SOLNU_VAR).map(function(feature) {
  return feature.set('landcover', 4);
});
```

// === 2. Fusionner toutes les classes dans une seule FeatureCollection ===

```
var trainingPolygons = fc_AGRICULTURE
  .merge(fc_BATIMENT)
  .merge(fc_EAU)
  .merge(fc_ROUTE)
  .merge(fc_SOLNU);
```

```
// === 3. Exporter vers les Assets ===  
// Remplace 'ton_nom_utilisateur' par ton ID Earth Engine (ici on garde 'lamrabetoumayma10')
```

```
Export.table.toAsset({  
  collection: fc_AGRICULTURE,  
  description: 'Export_AGRICULTURE',  
  assetId: 'users/lamrabetoumayma10/AGRICULTURE_VAR'  
});
```

```
Export.table.toAsset({  
  collection: fc_BATIMENT,  
  description: 'Export_BATIMENT',  
  assetId: 'users/lamrabetoumayma10/BATIMENT_VAR'  
});
```

```
Export.table.toAsset({  
  collection: fc_EAU,  
  description: 'Export_EAU',  
  assetId: 'users/lamrabetoumayma10/EAU_VAR'  
});
```

```
Export.table.toAsset({  
  collection: fc_ROUTE,  
  description: 'Export_ROUTE',  
  assetId: 'users/lamrabetoumayma10/ROUTE_VAR'  
});
```

```
Export.table.toAsset({  
  collection: fc_SOLNU,  
  description: 'Export_SOLNU',  
  assetId: 'users/lamrabetoumayma10/SOLNU_VAR'  
});
```

Matrice de confusion

```
// === 1. Charger l'image classifiée depuis les Assets ===  
var classified = ee.Image('users/lamrabetoumayma10/Classification_final_random_forest');
```

```
// === 2. Charger les FeatureCollections de validation ===  
var agriculture_val = ee.FeatureCollection('users/lamrabetoumayma10/AGRICULTURE_VAR');  
var batiment_val = ee.FeatureCollection('users/lamrabetoumayma10/BATIMENT_VAR');  
var eau_val = ee.FeatureCollection('users/lamrabetoumayma10/EAU_VAR');  
var route_val = ee.FeatureCollection('users/lamrabetoumayma10/ROUTE_VAR');  
var solnu_val = ee.FeatureCollection('users/lamrabetoumayma10/SOLNU_VAR');
```

```
// === 3. Ajouter les étiquettes de classe à chaque FeatureCollection ===  
agriculture_val = agriculture_val.map(function(f) {  
  return f.set('landcover', 0);  
});
```

```
batiment_val = batiment_val.map(function(f) {  
  return f.set('landcover', 1);  
});
```

```

eau_val = eau_val.map(function(f) {
  return f.set('landcover', 2);
});

route_val = route_val.map(function(f) {
  return f.set('landcover', 3);
});

solnu_val = solnu_val.map(function(f) {
  return f.set('landcover', 4);
});

// === 4. Fusionner toutes les zones de validation ===
var validation = agriculture_val
  .merge(batiment_val)
  .merge(eau_val)
  .merge(route_val)
  .merge(solnu_val);

// === 5. Échantillonner l'image classifiée avec les polygones de validation ===
var validationPoints = classified.sampleRegions({
  collection: validation,
  properties: ['landcover'],
  scale: 10,
  geometries: true
});

// === 6. Créer et afficher la matrice de confusion ===
var confMatrix = validationPoints.errorMatrix('landcover', 'classification');
print('Matrice de confusion :', confMatrix);
print('Précision globale :', confMatrix.accuracy());
print('Kappa :', confMatrix.kappa());

```

Validation de svm :

```

// === 1. Charger l'image classifiée SVM depuis les Assets ===
var classified = ee.Image('users/lamrabetoumayma10/Classification_KsarElKebir_SVM');

// === 2. Charger les FeatureCollections de validation ===
var agriculture_val = ee.FeatureCollection('users/lamrabetoumayma10/AGRICULTURE_VAR');
var batiment_val = ee.FeatureCollection('users/lamrabetoumayma10/BATIMENT_VAR');
var eau_val = ee.FeatureCollection('users/lamrabetoumayma10/EAU_VAR');
var route_val = ee.FeatureCollection('users/lamrabetoumayma10/ROUTE_VAR');
var solnu_val = ee.FeatureCollection('users/lamrabetoumayma10/SOLNU_VAR');

// === 3. Ajouter les étiquettes de classe à chaque FeatureCollection ===
agriculture_val = agriculture_val.map(function(f) {
  return f.set('landcover', 0);
});

batiment_val = batiment_val.map(function(f) {

```

```

    return f.set('landcover', 1);
  });

  eau_val = eau_val.map(function(f) {
    return f.set('landcover', 2);
  });

  route_val = route_val.map(function(f) {
    return f.set('landcover', 3);
  });

  solnu_val = solnu_val.map(function(f) {
    return f.set('landcover', 4);
  });

  // === 4. Fusionner toutes les zones de validation ===
  var validation = agriculture_val
    .merge(batiment_val)
    .merge(eau_val)
    .merge(route_val)
    .merge(solnu_val);

  // === 5. Échantillonner l'image classifiée avec les polygones de validation ===
  var validationPoints = classified.sampleRegions({
    collection: validation,
    properties: ['landcover'],
    scale: 10,
    geometries: true
  });

  // === 6. Créer et afficher la matrice de confusion ===
  var confMatrix = validationPoints.errorMatrix('landcover', 'classification');
  print('📊 Matrice de confusion SVM :', confMatrix);
  print('📈 Précision globale SVM :', confMatrix.accuracy());
  print('📊 Kappa SVM :', confMatrix.kappa());

```

SMI :

Code utilisé /

```

// === Zone d'étude ===
var zone = ee.Geometry.Polygon([
  [-5.93139, 35.00583],
  [-5.90056, 35.00556],
  [-5.89944, 34.98111],
  [-5.92972, 34.98167]
]);
Map.centerObject(zone, 13);

// === Prétraitement Sentinel-2 SR ===
function maskS2(image) {
  var scl = image.select('SCL');
  var mask = scl.neq(3).and(scl.neq(8)).and(scl.neq(9)).and(scl.neq(10)).and(scl.neq(1));
  return image.updateMask(mask).copyProperties(image, ['system:time_start']);
}

```



```

}

var image = ee.ImageCollection('COPERNICUS/S2_SR')
  .filterBounds(zone)
  .filterDate('2024-06-01', '2024-08-01')
  .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 10))
  .map(maskS2)
  .median()
  .clip(zone);

// === Calcul Soil Moisture Index (SMI) ===
var SMI = image.expression(
  '(B8A - B11) / (B8A + B11)', {
    'B8A': image.select('B8A'),
    'B11': image.select('B11')
  }).rename('SMI');

// === Classification SMI en 4 classes ===
var classes = ee.Image(0)
  .where(SMI.gt(0.4), 4) // Très humide
  .where(SMI.lte(0.4).and(SMI.gt(0.2)), 3) // Modéré
  .where(SMI.lte(0.2).and(SMI.gt(0.0)), 2) // Sec
  .where(SMI.lte(0.0), 1); // Très sec

// === Palette modifiée ===
var palette = ['8e44ad', '2980b9', 'e67e22', 'f1c40f']; // violet, bleu, orange, jaune

Map.addLayer(classes, {min:1, max:4, palette: palette, opacity:0.8}, 'SMI classifié');

// === Légende ===
var legend = ui.Panel({
  style: {
    position: 'bottom-right',
    padding: '8px 15px',
    backgroundColor: 'white',
    fontWeight: 'bold'
  }
});

legend.add(ui.Label('LÉGENDE - Soil Moisture Index (SMI)',
  {fontWeight: 'bold', fontSize: '16px', margin: '0 0 6px 0'}));

function makeLegendItem(color, name) {
  var colorBox = ui.Label("", {
    backgroundColor: '#' + color,
    padding: '8px',
    margin: '0 0 4px 0',
    width: '20px',
    height: '20px'
  });
  var description = ui.Label(name, {margin: '0 0 4px 6px'});
  return ui.Panel([colorBox, description], ui.Panel.Layout.Flow('horizontal'));
}

```

```

}

legend.add(makeLegendItem('f1c40f', '4 - Très humide (> 0.4)'));
legend.add(makeLegendItem('e67e22', '3 - Modéré (0.2 - 0.4)'));
legend.add(makeLegendItem('2980b9', '2 - Sec (0.0 - 0.2)'));
legend.add(makeLegendItem('8e44ad', '1 - Très sec (≤ 0.0)'));

Map.add(legend);

// === Export vers Google Drive ===
Export.image.toDrive({
  image: classes,
  description: 'SMI_Classification_KsarElKebir',
  folder: 'GEE_exports',
  fileNamePrefix: 'SMI_Classification_KsarElKebir',
  region: zone,
  scale: 10,
  maxPixels: 1e13
});

// === Export vers Google Assets ===
Export.image.toAsset({
  image: classes,
  description: 'SMI_Classification_Asset_KsarElKebir',
  assetId: 'users/lamrabetoumayma10/SMI_Classification_KsarElKebir',
  region: zone,
  scale: 10,
  maxPixels: 1e13
});

```

SOC :

Code utilisé :

```

// === Zone d'étude ===
var zone = ee.Geometry.Polygon([
  [[-5.93139, 35.00583],
  [-5.90056, 35.00556],
  [-5.89944, 34.98111],
  [-5.92972, 34.98167]]
]);
Map.centerObject(zone, 13);

// === Prétraitement Sentinel-2 SR ===
function maskS2(image) {
  var scl = image.select('SCL');
  var mask = scl.neq(3).and(scl.neq(8)).and(scl.neq(9)).and(scl.neq(10)).and(scl.neq(1));
  return image.updateMask(mask).copyProperties(image, ['system:time_start']);
}

var image = ee.ImageCollection('COPERNICUS/S2_SR')
  .filterBounds(zone)
  .filterDate('2024-06-01', '2024-08-01')
  .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 10))

```

```

.map(maskS2)
.median()
.clip(zone);

// === Calcul Soil Organic Carbon (SOC) ===
var SOC = image.expression(
  '(B11 - B8A) / (B11 + B8A)', {
    'B11': image.select('B11'),
    'B8A': image.select('B8A')
  }).rename('SOC');

// === Classification SOC en 4 classes ===
var classes_SOC = ee.Image(0)
  .where(SOC.gt(0.3), 4) // Très élevé
  .where(SOC.lte(0.3).and(SOC.gt(0.1)), 3) // Élevé
  .where(SOC.lte(0.1).and(SOC.gt(0.0)), 2) // Faible
  .where(SOC.lte(0.0), 1); // Très faible

// === Palette SOC modifiée ===
var palette_SOC = ['ff6961', 'fef65b', '77dd77', '1f75fe']; // rouge clair, jaune, vert clair, bleu vif

Map.addLayer(classes_SOC, {min: 1, max: 4, palette: palette_SOC, opacity: 0.8}, 'SOC classifié');

// === Légende SOC ===
var legend_SOC = ui.Panel({
  style: {
    position: 'bottom-right',
    padding: '8px 15px',
    backgroundColor: 'white',
    fontWeight: 'bold'
  }
});

legend_SOC.add(ui.Label('LÉGENDE - Soil Organic Carbon (SOC)',
  {fontWeight: 'bold', fontSize: '16px', margin: '0 0 6px 0'}));

function makeLegendItem(color, name) {
  var colorBox = ui.Label("", {
    backgroundColor: '#' + color,
    padding: '8px',
    margin: '0 0 4px 0',
    width: '20px',
    height: '20px'
  });
  var description = ui.Label(name, {margin: '0 0 4px 6px'});
  return ui.Panel([colorBox, description], ui.Panel.Layout.Flow('horizontal'));
}

legend_SOC.add(makeLegendItem('1f75fe', '4 - Très élevé (> 0.3)'));
legend_SOC.add(makeLegendItem('77dd77', '3 - Élevé (0.1 - 0.3)'));
legend_SOC.add(makeLegendItem('fef65b', '2 - Faible (0.0 - 0.1)'));
legend_SOC.add(makeLegendItem('ff6961', '1 - Très faible (≤ 0.0)'));

```

```

Map.add(legend_SOC);

// === Export vers Google Drive ===
Export.image.toDrive({
  image: classes_SOC,
  description: 'SOC_Classification_KsarElKebir',
  folder: 'GEE_exports',
  fileNamePrefix: 'SOC_Classification_KsarElKebir',
  region: zone,
  scale: 10,
  maxPixels: 1e13
});

// === Export vers Google Assets ===
Export.image.toAsset({
  image: classes_SOC,
  description: 'SOC_Classification_Asset_KsarElKebir',
  assetId: 'users/lamrabetoumayma10/SOC_Classification_KsarElKebir',
  region: zone,
  scale: 10,
  maxPixels: 1e13
})

FE :
Code utilisé :
// === Zone d'étude ===
var zone = ee.Geometry.Polygon([
  [-5.93139, 35.00583],
  [-5.90056, 35.00556],
  [-5.89944, 34.98111],
  [-5.92972, 34.98167]
]);
Map.centerObject(zone, 13);

// === Prétraitement Sentinel-2 SR ===
function maskS2(image) {
  var scl = image.select('SCL');
  var mask = scl.neq(3).and(scl.neq(8)).and(scl.neq(9)).and(scl.neq(10)).and(scl.neq(11));
  return image.updateMask(mask).copyProperties(image, ['system:time_start']);
}

var image = ee.ImageCollection('COPERNICUS/S2_SR')
  .filterBounds(zone)
  .filterDate('2024-06-01', '2024-08-01')
  .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 10))
  .map(maskS2)
  .median()
  .clip(zone);

// === Calcul Ferric Iron Index (Fe) ===
var Fe = image.expression(

```

```

'(B4 - B3) / (B4 + B3)', {
  'B4': image.select('B4'),
  'B3': image.select('B3')
}).rename('Fe');

// === Classification Fe en 4 classes ===
var classes_Fe = ee.Image(0)
  .where(Fe.gt(0.4), 4) // Très élevé
  .where(Fe.lte(0.4).and(Fe.gt(0.2)), 3) // Élevé
  .where(Fe.lte(0.2).and(Fe.gt(0.0)), 2) // Faible
  .where(Fe.lte(0.0), 1); // Très faible

// === Nouvelle palette Fe modifiée ===
var palette_Fe = ['00441b', '238b45', '74c476', 'bae4b3']; // vert foncé, vert moyen, vert clair, vert très
clair

Map.addLayer(classes_Fe, {min: 1, max: 4, palette: palette_Fe, opacity: 0.8}, 'Fe classifié');

// === Légende Fe ===
var legend_Fe = ui.Panel({
  style: {
    position: 'bottom-right',
    padding: '8px 15px',
    backgroundColor: 'white',
    fontWeight: 'bold'
  }
});

legend_Fe.add(ui.Label('LÉGENDE - Ferric Iron Index (Fe)',
  {fontWeight: 'bold', fontSize: '16px', margin: '0 0 6px 0'}));

function makeLegendItem(color, name) {
  var colorBox = ui.Label("", {
    backgroundColor: '#' + color,
    padding: '8px',
    margin: '0 0 4px 0',
    width: '20px',
    height: '20px'
  });
  var description = ui.Label(name, {margin: '0 0 4px 6px'});
  return ui.Panel([colorBox, description], ui.Panel.Layout.Flow('horizontal'));
}

legend_Fe.add(makeLegendItem('bae4b3', '4 - Très élevé (> 0.4));
legend_Fe.add(makeLegendItem('74c476', '3 - Élevé (0.2 - 0.4));
legend_Fe.add(makeLegendItem('238b45', '2 - Faible (0.0 - 0.2));
legend_Fe.add(makeLegendItem('00441b', '1 - Très faible (≤ 0.0));

Map.add(legend_Fe);

// === Export vers Google Drive ===
Export.image.toDrive({

```



```

image: classes_Fe,
description: 'Fe_Classification_KsarElKebir',
folder: 'GEE_exports',
fileNamePrefix: 'Fe_Classification_KsarElKebir',
region: zone,
scale: 10,
maxPixels: 1e13
});

// === Export vers Google Assets ===
Export.image.toAsset({
  image: classes_Fe,
  description: 'Fe_Classification_Asset_KsarElKebir',
  assetId: 'users/lamrabetoumayma10/Fe_Classification_KsarElKebir',
  region: zone,
  scale: 10,
  maxPixels: 1e13
});

```

Fusion des indices :

Le code utilisé :

```

// === Zone d'étude ===
var zone = ee.Geometry.Polygon([
  [[-5.93139, 35.00583],
  [-5.90056, 35.00556],
  [-5.89944, 34.98111],
  [-5.92972, 34.98167]]
]);
Map.centerObject(zone, 13);

// === Masquage des nuages et préparation Sentinel-2 SR ===
function maskS2(image) {
  var scl = image.select('SCL');
  var mask = scl.neq(3).and(scl.neq(8)).and(scl.neq(9)).and(scl.neq(10)).and(scl.neq(1));
  return image.updateMask(mask).copyProperties(image, ['system:time_start']);
}

var image = ee.ImageCollection('COPERNICUS/S2_SR')
  .filterBounds(zone)
  .filterDate('2024-06-01', '2024-08-01')
  .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 10))
  .map(maskS2)
  .median()
  .clip(zone);

// === Calcul des indices ===
// SMI = (B8A - B11) / (B8A + B11)
var SMI = image.expression(
  '(B8A - B11) / (B8A + B11)', {
    'B8A': image.select('B8A'),
    'B11': image.select('B11')
  }).rename('SMI');

```

```

// SOC = (B3 - B4) / (B3 + B4)
var SOC = image.expression(
  '(B3 - B4) / (B3 + B4)', {
    'B3': image.select('B3'),
    'B4': image.select('B4')
  }).rename('SOC');

// Ferric Iron (FI) = (B4 - B3) / (B4 + B3)
var FI = image.expression(
  '(B4 - B3) / (B4 + B3)', {
    'B4': image.select('B4'),
    'B3': image.select('B3')
  }).rename('FI');

// === Classification des indices en 4 classes ===
function classifyIndex(indexImg) {
  return ee.Image(0)
    .where(indexImg.gt(0.4), 4)
    .where(indexImg.lte(0.4).and(indexImg.gt(0.2)), 3)
    .where(indexImg.lte(0.2).and(indexImg.gt(0.0)), 2)
    .where(indexImg.lte(0.0), 1);
}

var SMI_class = classifyIndex(SMI).rename('SMI_class');
var SOC_class = classifyIndex(SOC).rename('SOC_class');
var FI_class = classifyIndex(FI).rename('FI_class');

// === Palette des classes (1 à 4) ===
var palette = ['8e44ad', '2980b9', 'e67e22', 'f1c40f']; // violet, bleu, orange, jaune

// === Affichage des indices classifiés ===
Map.addLayer(SMI_class, {min:1, max:4, palette: palette, opacity: 0.7}, 'SMI classifié');
Map.addLayer(SOC_class, {min:1, max:4, palette: palette, opacity: 0.7}, 'SOC classifié');
Map.addLayer(FI_class, {min:1, max:4, palette: palette, opacity: 0.7}, 'FI classifié');

// === Combinaison des indices pour une carte finale (somme des classes) ===
var combined = SMI_class.add(SOC_class).add(FI_class).rename('Combined');

// Valeurs combinées vont de 3 (1+1+1) à 12 (4+4+4)

// === Classification finale basée sur la somme ===
// Par exemple :
// 3-5 = faible propice (1)
// 6-8 = moyen (2)
// 9-10 = bon (3)
// 11-12 = très bon (4)

var final_class = combined.expression(
  "b('Combined') <= 5 ? 1" +
  ": b('Combined') <= 8 ? 2" +
  ": b('Combined') <= 10 ? 3" +
  ": 4"

```

```

).rename('Final_class');

// Palette finale
var final_palette = ['d73027', 'fee08b', '1a9850', '006837']; // rouge, jaune clair, vert, vert foncé

Map.addLayer(final_class, {min:1, max:4, palette: final_palette, opacity:0.8}, 'Carte finale agriculture urbaine');

// === Légende simple pour la carte finale ===
var legend = ui.Panel({
  style: {position: 'bottom-right', padding: '8px 15px', backgroundColor: 'white', fontWeight: 'bold'}
});
legend.add(ui.Label('LÉGENDE - Zones propices agriculture urbaine', {fontSize: '16px', margin: '0 0 6px 0'}));

function makeLegendItem(color, name) {
  var colorBox = ui.Label('', {backgroundColor: color, padding: '8px', margin: '0 0 4px 0', width: '20px', height: '20px'});
  var description = ui.Label(name, {margin: '0 0 4px 6px'});
  return ui.Panel([colorBox, description], ui.Panel.Layout.Flow('horizontal'));
}

legend.add(makeLegendItem('#d73027', '1 - Faible propice'));
legend.add(makeLegendItem('#fee08b', '2 - Moyennement propice'));
legend.add(makeLegendItem('#1a9850', '3 - Bon'));
legend.add(makeLegendItem('#006837', '4 - Très bon'));

Map.add(legend);

// === Exporter la carte finale vers Drive ===
Export.image.toDrive({
  image: final_class,
  description: 'Final_Agriculture_Urbaine_KsarElKebir',
  folder: 'GEE_exports',
  fileNamePrefix: 'Final_Agriculture_Urbaine_KsarElKebir',
  region: zone,
  scale: 10,
  maxPixels: 1e13
});

// === Exporter la carte finale vers Assets ===
Export.image.toAsset({
  image: final_class,
  description: 'Final_Agriculture_Urbaine_Asset_KsarElKebir',
  assetId: 'users/lamrabetoumayma10/Final_Agriculture_Urbaine_KsarElKebir',
  region: zone,
  scale: 10,
  maxPixels: 1e13
});

```

Résultat final :

Le code utilisé

```

// === 1. Charger les polygones d'entraînement depuis les Assets ===

```

```

var agriculture = ee.FeatureCollection('users/lamrabetoumayma10/AGRICULTURE');
var batiment    = ee.FeatureCollection('users/lamrabetoumayma10/BATIMENT');
var eau         = ee.FeatureCollection('users/lamrabetoumayma10/EAU');
var route       = ee.FeatureCollection('users/lamrabetoumayma10/ROUTE');
var solnu       = ee.FeatureCollection('users/lamrabetoumayma10/SOLNU');

// === 2. Ajouter la classe à chaque FeatureCollection ===
var fc_agriculture = agriculture.map(function(f) { return f.set('class', 0); });
var fc_batiment    = batiment.map(function(f) { return f.set('class', 1); });
var fc_eau         = eau.map(function(f) { return f.set('class', 2); });
var fc_route       = route.map(function(f) { return f.set('class', 3); });
var fc_solnu       = solnu.map(function(f) { return f.set('class', 4); });

// === 3. Fusionner toutes les classes dans un seul FeatureCollection ===
var trainingZones = fc_agriculture
  .merge(fc_batiment)
  .merge(fc_eau)
  .merge(fc_route)
  .merge(fc_solnu);

// === 4. Définir la zone d'étude ===
var zone = ee.Geometry.Polygon([
  [
    [-5.93139, 35.00583],
    [-5.90056, 35.00556],
    [-5.89944, 34.98111],
    [-5.92972, 34.98167]
  ]
]);
Map.centerObject(zone, 13);
Map.addLayer(zone, {color: 'red'}, 'Zone d\'étude');

// === 5. Prétraitement Sentinel-2 SR ===
function maskS2(image) {
  var scl = image.select('SCL');
  var mask = scl.neq(3).and(scl.neq(8)).and(scl.neq(9)).and(scl.neq(10)).and(scl.neq(1));
  return image.updateMask(mask).copyProperties(image, ['system:time_start']);
}

var image = ee.ImageCollection('COPERNICUS/S2_SR')
  .filterBounds(zone)
  .filterDate('2024-06-01', '2024-08-01')
  .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 10))
  .map(maskS2)
  .select(['B2', 'B3', 'B4', 'B8', 'B11']) // Bleu, Vert, Rouge, NIR, SWIR
  .median()
  .clip(zone);

// === 6. Réhaussement de contraste ===
function linearStretch(image, pmin, pmax) {
  var percentiles = image.reduceRegion({
    reducer: ee.Reducer.percentile([pmin, pmax]),

```

```

    geometry: zone,
    scale: 10,
    maxPixels: 1e9
  });

  var bands = image.bandNames();

  var stretchedBands = bands.map(function(bandName) {
    bandName = ee.String(bandName);
    var band = image.select(bandName);
    var min = ee.Number(percentiles.get(bandName.cat('_p').cat(pmin.toString())));
    var max = ee.Number(percentiles.get(bandName.cat('_p').cat(pmax.toString())));
    min = ee.Algorithms.If(min, min, 0);
    max = ee.Algorithms.If(max, max, 1);
    return band.clamp(min, max).unitScale(min, max).rename(bandName);
  });

  return ee.ImageCollection(stretchedBands).toBands().rename(bands);
}

var enhanced = linearStretch(image, 2, 98);
Map.addLayer(enhanced, {bands: ['B4', 'B3', 'B2'], min: 0, max: 1}, 'RGB réhaussé');

// === 7. Échantillonnage et classifieur ===
var training = enhanced.sampleRegions({
  collection: trainingZones,
  properties: ['class'],
  scale: 10
});

var withRandom = training.randomColumn('random');
var trainingSet = withRandom.filter(ee.Filter.lt('random', 0.7));
var testSet = withRandom.filter(ee.Filter.gte('random', 0.7));

// === 8. Entraînement Random Forest ===
var classifier = ee.Classifier.smileRandomForest(100).train({
  features: trainingSet,
  classProperty: 'class',
  inputProperties: enhanced.bandNames()
});

// === 9. Classification finale ===
var classified = enhanced.classify(classifier);
Map.addLayer(classified, {
  min: 0,
  max: 4,
  palette: ['008000', 'FF0000', '0000FF', '000000', 'C2B280']
}, 'Classification');

// === 10. Évaluation ===
var validated = testSet.classify(classifier);
var cm = validated.errorMatrix('class', 'classification');
```



```

print('Matrice de confusion', cm);
print('Précision globale (%)', cm.accuracy().multiply(100));

// === 11. Extraction des pixels SOLNU ===
var solnu_mask = classified.eq(4);
var solnu_area = enhanced.updateMask(solnu_mask);

// === 12. Calcul des indices ===
var ndvi = image.normalizedDifference(['B8', 'B4']).rename('NDVI');
var smi = image.normalizedDifference(['B11', 'B8']).rename('SMI');
var soc = image.select('B3').divide(image.select('B2')).rename('SOC');
var fi = ndvi.add(smi).rename('FI');

// === 13. Détection des zones propices ===
var smi_thresh = smi.gt(0.1);
var soc_thresh = soc.gt(1.2);
var fi_thresh = fi.gt(0.3);
var propice = smi_thresh.and(soc_thresh).and(fi_thresh).and(solnu_mask);
Map.addLayer(propice.updateMask(propice), {palette: ['00FF00']}, 'Zones propices');

// === 14. Export vers Google Drive ===
Export.image.toDrive({
  image: propice.updateMask(propice),
  description: 'Zones_Propices_Agriculture_Urbaines',
  folder: 'GEE_exports',
  region: zone,
  scale: 10,
  maxPixels: 1e13
});

// === 15. Ajout d'une légende ===
var legend = ui.Panel({style: {position: 'bottom-left', padding: '8px 15px'}});
legend.add(ui.Label({value: 'Légende', style: {fontWeight: 'bold', fontSize: '16px'}}));

function makeRow(color, name) {
  var colorBox = ui.Label("", {backgroundColor: color, padding: '8px', margin: '0 0 4px 0'});
  var description = ui.Label(name, {margin: '0 0 4px 6px'});
  return ui.Panel({widgets: [colorBox, description], layout: ui.Panel.Layout.Flow('horizontal')});
}

legend.add(makeRow('#008000', 'Agriculture'));
legend.add(makeRow('#FF0000', 'Bâtiment'));
legend.add(makeRow('#0000FF', 'Eau'));
legend.add(makeRow('#000000', 'Route'));
legend.add(makeRow('#C2B280', 'Sol nu'));
legend.add(makeRow('#00FF00', 'Zones propices agriculture'));

Map.add(legend);

```

Les références

Aubry, C., Ramamonjisoa, J., Dabat, M. H., Rakotoarisoa, J., Rakotondraibe, J., & Rabeharisoa, L. (2012). *Urban agriculture and land use in cities: An approach with the multi-functionality and sustainability concepts in the case of Antananarivo (Madagascar)*.

Longley, P. A., Goodchild, M. F., Maguire, D. J., & Rhind, D. W. (2015). *Geographic Information Systems and Science* (4th ed.). Wiley.

Belgiu, M., & Drăguț, L. (2016). Random forest in remote sensing: A review of applications and future directions. *ISPRS Journal of Photogrammetry and Remote Sensing*, 114, 24–31.

Mountrakis, G., Im, J., & Ogole, C. (2011). Support vector machines in remote sensing: A review. *ISPRS Journal of Photogrammetry and Remote Sensing*, 66(3), 247–259.

Congalton, R. G., & Green, K. (2008). *Assessing the Accuracy of Remotely Sensed Data: Principles and Practices*. CRC Press.

Jensen, J. R. (2016). *Introductory Digital Image Processing: A Remote Sensing Perspective*. Pearson.

Segal (1982) : Premier à proposer des indices spectraux pour les oxydes de fer.

Bedini (2011) : Validation de l'utilisation des bandes Sentinel-2 pour cartographier le fer.

Réf. : Bedini, E. (2011). "Mineral mapping in the Kap Simpson complex, East Greenland, using HyMap and ASTER remote sensing data." *International Journal of Remote Sensing*