



معهد الحسن الثاني للزراعة والبيطرة
INSTITUT AGRONOMIQUE ET VÉTÉRINAIRE HASSAN II

La détection des panneaux photovoltaïques à l'aide du model Deep Learning Mask R-CNN via de l'imagerie RGB

Réalisée par :

- Ben Ouaa Atmane
- Naciri Oussama
- Gharoumi Oussama
- Nahid Salaheddine
- Daoudi Bader Eddine

Encadré par :

- Mme. SEBARI Imane
- Mme. AIR EL KADI KENZA
- JABRANE MOUAD

Table des matières

I.	Introduction :.....	3
II.	Problématique :.....	4
III.	Objectif du projet :	5
IV.	Méthodologie	6
1.	Approche par un modèle de Deep Learning pré-entraîné (Mask R-CNN avec GeoAI).....	6
2.	Réentraînent (FINE-TUNING) du modèle Mask R-CNN	16
3.	Approche par classification sous ERDAS Imagine	18
a)	Classification supervisée : méthode de la Distance Minimale.....	18
b)	Classification non supervisée : méthode de isodata	21
V.	Discussion :	23
VI.	Limites des méthodes utilisées :	25
VII.	Conclusion :.....	26
VIII.	Bibliographie :	28

I. Introduction :

Dans un contexte mondial marqué par la transition énergétique et la lutte contre le changement climatique, les énergies renouvelables occupent une place centrale. Parmi elles, l'énergie solaire photovoltaïque se distingue par son potentiel de production propre et durable. Avec l'essor des installations solaires à travers le monde, la détection automatique des panneaux photovoltaïques à partir d'images satellitaires ou aériennes devient une problématique stratégique pour de nombreuses applications, allant de la planification énergétique à la surveillance de l'aménagement du territoire.

Ce projet s'inscrit dans cette dynamique et vise à développer une méthode efficace pour détecter les panneaux photovoltaïques à partir d'images à haute résolution. Pour cela, deux approches complémentaires ont été explorées :

La première repose sur l'utilisation d'un modèle de Deep Learning, **Mask R-CNN**, spécialisé dans la détection et la segmentation d'objets. Ce modèle a été réentraîné (fine-tuning) par le chercheur **Qiusheng Wu**, professeur en géoinformatique et fondateur de la bibliothèque **GeoAI**, afin de l'adapter spécifiquement à la détection des panneaux photovoltaïques dans les images géospatiales.

GeoAI (abréviation de *Geospatial Artificial Intelligence*) est une bibliothèque Python open source intégrée à l'écosystème de Google Earth Engine et d'autres outils SIG (*systèmes d'information géographique*). Elle vise à simplifier l'application des techniques d'intelligence artificielle aux données spatiales, en proposant une interface conviviale pour l'analyse, la visualisation et le traitement des images satellites. GeoAI permet notamment de combiner des modèles d'apprentissage profond avec des données issues de plateformes comme Sentinel, Landsat ou encore NAIP, rendant possible l'analyse géospatiale à grande échelle.

La seconde approche repose sur des techniques de **classification supervisée et non supervisée**, mises en œuvre à l'aide du logiciel **ERDAS Imagine**, une solution professionnelle largement utilisée en télédétection pour l'analyse, la segmentation et l'interprétation des images satellitaires.

- Pour la **classification supervisée**, la méthode choisie est celle de la **Distance Minimale** (*Minimum Distance Classifier*), qui attribue chaque pixel à la classe dont le centre moyen est le plus proche dans l'espace spectral. Cette méthode est simple, rapide et donne de bons résultats lorsque les classes sont bien séparées.
- Pour la **classification non supervisée**, l'algorithme **ISODATA** (*Iterative Self-Organizing Data Analysis Technique*) a été utilisé. Cet algorithme itératif regroupe les pixels en classes homogènes selon leurs caractéristiques spectrales, en adaptant dynamiquement le nombre et la forme des groupes. Il est particulièrement efficace lorsqu'on ne connaît pas à l'avance les classes présentes dans l'image.

L'objectif principal de ce travail est de **comparer** l'efficacité et la précision de ces deux approches en termes de détection des installations photovoltaïques, afin de déterminer les avantages et les limites de chacune dans des contextes d'utilisation variés.

II. Problématique :

L'accélération du déploiement des énergies renouvelables, notamment l'énergie solaire, s'est traduite par une augmentation rapide des installations de panneaux photovoltaïques à travers le monde. Dans ce contexte, la capacité à **localiser, recenser et surveiller automatiquement ces installations** constitue un enjeu stratégique pour les collectivités, les décideurs politiques, les chercheurs et les acteurs du secteur énergétique.

Traditionnellement, la détection des panneaux solaires repose sur des enquêtes de terrain, des bases de données déclaratives ou des traitements manuels d'images, des méthodes souvent longues, coûteuses et difficilement applicables à grande échelle. Face à cette problématique, l'utilisation des images satellitaires ou aériennes associée à des **méthodes automatiques d'analyse** constitue une alternative puissante et prometteuse.

Cependant, plusieurs **défis techniques** se posent :

- Comment distinguer avec fiabilité les panneaux photovoltaïques des autres objets présents sur les toitures ou au sol ?
- Quelle méthode fournit les **résultats les plus précis** dans un temps raisonnable, tout en restant accessible en termes d'outils et de compétences nécessaires ?
- Les techniques classiques de classification d'image sont-elles suffisantes, ou faut-il recourir à des **modèles de Deep Learning incluant l'intelligence artificielle (IA)** plus complexes et plus performants ?

Ainsi, la problématique centrale de ce projet peut être formulée comme suit :

Quelle méthode permet de détecter avec précision et efficacité les panneaux photovoltaïques à partir d'images satellitaires ou aériennes : une approche basée sur le Deep Learning (Mask R-CNN avec GeoAI) ou une classification d'image traditionnelle (Distance Minimale et ISODATA sous ERDAS Imagine) ?

Répondre à cette question permettra non seulement d'évaluer la pertinence des méthodes testées, mais aussi d'orienter les choix futurs en matière de détection automatisée dans un contexte opérationnel.

III. Objectif du projet :

Ce projet de fin d'étude vise à répondre à une problématique actuelle et stratégique : **la détection automatique des panneaux photovoltaïques** à partir d'images satellitaires ou aériennes. L'enjeu est d'identifier, localiser et quantifier ces installations à des fins de suivi, de planification ou de gestion des ressources énergétiques renouvelables.

Pour y parvenir, deux grandes approches méthodologiques ont été explorées :

Les **modèles de Deep Learning incluant l'intelligence artificielle (IA)**, et les méthodes classiques de classification d'image en télédétection.

Ainsi, les objectifs du projet peuvent être formulés de manière détaillée comme suit :

- **Mettre en œuvre une approche basée sur les modèles de Deep Learning**

L'objectif ici est d'utiliser un modèle d'apprentissage profond performant, le **Mask R-CNN**, reconnu pour sa capacité à détecter et segmenter précisément des objets dans les images. Ce modèle a été préalablement entraîné puis réentraîné (**fine-tuning**) par le chercheur **Qiusheng Wu**, créateur de la bibliothèque **GeoAI**, afin de l'adapter à la détection spécifique des panneaux solaires dans des images géospatiales. Il s'agira :

- D'exploiter les fonctionnalités de la bibliothèque GeoAI pour charger, appliquer et tester ce modèle.
- D'évaluer la qualité des détections obtenues à l'aide de données d'imagerie aérienne à haute résolution.

- **Appliquer une classification supervisée à l'aide de la méthode de la Distance Minimale**

Dans cette étape, l'approche repose sur une classification thématique supervisée réalisée à l'aide du logiciel ERDAS Imagine. Le choix s'est porté sur la méthode de **la Distance Minimale** (*Minimum Distance Classifier*), qui :

- Compare chaque pixel de l'image aux centres (vecteurs moyens) des classes d'apprentissage définies au préalable.
- Affecte chaque pixel à la classe la plus proche dans l'espace spectral.

Cette méthode est simple à mettre en œuvre et efficace si les échantillons d'apprentissage sont bien représentatifs.

- **Appliquer une classification non supervisée à l'aide de l'algorithme ISODATA**

En complément, une classification non supervisée a été réalisée à l'aide de l'algorithme **ISODATA** (*Iterative Self-Organizing Data Analysis Technique Algorithm*). Cette technique :

- Regroupe les pixels en classes homogènes selon leurs caractéristiques spectrales sans connaissance préalable des types d'objets présents.
- Permet d'explorer la structure interne des données et d'identifier des regroupements potentiellement liés aux panneaux solaires.

- Comparer les deux approches

Une analyse comparative sera menée pour évaluer les performances de chaque approche, selon plusieurs critères :

- **Précision de la détection,**
- **Taux de faux positifs et faux négatifs,**
- **Temps de traitement,**
- **Facilité d'implémentation et d'interprétation,**

- Proposer des recommandations pratiques

Enfin, le projet vise à formuler des recommandations sur l'usage optimal de ces techniques selon les besoins :

- Quelle approche privilégier pour un traitement rapide ?
- Laquelle est plus adaptée à un traitement automatisé à grande échelle ?
- Quel niveau d'expertise ou de ressources logicielles est nécessaire pour chaque méthode ?

IV. Méthodologie

1. Approche par un modèle de Deep Learning pré-entraîné (Mask R-CNN avec GeoAI)

La démarche repose sur un pipeline complet utilisant la bibliothèque **GeoAI**, développée par **Qiusheng Wu**, et intégrant un modèle de Deep Learning **Mask R-CNN** spécifiquement réentraîné (**fine-tuned**) pour détecter les panneaux photovoltaïques sur des images satellites ou aériennes. L'approche combine des opérations de détection, de vectorisation et d'analyse géométrique.

Voici le déroulement détaillé de chaque étape du traitement.

a) Inspection des métadonnées raster

Avant toute opération de traitement ou de visualisation, il est important d'inspecter les **informations raster**. Cette commande affiche:

➤ Le code utilisé:

```
[ ] raster_path = "/content/IMAGE_INPUT.tif"
[ ] geoai.print_raster_info(raster_path)
```

➤ Résultat:

===== RASTER INFORMATION: /content/IMAGE_INPUT.tif =====

Driver: GTiff

Dimensions: 4921 x 3051 pixels

Number of bands: 3

Data type: uint8

Coordinate Reference System: EPSG:3857

Georeferenced Bounds: BoundingBox(left=-13555786.276012858, bottom=4657530.2637391295, right=-13555418.921693237, top=4657758.013653963)

Pixel Resolution: 0.07465033928487655, 0.07464762859172223

NoData Value: None

✓ Format et Dimensions

- **Extension:** GEOTIFF
- **Dimensions : 4921 x 3051 pixels**
Image de 4921 pixels de largeur × 3051 pixels de hauteur.

✓ Caractéristiques des données

- **Number of bands : 3**
Correspond aux canaux RGB (Rouge, Vert, Bleu) standard pour une image couleur.
- **Data type : uint8**
Valeurs des pixels entre 0 et 255 (entiers non signés sur 8 bits).

✓ Système de coordonnées (CRS)

- **EPSG :3857**
Système de projection **Web Mercator** utilisé par :
 - Google Maps
 - OpenStreetMap
 - Services cartographiques web

✓ Emplacement géographique (Bornes)

- **Bounding Box**
Zone couverte en coordonnées EPSG :3857 (mètres) :

Direction	Valeur (m)
Left (Ouest)	-13,555,786.276
Bottom (Sud)	4,657,530.264
Right (Est)	-13,555,418.922
Top (Nord)	4,657,758.014

- **Couverture réelle:**
 - Largeur: 367.35 m (Est - Ouest)
 - Hauteur: 227.75 m (Nord - Sud)

✓ **Résolution spatiale**

- **X : 0.0747 m/pixel**
Chaque pixel couvre ≈ 7.47 cm en horizontal
- **Y : 0.0746 m/pixel**
Chaque pixel couvre ≈ 7.46 cm en vertical
- **Vérification:**
Largeur : $4921 \text{ px} \times 0.0747 \text{ m/px} \approx 367 \text{ m} \checkmark$
Hauteur : $3051 \text{ px} \times 0.0746 \text{ m/px} \approx 227 \text{ m} \checkmark$

✓ **Valeur NoData**

NoData Value : None

Tous les pixels contiennent des valeurs valides (pas de zones transparentes/masquées).

b) **Visualisation de l'image d'entrée**

Cette première étape permet de **visualiser l'image raster GeoTIFF** en entrée, généralement une image satellite à haute résolution. Cela permet de vérifier la qualité de l'image, sa couverture, et d'identifier visuellement la présence possible de panneaux solaires. La visualisation est interactive grâce à l'utilisation de folium ou ipyleaflet dans un environnement Jupyter Notebook.

➤ Le code utilisé:

```
geoai.view_raster(raster_path)
```

➤ Résultat:



c) **Initialisation du modèle Mask R-CNN**

Le détecteur est ici instancié à partir d'une classe intégrée dans la bibliothèque **GeoAI**. Celle-ci charge automatiquement le modèle **Mask R-CNN** fine-tuné par **Qiusheng Wu** pour la tâche spécifique de détection de panneaux solaires. Le modèle est préentraîné et prêt à l'emploi, ce qui permet d'éviter les coûts liés à l'entraînement d'un modèle personnalisé.

➤ Le code utilisé:

```
detector = geoai.SolarPanelDetector()
```

d) Génération des masques de détection

➤ Le code utilisé:

```
output_path = "IMAGE_INPUT_masks.tif"
> masks_path = detector.generate_masks(
    raster_path,
    output_path=output_path,
    confidence_threshold=0.4,
    mask_threshold=0.5,
    min_object_area=100,
    overlap=0.25,
    chip_size=(400, 400),
    batch_size=4,
    verbose=False,
)
```

Dans cette étape, le modèle analyse l'image raster en la **découpant en tuiles** de 400 × 400 pixels, avec un recouvrement de 25 % entre les tuiles pour éviter les effets de bord. Le modèle prédit ensuite des **masques de segmentation** pour chaque tuile, c'est-à-dire des zones correspondant à des panneaux solaires.

- Seuls les objets ayant un **score de confiance supérieur à 0.4** sont retenus.
- Les objets ayant une **aire inférieure à 100 pixels** sont filtrés pour éviter les faux positifs.
- Le **seuil de masquage** à 0.5 est utilisé pour convertir les probabilités de détection en masques binaires.

Cette étape génère une **image raster binaire (GeoTIFF)** contenant tous les masques de détection.

- Les **pixels de valeur 1** représentent les zones détectées comme **panneaux photovoltaïques**,
- Les **pixels de valeur 0** correspondent à l'arrière-plan (non détecté).

➤ Résultat:



e) Visualisation des masques générés sur QGIS

Les masques prédits sont superposés à l'image de base pour validation visuelle. Cela permet de vérifier la qualité des détections, la forme des objets et la cohérence spatiale des résultats.




f) Vectorisation des masques

Les masques raster sont ensuite convertis en polygones vectoriels (GeoJSON). L'algorithme applique une simplification géométrique avec un paramètre epsilon=0.2, ce qui permet de nettoyer les contours des objets et de rendre les formes rectangulaires, typiques des panneaux solaires.

➤ Le code utilisé:

```
gdf = geoi.orthogonalize(  
    input_path=masks_path, output_path="IMAGE_INPUT_masks.geojson", epsilon=0.2  
)
```

➤ Résultat (Fichier geojson importer dans Qgis) :



g) Calcul des propriétés géométriques

GeoAI, en utilisant la fonction **geoai.add_geometric_properties(gdf)**, ajoute des attributs géométriques aux entités détectées :

Attribut	Description
geometry	Coordonnées du polygone détecté
area_m2	Aire réelle du polygone en m ²
length_m	Longueur maximale (en m) du polygone (selon la bounding box)
perimeter_m	Périmètre du polygone (en mètres)
area_bbox_m2	Aire de la boîte englobante du polygone
area_convex_m2	Aire de l'enveloppe convexe
area_filled_m2	Aire du polygone avec trous comblés (si applicable)
major_length_m	Longueur de l'axe principal (ellipse ajustée)
minor_length_m	Longueur de l'axe secondaire
eccentricity	Rapport entre les axes principal et secondaire (≈ 1 pour les objets très allongés)
orientation	Angle d'orientation du polygone (en degrés)
elongation	Rapport longueur/largeur (bounding box), reflète l'allongement
extent	Taux d'occupation de la bounding box (surface / bbox)
solidity	Compacité par rapport à l'enveloppe convexe (surface / convexe)
complexity	Rapport entre le périmètre ² et la surface, indicateur de forme irrégulière

Cela permet des analyses statistiques et spatiales plus poussées (par exemple : la taille moyenne des installations, leur orientation préférentielle, etc.).

➤ Résultat:

	geometry	value	area_m2	length_m	perimeter_m	area_bbox_m2	area_convex_m2	area_filled_m2	major_length_m	minor_length_m	eccentricity	orientation	elongation	extent	solidity	complexity
0	POLYGON ((-13555603.955 4657949.439, -13555601...	255	13.848780	17.773420	17.773420	13.848780	13.848780	13.848780	6.871240	2.015470	0.956014	90.0	3.409249	1.000000	1.000000	1.347288
1	POLYGON ((-13555896.001 4657949.363, -13555894...	255	10.052594	17.996987	17.996987	10.052594	10.052594	10.052594	7.691523	1.306970	0.985457	90.0	5.885002	1.000000	1.000000	1.601238
2	POLYGON ((-13555892.828 4657948.816, -13555889...	255	43.794885	27.056748	27.056748	44.195465	43.995175	43.794885	8.012690	5.515684	0.725361	90.0	1.452710	0.990936	0.995447	1.153344
3	POLYGON ((-13555589.94 4657947.647, -13555588...	255	44.195802	32.478562	32.478562	51.516271	48.477006	44.195802	9.257522	5.564802	0.799165	90.0	1.663585	0.857900	0.911686	1.378165
4	POLYGON ((-13555760.559 4657949.141, -13555760...	255	9.995438	14.032941	14.032941	11.432909	10.627814	9.995438	4.030791	2.836394	0.710515	0.0	1.421097	0.874269	0.940498	1.252111

Après, la commande **print(len(gdf))** permet d'afficher le nombre total d'objets vectoriels (polygones) présents dans le GeoDataFrame après l'ajout des propriétés géométriques. Le résultat obtenu est de 81 objets détectés.

Cela signifie que le modèle Mask R-CNN, après post-traitement et vectorisation, a permis d'extraire 81 entités spatiales potentiellement représentatives de panneaux photovoltaïques. Cette valeur constitue un point de départ pour la phase de filtrage et d'analyse thématique.

```
print(len(gdf))
```


81

Finalement, les polygones sont affichés sur la carte avec une coloration selon leur élongation en utilisant la fonction **geoai.view_vector_interactive()**. Cela permet une vérification visuelle rapide de la forme des objets détectés et aide à repérer ceux qui sont trop compacts ou irréguliers.

➤ Le code utilisé:

```
geoai.view_vector_interactive(gdf, column="elongation", tiles=raster_url)
```

➤ Résultat :



h) Filtrage des objets détectés

Un filtrage a été appliqué afin d'éliminer les objets trop petits ou présentant une forme incohérente avec des panneaux solaires. Deux critères ont été retenus: l'aire ($> 5 \text{ m}^2$) et l'élongation (< 10).

➤ Le code utilisé:

```
gdf_filter = gdf[(gdf["elongation"] < 10) & (gdf["area_m2"] > 5)]  
print(len(gdf_filter))
```

Ce filtre conserve uniquement les polygones :

- Ayant une aire supérieure à 5 m^2 ,
- Et une élongation inférieure à 10 (au-delà, la forme devient exagérément allongée et peu réaliste pour un panneau).

Sur les 81 objets initiaux détectés par le modèle, 70 ont été conservés après application de ces critères. Ce sous-ensemble constitue un jeu de données plus fiable, représentatif des vraies installations photovoltaïques observables dans l'image.

i) Visualisation et analyse des résultats finaux

Une fois les objets filtrés, une visualisation interactive finale est générée à l'aide de :

```
geoai.view_vector_interactive(gdf_filter, column="area_m2", tiles=raster_url)
```

Cette carte permet de superposer les objets détectés sur l'image satellite initiale, en les colorant selon leur surface (area_m2). Cela offre une vue d'ensemble claire de la répartition spatiale des panneaux photovoltaïques, et permet d'identifier visuellement les plus grandes installations.



Une seconde visualisation, plus épurée, est ensuite produite avec un style uniforme :

```
geoai.view_vector_interactive(  
    gdf_filter, style_kws={"color": "red", "fillOpacity": 0}, tiles=raster_url  
)
```

Dans cette carte, les contours des objets sont affichés en rouge sur fond d'image satellite. Elle permet de valider précisément chaque détection. En cliquant sur un polygone, toutes les propriétés géométriques calculées sont affichées : surface, longueur, compacité, orientation, etc.




○ Analyse statistique de la surface détectée

Une analyse quantitative est ensuite effectuée sur la colonne `area_m2`. Un histogramme montre la distribution des surfaces des panneaux détectés. Le code:

```
gdf_filter["area_m2"].hist()
```

Génère un histogramme où l'on observe que la majorité des panneaux ont une surface comprise entre 5 m² et 40 m², avec quelques installations plus grandes.



Les statistiques descriptives sont obtenues par :

```
gdf_filter["area_m2"].describe()
```

Ce qui donne les valeurs suivantes :

- Nombre total d'objets : 37
- Surface minimale : 7.12 m²
- Surface maximale : 70.95 m²
- Moyenne : 26.88 m²
- Médiane (50%) : 22.43 m²
- Écart type : 15.48 m²

area_m2	
count	37.000000
mean	26.888097
std	15.489636
min	7.127190
25%	15.229563
50%	22.438566
75%	34.762354
max	70.951653

Enfin, la surface totale détectée est obtenue par :

```
gdf_filter["area_m2"].sum()
```

Avec un résultat de : **994.85 m²**


Cela représente la surface totale estimée occupée par les panneaux photovoltaïques dans la zone d'étude.

j) Export des résultats finaux

Une fois le filtrage appliqué et les résultats validés visuellement, les objets détectés sont exportés sous forme vectorielle pour une exploitation SIG. Cela est réalisé à l'aide de la commande suivante :

```
gdf_filter.to_file("solar_panels.geojson")
```

Cette commande génère un fichier au format GeoJSON contenant les 37 polygones représentant les panneaux photovoltaïques identifiés et validés dans la zone d'étude.



Cette figure ci-dessus montre clairement que les panneaux exportés correspondent bien à des installations visibles sur les toitures, ce qui confirme la qualité de la détection. Les polygones vectoriels sont alignés avec précision sur les structures cibles.

3. Réentraînent (FINE-TUNING) du modèle Mask R-CNN

L'apprentissage du modèle repose sur un pipeline intégralement exécuté dans un environnement Jupyter Notebook via Google Colab, en s'appuyant sur la bibliothèque Python **geoai-py**. Contrairement à une approche classique nécessitant un grand volume de données, l'auteur a utilisé une seule image satellite annotée manuellement pour entraîner un modèle Mask R-CNN à des fins de démonstration.

➤ Données utilisées

Les données d'entrée sont :

- Une image GeoTIFF à haute résolution (solar_panels_davis_ca.tif), couvrant une portion de la ville de Davis en Californie ;
- Un fichier vectoriel GeoJSON (solar_panels_davis_ca.geojson) représentant les contours exacts des panneaux solaires visibles sur l'image, dessinés manuellement.

L'image mesure 6711×3242 pixels, avec une résolution spatiale d'environ 7 cm/pixel.

➤ Génération des tuiles d'apprentissage

Afin de préparer les données pour l'apprentissage supervisé, l'image raster et les annotations vectorielles sont découpées en tuiles à l'aide de la fonction **geoai.export_geotiff_tiles()**. Cette opération produit :

- Une série de patches d'image de 512×512 pixels (avec recouvrement de 50 %),
- Des masques binaires associés (au format PNG), où chaque pixel est étiqueté comme panneau (1) ou fond (0), à partir des polygones du fichier GeoJSON.

➤ Entraînement du modèle Mask R-CNN

Le modèle est entraîné à l'aide de la fonction **geoai.train_MaskRCNN_model()**, avec les paramètres suivants :

- Backbone préentraîné sur COCO (pretrained=True)
- Nombre d'époques: 100
- Taille du batch: 4
- Taux d'apprentissage: 0.005
- Division validation: 20 %

Ce modèle Mask R-CNN est une architecture de deep learning spécialisée dans la détection d'objets avec segmentation précise. Il produit pour chaque objet détecté:

- Une classe (dans notre cas, "panneau solaire"),
- Une boîte englobante (bounding box),
- Un masque de segmentation (forme exacte en pixels).

➤ Objectif de l'apprentissage

Le but de l'apprentissage est d'ajuster les poids internes du modèle pour qu'il puisse reconnaître automatiquement la forme, la taille et la texture typiques d'un panneau solaire dans des images à haute résolution. Même si l'entraînement a été réalisé sur une zone très restreinte, le modèle peut ensuite être testé sur d'autres images, à condition qu'elles soient similaires en résolution et en contexte visuel.

➤ Application du modèle sur une image test

Une fois le modèle entraîné, il est appliqué sur une nouvelle image satellite (`solar_panels_test_davis_ca.tif`) pour évaluer sa capacité à détecter les panneaux solaires sur des données qu'il n'a jamais vues. Cette étape, appelée aussi inférence ou application du modèle, consiste à générer automatiquement des prédictions à partir de ce que le modèle a appris.

L'objectif principal est de vérifier si le modèle généralise bien au-delà des images utilisées pendant l'entraînement. Dans le cas du projet GeoAI, cette validation est qualitative : on observe visuellement si les panneaux solaires sont bien détectés, mais aucune métrique chiffrée (comme la précision ou le rappel) n'est calculée.

L'inférence est réalisée grâce à la fonction **`geoai.object_detection()`**, qui découpe l'image en fenêtres glissantes de 512×512 pixels avec recouvrement. Le modèle analyse chaque fenêtre et produit un masque binaire indiquant les zones où des panneaux solaires sont présents.

➤ Vectorisation des masques

Les résultats bruts produits par le modèle sont des masques binaires : des images où chaque pixel est soit 1 (zone détectée comme panneau solaire), soit 0 (fond). Cependant, ces masques ne sont pas encore utilisables dans un SIG, car ils ne sont pas vectoriels.

La vectorisation permet de transformer ces masques en polygones géographiques (formes fermées avec des coordonnées réelles). Cela se fait avec la fonction **`geoai.orthogonalize()`**, qui détecte les contours des zones masquées et les convertit en un fichier GeoJSON. Ce fichier contient des polygones géoréférencés représentant les panneaux détectés, que l'on peut ouvrir dans QGIS ou afficher sur une carte interactive.

➤ Visualisation et validation

Une fois les résultats vectorisés, il est possible de les visualiser directement sur une carte pour évaluer la qualité des détections. GeoAI propose des outils intégrés pour afficher les résultats côte à côte avec l'image d'origine, grâce à la fonction **`geoai.create_split_map()`**.

Cela permet une vérification visuelle intuitive : on peut comparer les panneaux détectés aux véritables toits visibles sur l'image. Dans ce projet, aucune validation quantitative (comme l'Intersection over Union ou la précision) n'est calculée, car le but est simplement de démontrer le fonctionnement du modèle.

4. Approche par classification sous ERDAS Imagine

a) Classification supervisée : méthode de la Distance Minimale

Cette méthode repose sur le calcul de la **distance euclidienne** entre un pixel à classifier et le centroïde de chaque classe d'apprentissage. Chaque pixel est ensuite affecté à la classe dont le centre est le plus proche, à condition que cette distance soit inférieure à un seuil maximal.

- La formule utilisée pour une image avec deux bandes (x, y) est :

$$ED^2 = (x_p - x_c)^2 + (y_p - y_c)^2$$


où :

- (x_p, y_p) sont les valeurs spectrales du pixel,
- (x_c, y_c) sont les coordonnées moyennes (centre) de la classe c ,
- ED est la distance euclidienne.


■ Mise en œuvre dans ERDAS Imagine

- Préparation des données:

Chargement de l'image satellitaire dans ERDAS Imagine.




Définition des **zones d'entraînement** manuellement pour les classes cibles (panneaux solaires, toiture, sol nu, végétation).



○ **Execution de la classification:**


Choix de l'algorithme "**Minimum Distance**" dans le module de classification supervisée.

Application du modèle aux pixels de l'image.



- **Production des résultats:**

Carte raster classifiée (chaque pixel affecté à une classe).



L'image montre le résultat de la classification supervisée par distance minimale, distinguant grossièrement les zones bâties (rouge) et végétalisées (vert), avec quelques confusions visibles entre les classes.

- **Une analyse qualitative**

En comparant visuellement la **carte classifiée** avec l'**image originale**, plusieurs observations peuvent être faites :

- **Bonne détection des toitures:**

De nombreuses zones en rouge dans l'image classifiée coïncident avec des toits visibles dans l'image originale, ce qui montre une certaine efficacité de la méthode à distinguer les surfaces construites.

- **Faible discrimination des panneaux solaires :**

La méthode de distance minimale **ne permet pas d'isoler les panneaux photovoltaïques** des autres structures de toiture. Ces derniers apparaissent intégrés dans la classe générale des toits, sans distinction particulière.

- **Confusions dans les zones végétalisées :**

Certaines zones de végétation (pelouses, arbres) sont bien identifiées (en vert), mais d'autres zones complexes, notamment les zones en ombre, présentent des erreurs de classification.

- Pas de segmentation fine :

La classification fonctionne par pixel, sans prise en compte de la forme ni du contexte spatial. Cela entraîne une **granularité faible**, des **bords flous** et un **manque de précision** pour des objets aussi fins que des panneaux solaires.

b) Classification non supervisée : méthode de isodata


L'algorithme ISODATA est une méthode de **clustering itératif**, dérivée du K-means, qui permet de regrouper les pixels en classes spectrales homogènes en se basant uniquement sur leurs valeurs numériques. Il introduit cependant plusieurs mécanismes avancés :

- **Fusion automatique** de classes proches.
- **Scission** de classes trop étendues.
- **Élimination** des classes peu peuplées.
- **Nombre de classes ajustable dynamiquement**, contrairement au K-means classique.

Chaque itération permet de réorganiser les clusters pour **améliorer la séparation spectrale**.


■ Mise en œuvre dans ERDAS Imagine

- **Chargement de l'image multispectrale dans ERDAS.**




- **Paramétrage de l'algorithme :**

- Nombre initial de classes: 5
- Nombre maximum d'itérations : 10



- **Exécution de la classification ISODATA :**

Chaque pixel est assigné à une classe en fonction de la proximité avec les centres de clusters.



L'image illustre les résultats de la classification non supervisée par l'algorithme ISODATA, révélant une segmentation automatique des zones selon leurs similarités spectrales, mais avec des mélanges visibles entre classes.

○ **Analyse visuelle des classes :**

- **Toitures avec panneaux solaires :** Certaines classes présentent une texture homogène et des couleurs associées à des surfaces construites, notamment les toitures. On observe que ces classes couvrent la majorité des zones urbaines denses de l'image. La comparaison avec l'image originale confirme leur correspondance avec des toitures de maisons et des zones construites.
- **Végétation :** D'autres classes se distinguent par une répartition spatiale correspondant à la végétation urbaine, comme les jardins et les arbres en bordure des routes ou dans les parcs. Ces zones se manifestent par une teinte verte sur la carte classifiée, et se superposent bien avec les zones arborées visibles sur l'image originale.
- **Sols nus / routes :** Une classe regroupe des surfaces avec une texture plus homogène, souvent localisée sur les routes. Ces zones apparaissent comme des surfaces claires ou grises sur l'image originale.

V. Discussion :

1. Précision :

La précision mesure à quel point la méthode détecte correctement les panneaux solaires par rapport à l'ensemble des pixels ou objets analysés.

- **Mask R-CNN :** Très **haute précision** grâce à la segmentation **instance** et la détection des objets, y compris les petits panneaux solaires.
- **Méthode supervisée :** **Précision moyenne.** Dépend fortement de la qualité des **zones d'entraînement** et des caractéristiques des panneaux solaires dans l'image.
- **Méthode non supervisée (ISODATA) :** **Précision faible**, car elle se base sur des critères spectraux larges et ne tient pas compte des formes des objets (panels solaires souvent mal classés)

2. Taux d'erreur :

Le taux d'erreur représente le pourcentage de pixels mal classifiés ou d'objets mal détectés.

- **Mask R-CNN :** **Faible taux d'erreur** grâce à sa capacité à apprendre des représentations spatiales complexes.
- **Méthode supervisée :** Taux d'erreur **modéré**, dépend des zones d'entraînement et de la diversité des données.
- **Méthode non supervisée :** **Taux d'erreur élevé**, car l'algorithme ne prend pas en compte les informations complexes comme la forme ou le contexte des panneaux solaires.

3. Rapidité :

La rapidité mesure le temps nécessaire pour exécuter l'algorithme et obtenir les résultats.

- **Mask R-CNN : Relativement lent** en raison de l'entraînement du modèle et des calculs nécessaires pour appliquer un réseau de neurones convolutifs.
- **Méthode supervisée : Rapide** par rapport à Mask R-CNN, mais nécessite un entraînement préalable des zones d'entraînement.
- **Méthode non supervisée : Très rapide**, car l'algorithme ISODATA est un processus non itératif plus simple.

4. Accessibilité :

Cela fait référence à la facilité d'utilisation et à l'accès aux outils nécessaires pour appliquer la méthode.

- **Mask R-CNN : Peu accessible** pour les non-initiés. Nécessite un environnement de deep Learning, des compétences en codage (Python), et un accès à un GPU.
- **Méthode supervisée : Facilement accessible**, surtout avec des logiciels comme **ENVI** ou **ArcGIS**, mais nécessite des zones d'entraînement bien définies.
- **Méthode non supervisée : Très accessible** avec des outils SIG comme **QGIS** ou **ERDAS**, sans besoin d'une grande expertise.

5. Avantages et inconvénient :

Méthode	Avantages	Inconvénients
Mask R-CNN (Deep Learning)	- Très précise et robuste pour la détection des panneaux solaires. - Détection fine des objets même petits. - Adapté à des environnements complexes.	- Long à entraîner. - Nécessite beaucoup de ressources (GPU). - Peu accessible aux non-initiés.
Méthode supervisée (Distance minimale)	- Relativement rapide. - Facilement accessible avec des outils comme ENVI.	- Moins précise, surtout pour des images complexes. - Dépend des zones d'entraînement. - Sensible aux variations des objets.
Méthode non supervisée (ISODATA)	- Très rapide. - Facile à utiliser avec des outils SIG simples.	- Précision très faible. - Ne gère pas bien la détection d'objets complexes. - Ne prend pas en compte les formes.

VI. Limites des méthodes utilisées :

1. Modèle de Deep Learning:

- Besoins matériels élevés : nécessite un GPU puissant, ce qui limite son accessibilité.
- Temps de traitement long : l'inférence et la vectorisation prennent plus de temps que les méthodes classiques.
- Dépendance à la qualité des données : une mauvaise qualité d'image ou une résolution insuffisante peut fortement nuire à la performance.
- Pas de métrique quantitative automatique appliquée dans votre projet seulement une validation visuelle.
- Entraînement limité à une seule zone : la généralisation peut être faible sur d'autres régions ou images de contextes différents.

2. Classification supervisée (Distance Minimale) :

- Dépendance aux échantillons d'entraînement : mauvaise généralisation si les classes sont mal représentées.
- Confusions fréquentes : les panneaux sont souvent classés dans la même catégorie que les toitures.
- Absence de segmentation contextuelle : ne tient pas compte de la forme ni de la texture des objets, seulement des spectres.
- Sensibilité à l'homogénéité spectrale : faible performance si les classes sont proches spectralement (p. ex. toit foncé vs panneau solaire).

3. Classification non supervisée (ISODATA) :

- Aucune connaissance a priori : impossible de cibler spécifiquement les panneaux sans intervention humaine post-traitement.
- Résultats peu interprétables directement : nécessite une reclassification manuelle.
- Confusion spectrale forte : les panneaux ne se distinguent pas bien des autres objets.
- Utilité limitée pour une détection précise : utile pour une première exploration, mais pas pour une classification finale fiable.

VII. Conclusion :

Ce projet a permis de mettre en œuvre, comparer et évaluer différentes approches de détection automatique des panneaux photovoltaïques à partir d'images satellites à haute résolution. Trois méthodes ont été explorées : et une méthode de Deep Learning basée sur le modèle Mask R-CNN intégré via la bibliothèque GeoAI, la classification supervisée (par distance minimale), la classification non supervisée (ISODATA).

Sur le plan des résultats, les méthodes classiques ont fourni une première base d'identification des zones d'intérêt. L'approche ISODATA a montré une capacité à regrouper les pixels de manière spectrale sans annotation préalable, mais avec une précision limitée. La classification supervisée par distance minimale, quant à elle, a mieux ciblé les classes définies, au prix d'un effort d'échantillonnage initial.

Toutefois, c'est l'approche par Deep Learning qui s'est révélée la plus performante : le modèle Mask R-CNN, même entraîné sur un jeu de données réduit, a détecté 81 objets dont 70 ont été validés comme panneaux après filtrage géométrique, représentant une surface totale estimée à environ 994,85 m². L'analyse géométrique et la visualisation interactive dans QGIS ont permis une validation fine des résultats.

Malgré ces avancées, plusieurs limites ont été rencontrées :

- L'absence de validation quantitative (précision, rappel, IoU) limite l'évaluation objective des performances du modèle.
- Le modèle a été entraîné sur une seule image, ce qui réduit sa capacité de généralisation à d'autres zones géographiques.
- Les images utilisées ne contiennent que des canaux RGB, ce qui restreint l'analyse spectrale.
- L'approche reste strictement 2D, sans prise en compte de la hauteur ni de la topographie.

Pour améliorer la précision, la robustesse et la portée de cette solution, plusieurs recommandations peuvent être proposées pour les travaux futurs :

- Enrichir le jeu de données d'apprentissage avec des images annotées provenant de zones variées.
- Ajouter des bandes multispectrales ou infrarouges, permettant de mieux discriminer les matériaux en toiture.
- Intégrer des données 3D (comme le LiDAR ou les modèles numériques de surface) pour détecter l'élévation et l'orientation des panneaux.

- Tester des réseaux de Deep Learning plus récents et plus puissants, comme YOLOv8, Detectron2 ou Segment Anything Model (SAM), qui offrent des performances supérieures en vitesse et en précision.
- Développer une chaîne de validation quantitative, incluant des métriques de performance standard pour évaluer le modèle sur des jeux de test indépendants.

En conclusion, ce projet a démontré le potentiel concret du Deep Learning pour la cartographie des infrastructures solaires. Il constitue une base prometteuse pour la création d'un outil opérationnel de suivi des installations photovoltaïques à l'échelle régionale ou nationale, dans une optique de transition énergétique et de gestion territoriale intelligente. Cette approche permet une analyse précise des caractéristiques visuelles sans besoin de prétraitement intensif, ouvrant de nouvelles possibilités en reconnaissance d'objets, surveillance vidéo et médecine diagnostique.

VIII. Bibliographie :

- He et al., 2017 – Mask R-CNN.
- La bibliothèque GeoAi: [GitHub - opengeos/geoai: GeoAI: Artificial Intelligence for Geospatial Data](https://github.com/opengeos/geoai)
- Esri, 2022 – GEO AI Deep Learning Framework.
- Goodfellow et al., 2016 – Deep Learning.

Autres articles scientifiques utilisés