



Institut Agronomique et Vétérinaire Hassan II

Filière de Formation en
Sciences Géomatiques et Ingénierie Topographique



Application thématique de la télédétection

Seasonal LULC Classification in Arid region using GEE and AI(ML & DL).

Réalisé par (Groupe 1) :

BOULGHMAN Ismail N°12

BOUTOUBA Safaa N°15

OUNDOUH Oussama N°50

BENJEDDOU Haitam N°10

SEBITI Nouhaila N°54

Encadré par :

Mr.Hani Hassan

Juin, 2025

RESEARCH ARTICLE

Seasonal LULC Classification in Arid region using GEE and AI(ML DL)

Smail Bouilaghmane¹, Boutouba Safaa¹, Haitam Benjeddou¹, Oundouh Ossama¹ and Sebiti Nouhaila¹

¹Département de cartographie et photogrammétrie, IAV Hassan II, Rabat, Maroc.

Keywords: LULC, GEE, sentinel2, Machine Learning ,
Deep Learning,Indices spectraux,Analyse des séries temporelles,classification, carte de prédiction

MSC Codes: *Primary* – 68T01; *Secondary* – 62H30, 86A32

Abstract

Les régions arides comme celle d'Errachidia sont particulièrement vulnérables aux dynamiques saisonnières de l'occupation et de l'utilisation des terres (LULC), en raison de la fragilité de leurs écosystèmes et de la rareté des ressources hydriques. Ce travail vise à cartographier et analyser les changements saisonniers du LULC dans cette zone, en s'appuyant sur la plateforme Google Earth Engine (GEE) et des algorithmes d'intelligence artificielle (IA), en combinant des méthodes d'apprentissage automatique (CART, Random Forest, SVM) et d'apprentissage profond (DL).

Des images satellitaires Landsat 8 ont été exploitées pour classifier les différentes classes d'occupation du sol, avec un accent particulier sur les saisons printanière et estivale. L'intégration d'indices spectraux tels que NDVI, SAVI, NDWI, NDBI et NDMI a permis d'enrichir la précision de la classification.

Les modèles CART, RF, SVM et DL ont permis de générer des cartes LULC détaillées pour les années 2020 et 2024, avec une évaluation des performances basée sur la précision globale et les indices de Kappa. Les résultats mettent en évidence une régression significative des terres agricoles et une extension progressive des zones stériles et construites, en corrélation avec une pression anthropique accrue.

Par ailleurs, les prairies saisonnières (zones de végétation temporaire) présentent une dynamique marquée, avec des invasions secondaires sur les terrains abandonnés. Les ressources en eau, bien que rares, ont montré une stabilité relative, mais demeurent fortement influencées par les changements d'usage du sol.

Enfin, une carte de prédiction pour l'année 2028 a été produite, suggérant la poursuite des tendances observées, notamment une réduction marquée des surfaces végétalisées. Ce travail offre ainsi une base actualisée sur l'évolution spatio-temporelle du LULC dans les zones arides et propose des perspectives utiles pour orienter les politiques locales de gestion durable des terres et des ressources en eau.

Contents

1	Introduction	3
2	Etat de l'ART	3
3	Méthodologie et Matériels:	6
3.1	La zone d'étude	6
3.2	La méthodologie:	7
3.2.1	Collecte des données et pré-traitement:	9
3.2.2	Classification par Machine Learning:	11
3.2.3	Classification par Deep Learning:	14
4	Résultats	16
4.1	Résultats de la classification supervisée et évaluation de la précision	16
4.1.1	CART	16
4.1.2	Random Forest	20
4.1.3	SVM	24
4.2	Résultats de classification par DL	28
5	Discussion sur les résultats	29
5.1	Résultats de la classification supervisée et évaluation de la précision	29
5.1.1	CART	30
5.1.2	Random Forest	31
5.1.3	SVM	32
5.2	Comparaison entre les 3 algorithmes:	33
5.3	Interprétation des résultats du SVM et comparaison intersaisonnière.	34
5.4	Cartes de transition:	36
5.5	Résultats de classification par DL	38
5.6	La carte de prédiction de 2028	39
6	Limitation et contraintes:	40
7	Conclusion	40

1. Introduction

À l'échelle mondiale, le changement climatique (CC) et les événements extrêmes, tels que les sécheresses, menacent de plus en plus l'équilibre des écosystèmes terrestres, en particulier dans les zones arides et semi-arides. Ces régions, caractérisées par des ressources en eau limitées et des conditions environnementales fragiles, sont particulièrement vulnérables à la dégradation des terres, à la perte de végétation et à la raréfaction des ressources en eau. Au Maroc, et plus particulièrement dans la province d'Errachidia, située dans la région pré-saharienne, les impacts de ces stress climatiques sont de plus en plus marqués. Les sécheresses récurrentes, associées à une pression anthropique croissante, modifient le paysage naturel, réduisent la productivité agricole et mettent à mal des ressources en eau déjà rares.

Les recherches récentes ont souligné la nécessité de surveiller les dynamiques de l'occupation et de l'utilisation des terres (LULC) et leurs interactions avec les systèmes hydrologiques et végétaux dans ces environnements vulnérables. Les indices de végétation, tels que l'indice de végétation par différence normalisée (NDVI), l'indice de végétation ajusté par le sol (SAVI), et l'indice de différence normalisée de l'humidité (NDMI), ainsi que des indices relatifs à l'eau comme l'indice de différence normalisée de l'eau (NDWI) et l'indice de différence normalisée des zones bâties (NDBI), sont des outils puissants pour détecter les changements dans la santé de la végétation, l'humidité du sol, les masses d'eau et l'expansion urbaine au fil du temps. Ces indices, dérivés des données de télédétection satellitaire, sont essentiels pour suivre les changements écologiques et orienter les stratégies de gestion durable des terres et des ressources en eau.

Dans ce contexte, les technologies de télédétection et les plateformes d'analyse telles que Google Earth Engine (GEE) permettent d'exploiter des séries temporelles d'images satellitaires avec une grande efficacité pour le suivi du LULC. Les images Sentinel 2 offrent une archive précieuse pour l'analyse multi-temporelle, notamment pour des périodes ciblées comme le printemps et l'été. L'intégration d'algorithmes d'intelligence artificielle, notamment les méthodes d'apprentissage automatique telles que **CART**, **Random Forest (RF)**, **Support Vector Machine (SVM)**, ainsi que **l'apprentissage profond (DL)**, permet de classer et prédire les tendances d'occupation du sol avec une grande précision.

Cette étude s'appuie sur les images satellites Landsat 2 pour analyser les changements saisonniers du LULC en 2020 et 2024, en mettant en œuvre des algorithmes d'intelligence artificielle tels que CART, Random Forest, SVM et Deep Learning. L'objectif est double : (1) évaluer avec précision les évolutions spatio-temporelles des classes LULC dans la zone d'étude, et (2) prédire l'occupation du sol à l'horizon 2028, afin d'anticiper les tendances futures et de soutenir la planification territoriale et environnementale.

Cette approche combinée, à la fois descriptive et prédictive, vise à fournir une base scientifique solide pour la prise de décision en matière de gestion durable des terres dans les zones arides marocaines et plus précisément celle de Errachidia.

2. Etat de l'ART

La classification de l'occupation du sol (LULC) est un processus essentiel pour comprendre et gérer l'évolution des paysages, en particulier dans les zones arides où les ressources naturelles sont limitées et vulnérables aux changements environnementaux. Dans des régions comme **Errachidia**, située dans le Sud-Est du Maroc, la gestion durable des terres nécessite une surveillance continue pour suivre les dynamiques de la végétation, de l'urbanisation et de l'agriculture. Les techniques de télédétection ont permis de cartographier ces changements à grande échelle, mais la complexité des environnements

arides et les variations saisonnières rendent cette tâche difficile.

Les régions arides, caractérisées par des précipitations faibles et irrégulières, sont particulièrement sensibles aux changements de couvert végétal et aux impacts du changement climatique. La cartographie précise de l'occupation du sol est donc cruciale pour l'évaluation des risques, tels que la désertification et la gestion des ressources en eau.

a) **Travaux précédents sur la classification LULC dans les zones arides**

Les travaux précédents sur la classification de l'occupation du sol (LULC) ont montré des approches variées pour les zones arides, principalement axées sur l'utilisation des indices spectraux. Ces indices, tels que :

- **NDVI (Normalized Difference Vegetation Index)** : Utilisé pour mesurer la couverture végétale et la biomasse, facilitant l'observation des effets de la sécheresse et de la désertification.
- **NDWI (Normalized Difference Water Index)** : Sert à évaluer l'humidité du sol et la disponibilité en eau.
- **EVI (Enhanced Vegetation Index)** : Fournit des informations sur la qualité de la végétation.

Les données associées aux images extraites en utilisant ces indices ont été exportées vers des outils SIG (Systèmes d'Information Géographique) pour extraire les valeurs des changements des classes LULC au fil du temps.

Cette recherche s'appuie sur des données satellitaires (MCD12Q1 et indices spectraux) couvrant la période d'étude, traitées via **Google Earth Engine** pour analyser les évolutions spatiotemporelles de l'occupation du sol à Errachidia. Des modèles d'intelligence artificielle (**ML et DL**) ont ensuite été utilisés pour améliorer la classification des données et prédire les changements d'usage du sol.

Dans d'autres recherches, l'effet de la saisonnalité sur la précision des cartes LULC a également été exploré à travers des méthodes intégrant la variation temporelle. Ces études ont mis l'accent sur la comparaison et l'amélioration de la précision des cartes classifiées. Pour réduire l'effet de la saisonnalité et améliorer la précision des cartes, une approche de mélange **spectral-temporel d'images satellites sans nuages** a été utilisée. De plus, une attention particulière a été accordée à la sélection de la meilleure saison pour délimiter les LULC d'une condition environnementale particulière ou pour extraire des caractéristiques spécifiques. En ce qui concerne les applications de LULC, plusieurs études ont souligné son importance dans des domaines tels que l'analyse des changements LULC, l'analyse des températures de surface, l'évaluation des risques, l'analyse des impacts du changement climatique et la surveillance environnementale à grande échelle. Dans ces recherches, l'accuracy des cartes LULC dépendait souvent de la qualité des images satellites utilisées, en particulier des images sans nuages, pour garantir une précision accrue des cartes.

Cette étude a utilisé des images Landsat 8 OLI acquises pour trois saisons (post-mousson, hiver et été), en tenant compte de la disponibilité d'images sans nuages. La classification de l'occupation du sol (LULC) a été effectuée en deux étapes : d'abord, chaque saison a été classée séparément à l'aide de la méthode de classification par **maximum de vraisemblance** (Maximum Likelihood), avec des échantillons d'apprentissage spécifiques ; ensuite, les trois cartes saisonnières ont été superposées et reclassées selon les combinaisons de codes LULC à l'aide d'**ArcMap 10.5**.

L'évaluation de la précision a été réalisée avec des **métriques standards** (exactitudes utilisateur et producteur, précision globale et coefficient Kappa), montrant des variations selon les saisons. Cette approche permet également de suivre les changements saisonniers et les rotations des types d'occupation du sol.

b) Méthodes classiques vs Intelligence Artificielle (IA)

Les méthodes classiques de classification LULC ont longtemps été dominées par des techniques telles que la classification supervisée et non supervisée, utilisant principalement des algorithmes comme le Maximum Likelihood Classification (MLC) ou le **k-means clustering**. Cependant, ces méthodes ne permettent pas toujours de distinguer avec précision des classes similaires, particulièrement dans des environnements hétérogènes comme ceux des zones arides.

L'introduction de l'**apprentissage automatique (ML)**, et plus récemment de l'**apprentissage profond (DL)**, a permis d'améliorer la précision des classifications, notamment grâce à des modèles comme les Forêts Aléatoires (**Random Forest**) et les Réseaux de Neurones Convolutifs (**CNN**). Ces approches ont prouvé leur efficacité dans la classification LULC, en particulier pour traiter des images multi-spectrales complexes et des séries temporelles. **Par exemple**, plusieurs études ont démontré que les modèles basés sur l'apprentissage automatique, comme le Random Forest, surpassent les méthodes classiques en termes de précision, notamment dans la classification des zones de végétation et de terres cultivées dans des environnements semi-arides.

c) Avantages de Google Earth Engine (GEE) et des indices spectraux

L'utilisation de Google Earth Engine (GEE) a révolutionné l'analyse des données de télédétection en offrant une plateforme cloud permettant de traiter efficacement des séries temporelles massives d'images satellites, telles que celles de Sentinel-2. GEE permet d'appliquer facilement des algorithmes de traitement et de classification sur des ensembles de données à grande échelle, ce qui est essentiel pour les régions arides, où les conditions de terrain peuvent varier considérablement au fil du temps.

Les indices spectraux, tels que le NDVI, le SAVI et le NDBI, jouent un rôle central dans l'analyse des surfaces de végétation, des sols et des zones bâties. Le NDVI est particulièrement utile pour détecter la végétation et surveiller les changements de couverture végétale saisonnière. Le SAVI, ajusté pour les zones à faible végétation, est particulièrement adapté aux environnements semi-arides comme celui d'Errachidia. De plus, le NDBI permet de surveiller l'extension des zones urbaines et l'impact de l'urbanisation sur les écosystèmes. En plus du NDMI et NDWI.

L'intégration de GEE et des indices spectraux avec des techniques avancées d'IA permet une classification plus précise et une meilleure détection des changements saisonniers dans les régions arides, un domaine encore sous-exploité dans la littérature.

d) Lacunes et pistes à approfondir

Malgré l'utilisation croissante d'indices spectraux (NDVI, SAVI, NDBI, etc.) et de plateformes comme Google Earth Engine, la **classification de l'occupation du sol (LULC)** en régions arides demeure confrontée à plusieurs **limitations méthodologiques**. La majorité des études emploient des **approches statiques**, basées sur une seule saison et une seule méthode de classification, souvent la méthode de Maximum de Vraisemblance, sans considérer les dynamiques saisonnières. Cela engendre des erreurs de reclassification, notamment dans les zones complexes comme les milieux sableux côtiers ou urbains denses, où un même pixel peut être classé comme bâti en été,

plan d'eau après la mousson, et sol nu en hiver.

En outre, **la faible résolution spatiale** de certaines données (comme celles issues de GRACE-FO) limite la détection des petits changements de couverture du sol, alors que les images Landsat ou MODIS utilisées couvrent parfois des périodes incomplètes ou présentent des lacunes liées à la couverture nuageuse. L'absence de relevés de terrain, due à leur coût et leur durée, ainsi que le manque de bases de données actualisées sur la végétation et les ressources en eau, compliquent davantage l'évaluation sur le terrain.

Ainsi, peu d'études intègrent réellement une **analyse spatiotemporelle complète** en zones arides comme Errachidia. L'exploitation de **séries temporelles multisaisonnières**, l'utilisation de données à plus haute résolution et l'intégration progressive de modèles d'apprentissage profond plus robustes apparaissent comme des perspectives prometteuses pour améliorer la précision et la fiabilité des classifications LULC dans ces environnements sensibles.

3. Méthodologie et Matériels:

3.1. La zone d'étude

La province d'Errachidia, surnommée « la province aux 330 jours de soleil », compte sept communes urbaines et vingt-deux communes rurales, avec une population de **418,451** habitants selon le dernier recensement officiel de 2014. Elle s'étend sur une superficie de 27,037 km² (HCP, 2019). **La province d'Errachidia a été choisie comme zone d'étude** en raison de ses conditions climatiques extrêmes, avec de fortes variations de température entre l'été et l'hiver, ce qui influence directement l'occupation du sol (LULC). Cette zone présente une grande diversité de types d'occupation du sol, allant des oasis agricoles aux zones désertiques, permettant ainsi une analyse détaillée des changements saisonniers dans l'utilisation des terres. L'étude de cette variabilité permettra d'observer l'impact des fluctuations climatiques sur les différents types de couvertures terrestres, notamment la végétation et les sols nus.

L'économie de la province repose principalement sur l'agriculture, rendant son développement fortement dépendant des ressources en eau et des conditions climatiques. La province d'Errachidia, située dans la zone pré-saharienne du Maroc, présente une grande diversité géographique et écologique qui influence sa population et son économie. Elle est composée de quatre principales unités morphologiques. **La chaîne du Haut Atlas**, au nord, est un relief massif formé de crêtes et de couloirs calcaires. **Le domaine des Hamadas**, est constitué de plateaux de couches sédimentaires. **La plaine de Tafilalet**, une dépression entre le Haut Atlas et les Hamadas. Enfin, une partie des communes rurales de l'**Anti Atlas Oriental**, composée de roches primaires, est incluse dans cette diversité géographique. Cette variabilité topographique joue un rôle clé dans la répartition des ressources naturelles, des infrastructures et des activités économiques.

Le climat semi-désertique de la province d'Errachidia se caractérise par un écart thermique important entre l'été et l'hiver, avec des températures atteignant 31,5°C en juillet et 5°C en janvier. Les précipitations sont faibles et irrégulières, la majorité du territoire recevant moins de 100 mm de pluie par an. Les vents forts sont fréquents, avec des vitesses supérieures à 57,6 km/h pendant les mois d'été (mai à août), ce qui accentue les conditions arides de la région.

Les sols de la province sont principalement peu évolués en raison de l'aridité du climat, avec une faible densité végétale. Toutefois, des sols évolués sont présents dans les palmeraies, où les microclimats




Figure 1. Présentation de la zone d'étude..

plus humides favorisent la formation de sols propices à l'agriculture. Ces sols sont cependant vulnérables à l'érosion, à la salinisation et au ruissellement, ce qui pose des défis pour l'agriculture durable.

Les ressources en eau de la province d'Errachidia proviennent principalement des eaux superficielles, issues des oueds Ziz, Gheris et Guir, qui prennent leur origine dans le Haut Atlas et l'Anti Atlas.

3.2. La méthodologie:

Dans la présente étude, nous avons tenté d'identifier les potentiels et les zones de faiblesse de l'environnement de la province, tout en mettant l'accent sur le rôle des facteurs anthropiques dans l'accélération de la vulnérabilité. Elle met en lumière les changements spatio-temporels survenus au cours des dernières années en matière d'occupation des sols et de ressources en eau.

La superficie de notre zone d'étude est de 199 786,653 hectares. Pour l'analyse, nous avons principalement utilisé des images satellitaires représentant les quatre saisons des années 2020 et 2024. Ce choix s'explique par la faible variabilité observée entre les années proches, ce qui rend les changements difficilement perceptibles à court terme.

Dans cette étude, premièrement nous avons utilisé la plateforme Google Earth Engine (GEE) pour effectuer une **classification supervisée** de l'occupation et de l'utilisation des sols (LULC) au sein de

notre zone d'étude. Des images satellites **Sentinel-2** ont été sélectionnées pour les quatre saisons des années **2020** et **2024**, en privilégiant celles présentant moins de 20 % de couverture nuageuse. Afin de saisir les dynamiques saisonnières et les changements subtils, des images composites ont été générées à partir des valeurs médianes de réflectance. Plusieurs **indices spectraux** ont ensuite été calculés pour améliorer la différenciation des types de couvert :

- **NDVI;** Le NDVI est largement utilisé pour évaluer la densité et la santé de la végétation. Il permet de distinguer les zones végétalisées des zones stériles ou urbanisées. Il est particulièrement utile pour le suivi de l'évolution de la couverture végétale, notamment dans les zones agricoles ou en période de sécheresse. **Dans la région d'Errachidia**, un territoire semi-aride où la végétation est souvent soumise à des conditions climatiques extrêmes, le NDVI permet de suivre l'état de la végétation, d'identifier les zones de végétation temporaire (comme les prairies saisonnières) et de détecter les changements dans la couverture végétale dus à la sécheresse ou aux changements d'occupation des sols.

$$\text{NDVI} = \frac{(\text{NIR} - \text{RED})}{(\text{NIR} + \text{RED})}$$

- **SAVI;** Le SAVI est une variante du NDVI qui **corrige l'effet du sol**, particulièrement utile dans les zones arides où la couverture végétale est souvent faible et le sol très visible. Il est utilisé pour estimer la végétation dans les zones où la couverture végétale est limitée. Étant donné la nature aride de la région d'Errachidia, où de vastes zones de sol nu sont présentes, l'utilisation du SAVI est pertinente pour réduire l'impact des sols nus sur les résultats de la télédétection. Il permet de mieux quantifier la végétation dans un environnement où le NDVI pourrait donner des résultats biaisés à cause de l'exposition du sol.

$$\text{SAVI} = \frac{(\text{NIR} - \text{RED})}{(\text{NIR} + \text{RED} + L)} \times (1 + L)$$

- **NDMI;** Le NDMI est utilisé pour mesurer l'humidité de la végétation et du sol. Cet indice est particulièrement utile pour suivre les conditions de sécheresse et le stress hydrique des végétaux. La région d'Errachidia est caractérisée par un climat très sec et par des périodes de sécheresse prolongées. Le NDMI est donc particulièrement adapté pour suivre l'évolution de l'humidité dans la végétation et le sol, permettant ainsi de détecter les zones affectées par des stress hydriques, ce qui est crucial pour une gestion durable des ressources en eau.

$$\text{NDMI} = \frac{(\text{NIR} - \text{SWIR})}{(\text{NIR} + \text{SWIR})}$$

- **NDWI;**

Le NDWI est utilisé pour délimiter les zones en eau libre, telles que les rivières, les lacs, ou les zones inondées. Il permet de surveiller les ressources en eau de surface et d'évaluer les impacts de la sécheresse ou des crues. La province d'Errachidia dépend fortement de ses ressources en eau souterraine et en surface, notamment grâce au réseau hydrographique du bassin de Ziz. Le NDWI permet d'identifier les zones humides, les cours d'eau, et d'observer l'évolution des ressources en eau de surface, essentielles dans cette région en raison de leur vulnérabilité à la sécheresse.

$$\text{NDWI} = \frac{(\text{GREEN} - \text{NIR})}{(\text{GREEN} + \text{NIR})}$$

- **NDBI:** Le NDBI permet de détecter les zones urbaines et construites. Cet indice est particulièrement utile pour l'analyse de l'expansion urbaine et l'impact des infrastructures humaines sur l'environnement. La région d'Errachidia connaît une urbanisation croissante, ce qui entraîne une transformation de l'usage des sols et une pression accrue sur les ressources naturelles. Le NDBI permet de suivre l'expansion urbaine et d'analyser son impact sur l'environnement, notamment en termes de consommation d'espace, de perte de terres agricoles, et d'augmentation des zones construites. La formule est :
$$\text{NDBI} = \frac{(\text{SWIR} - \text{NIR})}{(\text{SWIR} + \text{NIR})}$$

Dans ce contexte, cette étude vise à analyser les dynamiques saisonnières de l'occupation des terres dans la région d'Errachidia au cours des quatre saisons de l'année, en s'appuyant sur la plateforme Google Earth Engine (**GEE**) et une combinaison de méthodes d'apprentissage automatique (**CART**, **Random Forest**, **SVM**) et d'apprentissage profond (**DL**).

L'objectif est de cartographier les changements d'occupation du sol et d'en évaluer les tendances, en mettant en parallèle les résultats obtenus par chaque algorithme. Pour ce faire, une comparaison approfondie a été menée à l'aide de **métriques d'évaluation** telles que la précision globale, l'indice de Kappa et la matrice de confusion, afin d'identifier la méthode offrant les meilleures performances.

Aucun jeu de données externe n'a été utilisé dans cette étude : tous les paramètres analysés proviennent des résultats de classification et des indices spectraux calculés (NDVI, SAVI, NDWI, NDBI, NDMI). En complément de l'analyse qualitative, la **surface occupée** par chaque classe dans les géométries sélectionnées a été calculée pour détecter les évolutions dans le temps. Enfin, **une carte de prédiction** a été générée pour l'année 2028 à partir des résultats du modèle Random Forest, afin d'anticiper les tendances futures.

Ce travail fournit ainsi une vision détaillée et cohérente de l'évolution spatio-temporelle de l'occupation des sols dans cette région aride, et propose des éléments d'aide à la décision pour une gestion durable des ressources naturelles.

3.2.1. Collecte des données et pré-traitement:

Les données utilisées dans cette étude ont été extraites à partir de l'imagerie satellite **Sentinel-2**, disponible via la plateforme **Google Earth Engine** (GEE). La première étape consistait à délimiter une zone d'étude située dans la région d'Errachidia, à l'aide d'un rectangle géométrique défini par les coordonnées [31.7815, -4.6925] et [32.0725, -4.2220]. Cette zone a été centrée et visualisée sur la carte avec une transparence partielle.

Le traitement des images Sentinel-2 a impliqué plusieurs étapes cruciales. D'abord, **un masquage des nuages** a été appliqué à l'aide de la fonction **maskS2clouds()**, qui exclut les pixels affectés par les nuages et les cirrus, en se basant sur les informations des bandes QA60. Ce processus permet de conserver uniquement les pixels de terrain non obstrués.

```

1 // 1. Définir la zone d'étude (Errachidia)
2 var zone = ee.Geometry.Rectangle([-4.6925, 31.7815, -4.222, 32.0725]);
3 Map.centerObject(zone, 9);
4 Map.addLayer(zone, {color: 'FF0000', fillOpacity: 0.1, 'Zone carrée', true, 0.5});
5
6 // Fonction pour masquer les nuages (important)
7 function maskS2clouds(image) {
8   var qa = image.select('QA60');
9   var cloudBitMask = 1 << 10;
10  var cirrusBitMask = 1 << 11;
11  var mask = qa.bitwiseAnd(cloudBitMask).eq(0)
12    .and(qa.bitwiseAnd(cirrusBitMask).eq(0));
13  return image.updateMask(mask)
14    .divide(10000) // Normalise les réflectances à une échelle [0,1] (environ)
15    .select("0,*")
16    .copyProperties(image, ["system:time_start"]);
17 }

```

Figure 2. Le code pour la délimitation et masquage des nuages.

Ensuite, pour chaque saison d'intérêt, **une image composite** a été générée en utilisant la méthode de la médiane pour réduire l'impact des valeurs aberrantes et obtenir une image représentative de la saison. Dans le cadre de cette étude, une image composite pour la saison hivernale 2020 a été calculée en filtrant les images Sentinel-2 selon les dates et en excluant celles avec un pourcentage de pixels nuageux supérieur à 20%.

```

19 // 2. Charger l'image Sentinel-2 pour la saison hivernal
20 function getImageComposite(start, end, aoi) { // Renommée pour plus de clarté
21   return ee.ImageCollection('COPERNICUS/S2_SR_HARMONIZED') // collection recommandée
22     .filterBounds(aoi)
23     .filterDate(start, end)
24     .filter(ee.Filter.lt('CLOUDY_PIXEL_PERCENTAGE', 20))
25     .map(maskS2clouds) // Appliquer le masquage des nuages
26     .median() // Utiliser la médiane pour un composite plus robuste
27     .clip(aoi);
28 }
29
30 // Dates pour l'hiver (ajustez si besoin, ex: hiver 2020-2021)
31 var saison = getImageComposite('2019-12-01', '2020-02-29', zone); // Hiver météorologique
32

```

Figure 3. Le code pour charger l'image Sentinel-2 pour la saison hivernal.

Des indices spectraux, tels que le **NDVI**, **SAVI**, **NDWI**, **NDMI** et **NDBI**, ont été calculés à partir des bandes disponibles de l'image. Ces indices ont été ajoutés à l'image composite pour fournir des informations supplémentaires sur les caractéristiques du sol et de la végétation.

```

33 // 3. Calcul des indices spectraux
34 function addIndices(image) {
35   var ndvi = image.normalizedDifference(['B8', 'B4']).rename('NDVI');
36   var sav1 = image.expression(
37     '((NIR - RED) / (NIR + RED + L)) * (1 + L)', {
38     'NIR': image.select('B8'),
39     'RED': image.select('B4'),
40     'L': 0.5
41   }).rename('SAVI');
42   // NDMI pour l'eau (McFeeters)
43   var ndwi = image.normalizedDifference(['B3', 'B8']).rename('NDWI_Eau');
44   // NDMI pour l'humidité de la végétation (similaire à NDMI de Gao)
45   var ndmi = image.normalizedDifference(['B8', 'B11']).rename('NDMI_Humidite');
46   var ndbi = image.normalizedDifference(['B11', 'B8']).rename('NDBI');
47   return image.addBands(ndvi, sav1, ndwi, ndmi, ndbi);
48 }
49
50 var imageAvecIndices = addIndices(saison); // Renommée pour clarté
51 print('Image avec indices (avant normalisation):', imageAvecIndices);
52

```

Figure 4. Le code pour calcul des indices.

Enfin, les données ont été normalisées pour être compatibles avec les modèles de machine learning. **La normalisation** des bandes, y compris les indices spectraux, a été effectuée en utilisant la moyenne et l'écart-type calculés sur la zone d'étude. Cette étape a permis de rendre les données cohérentes et à

échelle comparable pour les modèles de machine learning.

```
// fonction pour normaliser (standardiser) l'image
function normalizeImage(image, bands, means, stdDevs) {
  var normalized = image.select(bands).toFloat(); // convertir en float pour les calculs
  bands.forEach(function(bandName) {
    var mean = ee.Number(means.get(bandName));
    var stdDev = ee.Number(stdDevs.get(bandName));
    // éviter la division par zéro si stdDev est très petit ou nul
    var bandNormalized = image.select(bandName).subtract(mean).divide(stdDev.max(0.00001)); // stdDev.max(eps)
    normalized = normalized.addBands(bandNormalized, [bandName], true); // remplacer la bande originale
  });
  return normalized;
}

var imageNormaliseePourSVM = normalizeImage(imageavecIndices, bandesPourSVM, means, stdDevs);
print("Image Normalisée pour SVM (vérifier les bandes):", imageNormaliseePourSVM);
```

Figure 5. Le code pour la normalisation.

3.2.2. Classification par Machine Learning:

Création des zones d'entraînement:

Le choix des zones d'entraînement est une étape cruciale dans la mise en œuvre d'une classification supervisée. Il faut sélectionner des zones représentatives pour chaque classe (**eau, végétation, bâti, sol nu**). **Il est essentiel** de couvrir toute la variabilité possible au sein de chaque classe, notamment en incluant différents types de végétation, de bâtiments ou de sols nus. Les zones proches des frontières entre deux classes sont évitées pour limiter les mélanges spectraux. Les échantillons doivent être visuellement clairs, exempts d'ombres, de nuages ou d'autres artefacts, et stables dans le temps. Par ailleurs, un équilibre entre le nombre d'échantillons par classe est recherché pour éviter les biais d'apprentissage et garantir une meilleure performance du classificateur. Dans Google Earth Engine (**GEE**), quatre ensembles de polygones représentant les classes LULC (Eau, Végétation, Bâtiments, Sol nu) ont été créés manuellement, importés comme **FeatureCollection**, puis enrichis d'une propriété **landcover(0 à 3)**. Chaque feature a été modifié via **.map()** pour ajouter cette propriété, et les échantillons ont été affichés avec **Map.addLayer()** pour vérification visuelle. **Et puis** les quatre **FeatureCollections** annotées ont été fusionnées à l'aide de la méthode **.merge()** pour créer un ensemble global d'échantillons d'entraînement nommé **echantillonsEntrainement**. Cela permet de regrouper toutes les données d'apprentissage dans une seule collection.

```
var eau_samples = eau.map(function(feature) { // 'eau' est le nom de votre import
  return feature.set('landcover: 0'); // classe 0 pour l'eau
});
var vegetation_samples = vegetation.map(function(feature) { // 'vegetation' est le nom de votre import
  return feature.set('landcover: 1'); // classe 1 pour la végétation
});
var batiment_samples = batiment.map(function(feature) { // 'batiment' est le nom de votre import
  return feature.set('landcover: 2'); // classe 2 pour le bâtiment
});
var solnu_samples = solnu.map(function(feature) { // 'solnu' est le nom de votre import
  return feature.set('landcover: 3'); // classe 3 pour le sol nu
});

// Afficher vos échantillons pour vérification
Map.addLayer(eau_samples, {color: '0000FF'}, 'Vos échantillons Eau');
Map.addLayer(vegetation_samples, {color: '00FF00'}, 'Vos échantillons Végétation');
Map.addLayer(batiment_samples, {color: 'FF0000'}, 'Vos échantillons Bâtiment');
Map.addLayer(solnu_samples, {color: 'FFFF00'}, 'Vos échantillons Sol Nu'); // Palette : Jaune pour Sol Nu

// 6. Fusion des échantillons
// Fusionner les FeatureCollections modifiées (celles avec la propriété 'landcover')
var echantillonsEntrainement = ee.FeatureCollection([]) // Créer une FeatureCollection vide
  .merge(eau_samples)
  .merge(vegetation_samples)
  .merge(batiment_samples)
  .merge(solnu_samples);

print("Nombre total de vos échantillons d'entraînement fusionnés:", echantillonsEntrainement.size());
```

Figure 6. Le code pour la fusion et l'affichage des zones d'entraînement.




Figure 7. La présentation des zones d'entraînement des 4 classes.

Entraînement du classificateur :

Dans cette étude, trois algorithmes de classification supervisée ont été utilisés : SVM (Support Vector Machine), Random Forest (RF) et CART (Classification and Regression Trees). Le choix de ces méthodes repose sur leur robustesse, leur popularité dans la littérature scientifique en télédétection, et leur capacité à bien fonctionner avec un nombre limité d'échantillons d'entraînement.

SVM est particulièrement adapté pour les jeux de données à haute dimension et les échantillons peu nombreux. Il fonctionne en cherchant l'hyperplan optimal qui sépare les différentes classes avec une marge maximale, ce qui le rend efficace pour distinguer des classes spectrales proches dans un espace complexe.

Random Forest, quant à lui, est un algorithme d'ensemble basé sur plusieurs arbres de décision construits à partir de sous-échantillons aléatoires. Il est reconnu pour sa précision, sa résistance au surapprentissage et sa capacité à gérer des variables bruitées ou corrélées. Il offre également une estimation de l'importance des variables, ce qui peut être utile pour l'interprétation des résultats.

Enfin, **CART** est une méthode simple et rapide qui permet de générer des arbres de décision interprétables. Bien qu'elle soit moins performante seule que RF ou SVM, elle est utile pour une première exploration des données et pour comprendre la logique de séparation entre les classes.

L'utilisation conjointe de ces trois méthodes permet donc de comparer leurs performances sur la classification LULC et de sélectionner la plus adaptée à la complexité des paysages arides d'Errachidia.

Entraînement du classificateur exemple donné par SVM:

Le classificateur SVM (Support Vector Machine) a été généré à l'aide de la fonction `ee.Classifier.libsvm()` de Google Earth Engine. Il a été entraîné à partir d'un ensemble de données nommé `trainingData`, qui contient des échantillons labellisés selon la classe **landcover**. Les variables explicatives utilisées pour l'entraînement sont les bandes sélectionnées dans `bandesPourSVM`, incluant notamment des indices spectraux. Une fois le modèle entraîné, il a été appliqué à l'image satellite normalisée pour produire une carte de classification LULC (Land Use/Land Cover).

Chaque pixel de l'image a ainsi été affecté à l'une des quatre classes définies : eau (0), végétation (1), bâtiment (2) ou sol nu (3). La carte obtenue a été visualisée à l'aide d'une palette colorimétrique intuitive : bleu pour l'eau, vert pour la végétation, rouge pour les bâtiments et jaune pour le sol nu.

```

1 // 9. Entraînement du classificateur SVM
2 {
3   var classificateurSVM = ee.Classifier.libsvm({
4     // Laissez GEE utiliser les valeurs par défaut pour kerneltypes, gamma, cost au début
5   }).train({
6     features: trainingData,
7     classProperty: 'landcover',
8     inputProperties: bandesPourSVM
9   });
10
11 // 10. Classification avec l'image normalisée
12 var imageClasséeSVM = imageNormaliséePourSVM.select(bandesPourSVM).classify(classificateurSVM);
13
14 Map.addLayer(imageClasséeSVM, { // Renommée
15   min: 0,
16   max: 3,
17   palette: ['0000FF', '00FF00', 'FF0000', 'FFFF00'] // Bleu, Vert, Rouge, Jaune
18 }, 'Classification SVM');

```

Figure 8. Le code pour l'application du SVM.

Évaluation de la précision:

L'évaluation de la qualité de cette classification se fait à travers la **matrice de confusion**, qui compare les classes réelles (labels) aux classes prédites par le modèle. La matrice de confusion permet d'analyser les erreurs de classification et de déterminer si certaines classes sont systématiquement mal identifiées.

Parmi les indicateurs tirés de la matrice de confusion, deux mesures sont particulièrement importantes : la **précision globale** et le **coefficient Kappa**.

La **précision globale** mesure la proportion de pixels correctement classifiés par rapport au nombre total de pixels. Elle est calculée en divisant le nombre de classifications correctes par le nombre total de pixels. Une précision élevée indique que le modèle effectue une classification correcte dans la majorité des cas.

Le **coefficient Kappa** est une mesure qui permet d'évaluer la performance du modèle en prenant en compte la possibilité de classification correcte par hasard. Il varie entre -1 et 1, où une valeur de 1 indique une parfaite classification, 0 indique que le modèle ne fait pas mieux que le hasard, et des valeurs négatives suggèrent que le modèle fait pire que le hasard. Ce coefficient est essentiel pour s'assurer que la classification est robuste et fiable.

```

// 11. Évaluation de précision
var echantillonsAvecRandom = trainingData.randomColumn(); // Renommée pour clarté
var fractionEntraînementSVM = 0.7; // 70% pour l'entraînement, 30% pour le test
var ensembleEntraînementSVM = echantillonsAvecRandom.filter(ee.Filter.lt('random', fractionEntraînementSVM));
var ensembleTestsSVM = echantillonsAvecRandom.filter(ee.Filter.gte('random', fractionEntraînementSVM));

var classificateurEntraînePourValidationSVM = ee.Classifier.libsvm({
  features: ensembleEntraînementSVM,
  classProperty: 'landcover',
  inputProperties: bandesPourSVM
}).train({
  features: ensembleEntraînementSVM,
  classProperty: 'landcover',
  inputProperties: bandesPourSVM
});

var classificationValidationSVM = ensembleTestsSVM.classify(classificateurEntraînePourValidationSVM);
var matriceConfusionsSVM = classificationValidationSVM.errorMatrix('landcover', 'classification'); // Renommée

print('-----');
print('ÉVALUATION DE LA PRÉCISION SVM :');
print('Matrice de confusion (SVM) :', matriceConfusionsSVM);
print('Précision globale (SVM) :', matriceConfusionsSVM.accuracy());
print('Coefficient Kappa (SVM) :', matriceConfusionsSVM.kappa());
print('-----');

```

Figure 9. Le code pour l'évaluation de la précision pour le cas du SVM.

L'évaluation de la précision du classificateur SVM repose sur la séparation aléatoire des données d'entraînement et de test, où 70 % des échantillons sont utilisés pour l'entraînement et 30 % pour la validation du modèle. Cette séparation permet de tester la performance du modèle sur des données qu'il n'a jamais vues, assurant ainsi une évaluation impartiale de ses capacités de classification.

Alors que, L'algorithme **CART** (Classification And Regression Trees) est basé sur un arbre de décision qui divise les données en fonction des valeurs des variables d'entrée pour prédire la classe à laquelle appartient chaque pixel. Dans ce code, le classificateur CART est créé en utilisant la méthode `ee.Classifier.smileCart()` et est ensuite entraîné avec les données d'échantillonnage, en spécifiant la propriété `landcover` comme cible de classification et les bandes d'indices spectraux comme caractéristiques d'entrée. Une fois le modèle entraîné, il est utilisé pour classifier l'image en fonction des classes définies. L'évaluation de la précision se fait à travers la matrice de confusion, qui permet de calculer la précision globale et le coefficient Kappa.

Et Lors de l'utilisation de l'algorithme **Random Forest** (RF), plusieurs éléments spécifiques sont adaptés dans le code. Contrairement au SVM ou au CART, RF permet de spécifier un paramètre important : `numberOfTrees`, qui indique le nombre d'arbres de décision à utiliser dans la forêt. Dans notre cas, ce paramètre a été fixé à 100, ce qui offre un bon compromis entre précision et temps de calcul. Le classificateur est instancié avec `ee.Classifier.smileRandomForest(numberOfTrees: 100)`, puis entraîné sur les échantillons d'apprentissage. Par ailleurs, le processus d'échantillonnage (`sampleRegions`) et de division en ensembles d'entraînement et de test reste inchangé. L'évaluation est également effectuée à l'aide de la matrice de confusion, qui permet de visualiser les prédictions correctes et incorrectes pour chaque classe, ainsi que le taux de précision globale et le coefficient de Kappa.

3.2.3. Classification par Deep Learning:

- **CNN:**

Le Convolutional Neural Network (CNN) est un type de réseau de neurones artificiels spécialement conçu pour traiter les données visuelles, telles que les images. Contrairement aux réseaux classiques (fully connected), les CNN exploitent les structures spatiales locales d'une image en utilisant des filtres convolutifs capables d'identifier automatiquement des motifs comme des formes, des textures ou des bords.

Un CNN est généralement composé de plusieurs types de couches :

Couches convolutionnelles : appliquent des filtres glissants sur l'image pour extraire des caractéristiques importantes (features).

Couches de pooling : réduisent la taille des données en gardant l'information essentielle, ce qui permet d'accélérer les calculs et de réduire le surapprentissage.

Couches denses (fully connected) : en fin de réseau, elles interprètent les caractéristiques extraites et attribuent une probabilité à chaque classe.

Ce type de réseau est particulièrement performant pour la classification d'images, car il peut apprendre automatiquement des représentations complexes et hiérarchisées à partir des données d'entrée. Dans le cadre de ce projet, le CNN a été utilisé pour classer des zones d'une image satellite en différentes classes thématiques en analysant localement des petits blocs d'image (patches), ce qui permet une reconnaissance précise des éléments au sol.

Pour notre étude : Après un prétraitement incluant la normalisation spectrale, la réorganisation des dimensions et l'extraction de patches homogènes de 32x32 pixels, un modèle CNN simple a été construit dans un environnement Python (Jupyter Notebook). Ce modèle, composé de deux couches convolutives suivies de couches denses, a été entraîné à l'aide de la fonction de perte *sparse categorical crossentropy* et de l'optimiseur *Adam*. L'entraînement a été réalisé sur un jeu de données divisé en 80 % pour l'apprentissage et 20 % pour le test. Le modèle a ensuite été appliqué de manière glissante sur l'image complète, en classifiant chaque patch selon la classe dominante, avant que le résultat ne soit visualisé avec Matplotlib et exporté en GeoTIFF via Rasterio.

```

X_patches, y_patches = extract_patches(X, y)
X_train, X_test, y_train, y_test = train_test_split(
    X_patches, y_patches, test_size=0.2, random_state=42
)

# Étape 2 : Construction du modèle CNN
model = models.Sequential([
    layers.Conv2D(32, (3, 3), activation='relu', input_shape=(32, 32, X.shape[2])),
    layers.MaxPooling2D((2, 2)),
    layers.Conv2D(64, (3, 3), activation='relu'),
    layers.Flatten(),
    layers.Dense(64, activation='relu'),
    layers.Dense(4, activation='softmax')
])

# Étape 3 : Compilation et résumé du modèle
model.compile(optimizer='adam',
              loss='sparse_categorical_crossentropy',
              metrics=['accuracy'])
model.summary()

# Étape 4 : Entraînement du modèle
history = model.fit(
    X_train, y_train,
    epochs=10,
    batch_size=32,
    validation_data=(X_test, y_test))

X_small = X[:256, :256, :]
def predict_image(model, X, patch_size=32):
    # Fonction à définir selon ta logique d'extraction-glissement-prédiction
    pass

# Exemple d'utilisation (si la fonction est définie)
# predicted_map = predict_image(model, X_small)

# Étape 6 : Visualisation
plt.figure(figsize=(10, 10))
plt.imshow(predicted_map, cmap='nipy_spectral')
plt.title('Carte de classification par Deep Learning (extrait)')
plt.colorbar()
plt.show()

```

Figure 10. Le code de la classification par CNN sur Google Collab.

• UNET:

U-Net peut également être utilisé pour des tâches de classification d'images, en particulier pour des applications où chaque pixel ou une région de l'image doit être assigné à une classe spécifique. Dans ce cas, U-Net est appliqué à des problèmes où l'on souhaite classifier des zones d'une image en fonction de certaines catégories, telles que l'utilisation des terres (LULC) ou la reconnaissance d'objets dans une scène.

Le modèle U-Net peut être modifié pour des tâches de classification en traitant chaque image ou chaque région comme une entité distincte à classifier. L'encodeur extrait les caractéristiques de l'image en réduisant progressivement sa taille et en augmentant le nombre de canaux de caractéristiques. Le goulot d'étranglement permet au réseau d'extraire des informations profondes et abstraites, tandis que la partie décodeur peut être utilisée pour attribuer une classe à l'image ou à des régions spécifiques, selon les besoins. La sortie peut être une carte de probabilité où chaque pixel appartient à une classe ou un vecteur de classification pour l'image entière si une approche plus globale est souhaitée.

Pour notre étude : Pour utiliser U-Net, il faut d'abord préparer les données en extrayant des patches 64x64 de l'image, accompagnés de leurs masques de classification. Ensuite, un modèle U-Net est créé, composé d'un encodeur et d'un décodeur, pour apprendre à prédire les classes pixel par pixel. Une fois le modèle entraîné sur les patches, il peut être appliqué à l'ensemble de l'image pour prédire la classification complète. Le résultat peut ensuite être exporté sous forme d'un fichier GeoTIFF, tout en conservant la projection et la géométrie spatiale de l'image d'origine.

Le code pour la mise en œuvre comprend des étapes suivantes: le chargement des données, la normalisation, la création du modèle U-Net avec Keras/TensorFlow, l'entraînement sur les données et enfin, la prédiction sur l'image complète. Grâce à cette méthode, on obtient des résultats de classification plus précis, adaptés aux besoins de segmentation sémantique, comme dans le cas de la classification des types de sol, de végétation et d'autres éléments géographiques.

```
def unet_model(input_shape=(64, 64, X_shape[2]), num_classes=4):
    inputs = layers.Input(shape=input_shape)
    c1 = layers.Conv2D(32, (3, 3), activation='relu', padding='same')(inputs)
    c1 = layers.Conv2D(32, (3, 3), activation='relu', padding='same')(c1)
    p1 = layers.MaxPooling2D((2, 2))(c1)
    c2 = layers.Conv2D(64, (3, 3), activation='relu', padding='same')(p1)
    c2 = layers.Conv2D(64, (3, 3), activation='relu', padding='same')(c2)
    p2 = layers.MaxPooling2D((2, 2))(c2)
    c3 = layers.Conv2D(128, (3, 3), activation='relu', padding='same')(p2)
    c3 = layers.Conv2D(128, (3, 3), activation='relu', padding='same')(c3)
    u1 = layers.UpSampling2D((2, 2))(c3)
    concat1 = layers.concatenate([u1, c2])
    c4 = layers.Conv2D(64, (3, 3), activation='relu', padding='same')(concat1)
    c4 = layers.Conv2D(64, (3, 3), activation='relu', padding='same')(c4)
    u2 = layers.UpSampling2D((2, 2))(c4)
    concat2 = layers.concatenate([u2, c1])
    c5 = layers.Conv2D(32, (3, 3), activation='relu', padding='same')(concat2)
    c5 = layers.Conv2D(32, (3, 3), activation='relu', padding='same')(c5)
    outputs = layers.Conv2D(num_classes, (1, 1), activation='softmax')(c5)
    model = models.Model(inputs, outputs)
    return model

model = unet_model()
model.compile(optimizer='adam', loss='sparse_categorical_crossentropy', metrics=['accuracy'])
model.summary()
history = model.fit(x_train, y_train, epochs=10, batch_size=16, validation_data=(x_test, y_test))
loss, acc = model.evaluate(x_test, y_test)
print("Accuracy on test:", acc)
i = 0
pred = model.predict(np.expand_dims(X_test[i], axis=0))
predicted_mask = np.argmax(pred[0], axis=-1)
plt.figure(figsize=(10,3))
plt.subplot(1,1,1)
plt.imshow(X_test[i][0,0], cmap='gray')
plt.title("image (band 1)")
plt.subplot(1,1,2)
plt.imshow(y_test[i].squeeze(), cmap='nipy_spectral')
plt.title("real Mask")
```

Figure 11. Une partie du code de la classification par UNET sur Google Collab : définition du modèle U-NET.

4. Résultats

4.1. Résultats de la classification supervisée et évaluation de la précision

La classification supervisée appliquée sur la zone d'étude a permis de générer des cartes thématiques représentant les différentes classes d'occupation du sol, à savoir : l'eau, la végétation, les bâtiments et le sol nu. Trois algorithmes ont été utilisés : CART (arbre de décision), Random Forest (forêt aléatoire) et SVM (Support Vector Machine).

4.1.1. CART

- **CART 2020:**




Figure 12. Les résultats de la classification de l'automne 2020.




Figure 13. Les résultats de la classification du printemps 2020.




Figure 14. Les résultats de la classification de l'hiver 2020.




Figure 15. Les résultats de la classification d'été 2020.

• **CART 2024:**




Figure 16. Les résultats de la classification d'automne 2024.




Figure 17. Les résultats de la classification de l'hiver 2024.




Figure 18. Les résultats de la classification deu printemps 2024.




Figure 19. Les résultats de la classification de l'été 2024.

4.1.2. Random Forest

- **RF 2020:**




Figure 20. Les résultats de la classification de l'AUTOMNE 2020.




Figure 21. Les résultats de la classification de l'été 2020.




Figure 22. Les résultats de la classification dU PRITEMPS 2020.




Figure 23. Les résultats de la classification de l'HIVER 2020.

• RF 2024:




Figure 24. Les résultats de la classification de l'AUTOMNE 2024.




Figure 25. Les résultats de la classification de l'été 2024.




Figure 26. Les résultats de la classification de l'HIVER 2024.




Figure 27. Les résultats de la classification du printemps 2024.

4.1.3. SVM

- SVM 2020:




Figure 28. Les résultats de la classification de l'AUTOMNE 2020.




Figure 29. Les résultats de la classification de l'été 2020.




Figure 30. Les résultats de la classification de l'hiver 2020.




Figure 31. Les résultats de la classification de l'hiver 2020.

• SVM 2024:




Figure 32. Les résultats de la classification de l'AUTOMNE 2024.




Figure 33. Les résultats de la classification de l'été 2024.




Figure 34. Les résultats de la classification de l'hiver 2024.




Figure 35. Les résultats de la classification du printemps 2024.

4.2. Résultats de classification par DL

- Résultats par CNN :




Figure 36. Les résultats de la classification par CNN.

L'image soumise représente le résultat d'une segmentation sémantique, vraisemblablement opérée par un réseau de neurones convolutifs (CNN), visant à classifier différentes classes d'occupation du sol. Cependant, plusieurs observations fondamentales limitent la robustesse et la complétude de cette classification.

Premièrement, l'absence d'une classe distincte pour les infrastructures bâties est une lacune significative. La fusion des "bâtiments" avec la catégorie "sol nu" (assimilée à des surfaces nues ou faiblement végétalisées) introduit une ambiguïté. Ceci suggère soit une insuffisance dans le jeu de données d'entraînement (manque d'exemples pour la classe "bâtiments"), soit des limites de l'architecture du CNN à discriminer des objets de faibles dimensions ou à faible contraste spectral par rapport au fond urbain ou naturel.

Deuxièmement, la pixélisation prononcée de l'image classifiée est une caractéristique notable. Cette granularité est typique des sorties de CNNs de segmentation, particulièrement lorsque des couches de pooling importantes sont utilisées, ou si la résolution spatiale de l'image d'entrée est faible par rapport à la taille des objets à détecter. La pixélisation engendre une perte de finesse des contours et des détails géométriques des objets classifiés

- Résultats par U-NET :




Figure 37. Les résultats de la classification par UNET.

Sur cette image, on observe une nette réduction de la pixélisation par rapport aux classifications précédentes. Les contours des différentes classes sont désormais beaucoup plus lisses et précis, ce qui confère à la carte un aspect plus naturel et détaillé. De plus, un point crucial est que la classification des bâtiments est clairement visible et distincte, représentée par les zones rouges.

5. Discussion sur les résultats

5.1. Résultats de la classification supervisée et évaluation de la précision

Pour une première comparaison, nous allons analyser les résultats de chaque algorithme d'apprentissage automatique en nous basant à la fois sur les **paramètres métriques** (tels que la précision globale et le coefficient de Kappa) et sur une **évaluation visuelle** des cartes classifiées obtenues.

5.1.1. CART

La qualité des cartes générées par l’algorithme CART est globalement satisfaisante, avec une bonne distinction des grandes classes et une évolution saisonnière visible, notamment pour la végétation. Cependant, on note quelques erreurs de classification, notamment une confusion entre certaines zones de sol nu et des surfaces bâties, ce qui limite la précision dans les zones urbanisées. Malgré cela, les cartes restent lisibles et reflètent globalement les tendances attendues dans un contexte aride.

• Analyse des précisions :

	2020		2024	
	CART			
	precision globale	kappa	precision globale	kappa
hiver	0,993917959	0,914497703	0,993300826	0,905496879
printemps	0,996910662	0,956133002	0,996207946	0,946044023
ete	0,997982036	0,971425873	0,996925833	0,957086604
automne	0,995055325	0,930715829	0,993271896	0,904639856

Figure 38. Les valeurs de kappa obtenus par classification saisonnière des années 2020 et 2024.

Indice	Valeur moyenne
NDVI	0.12595
SAVI	0.18891
NDWI	-0.34074
NDMI	-0.13812
NDBI	0.13812

Table 1. Valeurs moyennes des indices spectraux.

Classe réelle	Eau	Végétation	Bâtiment	Sol nu
Eau	528	0	1	10
Végétation	0	1222	0	0
Bâtiment	4	0	1296	273
Sol nu	6	0	273	87146

Table 2. Matrice de confusion de la classification supervisée CART.

La matrice de confusion montre une très bonne performance globale du classificateur CART. Certaines classes ont été très bien reconnues, comme la végétation avec 1222 pixels bien classés et aucun mal classé, ce qui indique une distinction claire grâce aux indices spectraux comme NDVI et SAVI, qui sont positifs et élevés (NDVI = 0.126 ; SAVI = 0.189), confirmant une forte activité végétale.

La classe sol nu est également bien détectée, avec 87146 pixels correctement classés. Cependant, on observe 273 pixels de sol nu confondus avec les bâtiments, ce qui est une erreur relativement fréquente. Cela s’explique par une certaine similarité spectrale entre les surfaces bâties et les sols nus, notamment en zones arides, où le NDBI (= 0.138) et le NDMI (= -0.138) peuvent se rapprocher.

L'eau est globalement bien classée (528 pixels bien reconnus), mais on note quelques confusions avec le sol nu (10 pixels) et les bâtiments (1 pixel). Cela peut être dû à des zones humides ou ombrées où les signatures spectrales se recoupent. Le NDWI négatif (= -0.341) indique une faible présence en eau ou une détection difficile.

La principale faiblesse du modèle se situe dans la confusion entre bâtiments et sol nu, avec 273 pixels de bâtiments mal classés en sol nu. Cela reflète une limite du classificateur CART, qui, basé sur des règles arborescentes, peut manquer de finesse dans des classes aux frontières spectrales peu nettes.

5.1.2. Random Forest

La qualité des cartes générées par l'algorithme Random Forest (RF) est très satisfaisante, grâce à la robustesse de cet algorithme dans la gestion de jeux de données complexes. Les grandes classes, comme la végétation et le sol nu, sont bien distinguées, et les transitions saisonnières apparaissent de manière nette et cohérente. On observe également une meilleure capacité de l'algorithme à réduire les confusions entre les surfaces bâties et les sols nus par rapport à d'autres approches plus simples. Toutefois, quelques erreurs ponctuelles de classification subsistent, notamment dans des zones à signature spectrale ambiguë. Dans l'ensemble, les cartes produites sont claires, informatives et reflètent fidèlement les dynamiques de l'occupation du sol dans cette région aride, confirmant l'efficacité de RF pour ce type d'analyse.

• Analyse des précisions :

	2020		2024	
	RF			
hiver	0,994343395	0,937098804	0,993686724	0,92789297
printemps	0,997823171	0,968873869	0,997618943	0,965712852
ete	0,998585232	0,979890239	0,99754509	0,965443632
automne	0,996769479	0,953970037	0,995112811	0,929306936

Figure 39. Les valeurs de kappa obtenus par classification saisonnière des années 2020 et 2024.

Classe réelle \ Classe prédite	Eau (0)	Végétation (1)	Bâti (2)	Sol nu (3)
Eau (0)	496	0	1	12
Végétation (1)	0	799	0	0
Bâti (2)	0	0	1392	255
Sol nu (3)	2	0	78	58486

Table 3. Matrice de confusion de la classification Random Forest.

Indice spectral	Valeur moyenne
NDVI	0.126
SAVI	0.189
NDWI	-0.341
NDMI	-0.138
NDBI	0.138

Table 4. Valeurs moyennes des indices spectraux pour la classification.

Le modèle de classification Random Forest (RF) présente une performance impressionnante, avec une précision globale de 99,43 % et un coefficient Kappa de 0,937, ce qui témoigne d’une classification fiable et cohérente. Les résultats de la matrice de confusion montrent que la classe 0 (eau) est correctement identifiée dans la majorité des cas, avec seulement quelques erreurs mineures vers les autres classes, ce qui est attendu en raison des limites de détection des petites étendues d’eau ou de l’effet des objets proches de l’eau. La classe 1 (végétation) est également parfaitement classifiée, sans erreurs, ce qui indique que le modèle parvient à identifier efficacement les zones végétalisées. En revanche, les bâtiments (classe 2) sont souvent correctement classés, mais il existe des erreurs où certains bâtiments sont confondus avec des zones de sol nu (classe 3), ce qui peut être dû à des caractéristiques spectrales similaires entre ces deux classes, notamment dans les zones urbaines où les bâtiments et les sols dégagés partagent des couleurs ou des textures proches.

Les indices spectraux obtenus, tels que le NDVI (0,1259) et le SAVI (0,1889), suggèrent que la végétation est présente, mais avec une densité relativement faible, ce qui est conforme aux caractéristiques des zones analysées. Le NDWI (indice de l’eau) montre une valeur négative de -0,3407, ce qui confirme qu’il n’y a pratiquement pas de couverture en eau dans cette zone, et le NDMI (-0,1381) indique des conditions sèches, ce qui renforce l’idée que la majorité de la surface est constituée de sols nus. L’indice NDBI (0,1381), quant à lui, révèle la présence d’éléments urbains, ce qui est cohérent avec la classification des bâtiments.

Ainsi, bien que le modèle distingue globalement bien les classes, les erreurs de classification entre les bâtiments et le sol nu pourraient être dues à la difficulté de différencier ces deux catégories, notamment dans les zones urbaines où les caractéristiques spectrales peuvent se superposer. En somme, le modèle fournit des résultats solides et permet d’identifier efficacement les principales classes de l’image, mais un ajustement plus fin pourrait être nécessaire pour améliorer la distinction entre le sol nu et les bâtiments dans certaines zones.

5.1.3. SVM

	2020		2024	
	SVM			
hiver	0,997403774	0,963653357	0,993686724	0,92789297
printemps	0,99789724	0,969297373	0,997618943	0,965712852
ete	0,998840637	0,983565389	0,99754509	0,965443632
automne	0,99771411	0,967943551	0,995112811	0,929306936

Figure 40. Les valeurs de kappa obtenus par classification saisonnière des années 2020 et 2024.

Classe réelle \ Classe prédite	Eau (0)	Végétation (1)	Bâti (2)	Sol nu (3)
Eau (0)	1187	0	0	0
Végétation (1)	0	559	0	4
Bâti (2)	0	0	1412	151
Sol nu (3)	0	2	70	87411

Table 5. Matrice de confusion de la classification SVM.

Le modèle SVM (Support Vector Machine) présente des résultats exceptionnels avec une précision globale de 99,75 % et un coefficient Kappa de 0,9644, ce qui indique une très haute performance dans la classification des différentes classes. La classe de l'eau (classe 0) est parfaitement identifiée, avec 1187 pixels correctement classifiés et aucune confusion avec les autres classes. La végétation (classe 1) est également bien distinguée, avec seulement 4 erreurs mineures vers la classe de sol nu (classe 3), ce qui montre que le modèle gère efficacement cette catégorie.

Les bâtiments (classe 2) sont correctement classifiés dans la majorité des cas, avec 1412 pixels correctement identifiés, mais 151 erreurs vers le sol nu. Cela suggère que certaines zones urbaines, surtout celles qui présentent des sols dégagés ou des caractéristiques spectrales similaires, sont parfois confondues avec des zones de sol nu. Enfin, la classe de sol nu (classe 3) est largement dominante, avec 87411 pixels correctement classifiés, bien que le modèle commette 70 erreurs vers les bâtiments et 2 erreurs vers l'eau. Ces erreurs sont relativement faibles et peuvent être attribuées à des similitudes spectrales entre certaines zones de sol nu et d'autres classes.

Dans l'ensemble, les résultats du modèle SVM sont remarquables, avec une précision très élevée et des erreurs minimales entre les classes. Le coefficient Kappa indique également que la classification est bien au-delà de ce que l'on attendrait par hasard, ce qui fait de ce modèle une solution efficace pour la classification des différentes catégories, notamment l'eau, la végétation, les bâtiments et le sol nu.

5.2. Comparaison entre les 3 algorithmes:

On a dressé un graphe pour comparer les algorithmes selon l'indice kappa et on a obtenu les résultats suivants :




Figure 41. Graphe de comparaison des indices kappa entre les différents algorithmes pendant l'année 2020.

L'indice Kappa est plus élevé pour le modèle SVM que pour le modèle Random Forest et CART, ce qui indique une meilleure capacité du SVM à différencier les classes de manière fiable. En raison de cette performance supérieure, nous adopterons le modèle SVM pour les étapes suivantes de l'étude. Il gère mieux les frontières complexes entre les classes, comme celles entre le sol nu et les bâtiments, et présente moins d'erreurs de classification. Ainsi, bien que les deux modèles soient performants, le SVM est le choix optimal pour la classification et l'analyse .

5.3. Interprétation des résultats du SVM et comparaison intersaisonnière.

Pour l'interprétation des résultats de la classification par SVM, nous avons opté pour la conversion des images GeoTIFF en fichiers TIFF. Cela nous a permis d'obtenir une table attributaire sur QGIS, ce qui facilite l'analyse des résultats. Cette conversion a été effectuée après avoir refait la classification en transformant les niveaux de gris en couleurs.

Ensuite, pour calculer le nombre de pixels pour chaque classe, nous avons utilisé des outils dans ArcGIS permettant de calculer des statistiques par zone, ici le nombre de pixels pour chaque classe. Après avoir obtenu ces valeurs, et sachant que la résolution de l'image est de 10 m, nous avons calculé la surface de chaque classe en multipliant le nombre de pixels par 100 .

Toutes ces opérations ont été réalisées sur la table attributaire dans ArcGIS, et le résultat final est présenté dans le tableau suivant.

		surface	
saison		2020	2024
hiver	eau	124590	112150
	vegetation	457180	381250
	batiment	149180	140020
	sol	18154120	18251650
printemps	eau	122720	114630
	vegetation	469790	389680
	batiment	138210	186650
	sol	18154350	18194110
ete	eau	97880	113080
	vegetation	359610	384070
	batiment	263570	170270
	sol	18164010	18217650
automne	eau	91700	116250
	vegetation	350740	352590
	batiment	163360	118270
	sol	18279270	18297960

Figure 42. La superficie de chaque classe par année et saisons.

Nous avons analysé l'évolution des superficies occupées par différentes classes d'occupation du sol (eau, végétation, bâtiment, sol nu) sur deux années (2020 et 2024) et selon les quatre saisons. L'objectif était d'observer les variations temporelles et saisonnières de ces classes, ainsi que d'identifier

d'éventuelles erreurs de classification dues aux limites du modèle.

Une première observation concerne la classe «**eau**», qui connaît une diminution notable de l'hiver à l'été, ce qui est cohérent avec les cycles naturels de l'environnement. En hiver, l'eau est présente en plus grande quantité en raison des précipitations et de la fonte des neiges, tandis qu'en été, l'évaporation et la réduction des apports hydriques entraînent une diminution des surfaces couvertes par l'eau. Cette tendance est bien marquée en 2020, bien qu'en 2024 une légère remontée soit observée entre le printemps et l'été, ce qui pourrait être due à des conditions climatiques particulières.

Concernant **la végétation**, les données montrent un pic au printemps, période durant laquelle la couverture végétale est à son maximum grâce à des conditions favorables de température et d'humidité. Cette surface diminue logiquement en été, probablement en raison de la **sécheresse**, puis se stabilise ou remonte légèrement en automne. Toutefois, **on constate une baisse globale de la végétation entre 2020 et 2024, toutes saisons confondues**, ce qui pourrait traduire un phénomène réel (déforestation, sécheresse accrue).

Un aspect particulièrement marquant de ce tableau concerne la classe des «**bâtiments**», dont les surfaces varient fortement selon les saisons et entre les deux années étudiées. En hiver, les superficies de bâtiments sont relativement stables : 149 180 m² en 2020 contre 140 020 m² en 2024, ce qui représente une légère baisse. En revanche, au printemps, une hausse notable est observée : de 138 210 m² en 2020, la surface classée comme bâtiment atteint 186 650 m² en 2024, soit une augmentation de près de 48 440 m². Cette évolution pourrait traduire un développement urbain réel, mais elle peut aussi résulter d'une meilleure distinction par le modèle entre les bâtiments et les zones voisines, notamment les sols nus.

La variation la plus frappante se produit en été. En 2020, le modèle attribue aux bâtiments une surface de 263 570 m², soit près du double de celle observée en hiver. En 2024, cette valeur chute brusquement à 170 270 m², ce qui laisse penser que la valeur anormalement élevée de 2020 résulte d'une erreur de classification. Il est probable que, dans les conditions estivales (lumière forte, sol sec, peu de végétation), de vastes zones de sol nu ont été mal interprétées comme des bâtiments. Ce phénomène est courant en classification automatique lorsque les signatures spectrales des classes sont proches ou lorsque les images utilisées ne comportent pas suffisamment de bandes spectrales pour distinguer efficacement les matériaux.

À l'automne, la surface classée comme bâtiment est de 163 360 m² en 2020, contre 118 750 m² en 2024, ce qui représente une baisse significative. Cela confirme la grande sensibilité du modèle aux conditions de lumière, de végétation et d'humidité du sol, qui influencent fortement la capacité à distinguer les bâtiments des surfaces voisines.

Ces fluctuations importantes indiquent que le classificateur SVM présente une certaine instabilité dans la reconnaissance des bâtiments, en particulier en été. Une amélioration du modèle pourrait passer par l'ajout de données auxiliaires (indices spectro-spatiaux, données de texture, altitude), ou par un étiquetage plus rigoureux, notamment pour mieux différencier les surfaces dures (bâtiments) des sols nus.

Enfin, la classe «**sol**» reste relativement stable au fil des saisons et des années, mais elle pourrait en réalité masquer certaines erreurs de classification. En effet, si une partie du sol est confondue avec des bâtiments ou de la végétation selon la saison, cela fausse les proportions réelles observées. La stabilité apparente de cette classe pourrait ainsi être artificielle, compensée par des erreurs inverses dans les autres classes.

5.4. Cartes de transition:

La visualisation des changements a été renforcée par la création de cartes de changement via ArcGIS:

La carte de transition permet d'analyser les changements d'occupation du sol entre deux périodes en comparant les images classifiées obtenues à partir du SVM. Elle repose sur une logique simple : **chaque pixel de l'image initiale (par exemple, la saison sèche) est comparé au même pixel dans l'image de la saison suivante** (par exemple, la saison humide). En fonction du changement observé, un code de transition unique est attribué. Ce code est calculé en multipliant la valeur de la classe d'origine par 10, puis en y ajoutant la valeur de la classe de destination. Par exemple, un pixel passant de la végétation (1) au bâti (2) reçoit le code 12.

Cette carte a été générée dans ArcGIS à l'aide de l'outil Raster Calculator (ou Map Algebra), qui permet d'effectuer des opérations entre deux couches raster. L'expression utilisée combine les deux rasters classifiés pour produire un nouveau raster contenant les codes de transition. Chaque code représente un type spécifique de changement (ou de stabilité), permettant ainsi une lecture fine des dynamiques territoriales.

Une fois la carte de transition obtenue, une symbologie spécifique a été appliquée pour rendre les changements facilement interprétables. **Par exemple, les transitions vers la végétation sont représentées en vert, celles vers le bâti en rouge, vers l'eau en bleu, et vers le sol nu en jaune.** Les zones stables (où la classe ne change pas) sont symbolisées en noir. Cette représentation permet de visualiser rapidement les processus comme l'urbanisation (végétation → bâti), la déforestation (végétation → sol nu), ou encore le verdissement (sol nu → végétation).




Figure 43. La carte de transition entre printemps 2020 et 2024.

Pour le printemps : La carte de transition du printemps montre une distribution variée des changements d'occupation du sol. Les zones de couleur jaune (transitions vers Sol nu) sont très répandues à travers l'image. Des foyers de couleur rouge (transitions vers Bâti) sont visibles, indiquant une extension des zones urbaines. Des surfaces bleues (transitions vers Eau) apparaissent de manière plus dispersée, tandis que de très petites parcelles vertes (transitions vers Végétation) sont également identifiables. La grande zone en haut à gauche présente un mélange de jaune et de bleu clair, et si on relie ceci aux calculs

de surface on remarque que la surface du sol en 2024 est plus grande que celle en 2020 alors que pour les autres classes c'est le contraire.




Figure 44. La carte de transition entre Hivers 2020 et 2024.

Pour l'Hiver : Pour la saison hivernale, la carte de transition affiche une persistance des couleurs jaune (transitions vers Sol nu) et rouge (transitions vers Bâti) sur l'ensemble du territoire. La grande zone supérieure gauche, qui avait montré des changements saisonniers marqués, est maintenant caractérisée par des nuances de jaune et de gris, suggérant la présence de sol nu ou une stabilité de cette classe. Les zones vertes (vers Végétation) et bleues (vers Eau) sont moins étendues que les transitions vers le sol nu et le bâti, mais restent présentes ponctuellement. Cette observation est fortement corrélée avec la forte augmentation de la surface de "Sol nu" et les diminutions de "Eau", "Végétation" et "Bâtiment". Cela suggère que durant l'hiver, une partie de l'eau, de la végétation et des bâtiments a été convertie en sol nu, ce qui est bien représenté par les pixels jaunes sur la carte. Les pixels rouges (transition vers Bâti) et verts (transition vers Végétation) sont moins prédominants, reflétant la diminution nette de ces classes, et les bleus sont également en baisse.




Figure 45. La carte de transition entre ETE 2020 et 2024.

Pour l'Été : Sur la carte de transition de l'été, les couleurs jaune et rouge continuent d'être des éléments dominants, similaires à ce qui est observé au printemps. La caractéristique la plus distinctive de cette saison est la présence étendue du bleu et du bleu clair dans la grande zone supérieure gauche de l'image. Ailleurs, les zones de couleur rouge (vers Bâti) et jaune (vers Sol nu) sont toujours apparentes. Les transitions vertes (vers Végétation) demeurent discrètes. En analysant les surfaces, nous avons observé une augmentation de la superficie occupée par l'eau, ainsi qu'une diminution notable de celle des bâtiments. Toutefois, la présence persistante de zones en rouge, indiquant une transition vers le bâti, pourrait résulter d'une confusion entre le sol nu et les zones bâties, due à une interprétation erronée lors de la classification.



Figure 46. La carte de transition entre Automne 2020 et 2024.

Pour l'Automne : La carte de transition de l'automne présente des motifs de couleurs qui varient par rapport aux saisons précédentes. Le jaune (transitions vers Sol nu) reste une couleur bien représentée, mais la grande zone supérieure gauche, qui était dominée par le bleu en été, montre maintenant une prédominance de vert clair et vert foncé (transitions vers Végétation). Les zones rouges (vers Bâti) sont toujours visibles et dispersées. Des îlots de bleu (vers Eau) peuvent être observés par endroits, mais de manière moins prépondérante que les autres couleurs. Les chiffres confirment une augmentation de la "Végétation" bien que modeste, et une augmentation notable de l'"Eau", ce qui est visuellement supporté par les pixels verts et bleus sur la carte. La diminution du "Bâtiment" et l'augmentation du "Sol nu" sont également cohérentes avec la présence des pixels jaunes et la relative diminution du rouge sur la carte.

5.5. Résultats de classification par DL

La première image, de classification par CNN, se caractérise par une pixélisation prononcée, où les contours des différentes catégories de classification (jaune pour le sol, bleu pour l'eau, vert pour la végétation) sont anguleux et manquent de finesse. Cette granulation grossière indique une résolution spatiale effective limitée de la classification, suggérant potentiellement l'utilisation d'un modèle CNN plus simple ou des opérations de pooling intensives qui réduisent la richesse des détails. Un aspect crucial de cette image est l'absence d'une catégorie distincte pour les bâtiments, ces derniers étant fusionnés et indifférenciés au sein de la vaste étendue jaune du "sol". Cette agrégation rend impossible une analyse spécifique des zones bâties et de l'impact des infrastructures humaines sur le paysage. De

plus, les catégories sont présentées de manière très basique, sans nuances internes, comme en témoigne la masse d'eau bleue qui apparaît comme une entité uniforme.

En revanche, la deuxième image, par Unet, témoigne d'une amélioration significative de la qualité de la classification. La pixélisation est réduite, résultant en des contours plus lisses, plus naturels et d'une précision accrue pour toutes les catégories. Cette finesse des détails est souvent associée aux architectures de réseaux de neurones plus avancées, qui sont conçues pour préserver les informations de localisation lors du processus de segmentation. L'avancée la plus notable est l'apparition, du classe des bâtiments en rouge.

5.6. La carte de prédiction de 2028

Pour les cartes de prédiction dans cette étude, nous avons utilisé un script sur Google Earth Engine (GEE) pour la période de 2020 à 2028. Une zone géographique d'étude a été définie à l'aide de coordonnées spécifiques pour la région d'Errachidia. Cette zone a ensuite été ajoutée à la carte afin d'extraire les images pertinentes pour l'analyse.

Le script a permis de créer une fonction pour obtenir une image par saison. En utilisant des images de Sentinel-2, les données ont été extraites pour différentes saisons, en filtrant les images par dates spécifiques et en réduisant la couverture nuageuse à moins de 20 %. Cette approche a permis d'obtenir des images représentatives pour les saisons concernées (hiver 2020, hiver 2024 et prévision pour l'hiver 2028).

Ensuite, des indices spectraux ont été calculés pour chaque image afin de mieux caractériser les propriétés de la couverture du sol. Les indices utilisés comprenaient le NDVI (indice de végétation), le SAVI (indice de végétation ajusté pour la densité du sol), le NDWI (indice d'humidité du sol), le NDMI (indice d'humidité de la végétation) et le NDBI (indice de bâtiments). Ces indices ont fourni des informations détaillées sur la végétation, l'humidité du sol et d'autres caractéristiques du terrain, nécessaires pour la classification de l'usage des sols.

Pour la classification, des polygones d'échantillonnage ont été créés pour identifier les différentes classes de couverture du sol, telles que l'eau, la végétation, les bâtiments et le sol nu. Ces polygones ont été utilisés pour l'entraînement du modèle de classification Random Forest (RF) en 2024, en utilisant les indices spectraux et les images des années 2020 et 2024.

Le classificateur RF a ensuite été appliqué aux images des années 2020, 2024 et 2028 pour générer des cartes de classification de l'utilisation des sols. Ces cartes ont permis de faire des prédictions pour l'année 2028. En parallèle, une évaluation du modèle a été réalisée en utilisant des données de 2024 pour calculer la précision de la classification, à travers une matrice de confusion, et en obtenant des mesures telles que la précision globale et le coefficient Kappa.

Enfin, les résultats des classifications ont été exportés vers Google Drive, où ils peuvent être analysés et utilisés pour des études ultérieures. Cependant, l'insuffisance de temps disponible nous a poussés à limiter l'étude aux années 2020 et 2024, ce qui a affecté la qualité des cartes de prédiction et limité l'analyse des corrélations entre la couverture du sol, les saisons et les années.

6. Limitation et contraintes:

- **Variation des couleurs du sol :** La variation des couleurs du sol, qui est similaire à celle des bâtiments, a affecté la précision de la classification. Cela a entraîné une mauvaise classification de certaines zones de sol comme bâtiments ou autres types de couverture du sol.
saisonniers autour des plans d'eau : Pendant les saisons sèches, les bords des plans d'eau ont parfois été détectés comme des bâtiments ou d'autres types de couverture du sol au lieu de sol nu en raison de similitudes de couleurs, ce qui a compromis la précision de la classification.
- **Données externes :** L'absence de données détaillées sur les propriétés du sol et les précipitations a rendu difficile l'amélioration des résultats de classification. L'intégration de telles données pourrait améliorer la précision de la classification et fournir de meilleures informations sur les modèles d'utilisation des terres.
- **Limitation temporelle :** L'insuffisance du temps disponible nous a poussés à choisir un nombre limité d'années (2020 et 2024) pour accélérer l'étude. Cette contrainte a affecté la qualité des cartes de prédiction et a limité l'analyse de la corrélation entre la couverture des sols, les saisons et les années. Si nous avions eu plus de temps, nous aurions pu étudier plus en détail les changements à travers plusieurs années, permettant une analyse plus complète des corrélations saisonnières et des tendances à long terme.

7. Conclusion

En conclusion, cette étude a exploité les technologies de télédétection, en utilisant des images Sentinel-2 des années 2020 et 2024, pour analyser la couverture des sols (LULC) dans la région d'Errachidia, une zone vulnérable et encore peu étudiée. Grâce à des indices tels que le NDVI, NDWI, EVI, et d'autres outils dérivés des images satellites, cette recherche a permis de fournir un diagnostic des états et des tendances des ressources en terres et en eau de cette province aride, fortement impactée par la pression humaine et la sécheresse.

L'étude a montré que les ressources en eau diminuent de manière significative. Concernant les constructions urbaines, une tendance à l'augmentation des zones urbanisées a été observée, mais certaines erreurs de classification du sol ont empêché une quantification précise de ces changements. La végétation a connu des changements très légers, avec des variations saisonnières, parfois augmentant. Une corrélation entre la végétation et les ressources en eau a également été identifiée. Si nous avions eu plus de temps, nous aurions pu approfondir l'étude de changements et des corrélations entre les saisons avec un échantillon de données sur plusieurs années.

Remerciement. Nous tenons à exprimer notre sincère gratitude à M. Hassan Hani pour son encadrement précieux, ses conseils avisés et son soutien constant tout au long de ce travail.

Déclaration de disponibilité des données. Les données utilisées dans cette étude proviennent exclusivement de la plateforme Google Earth Engine (GEE). Les images satellitaires Sentinel-2 utilisées sont librement accessibles via le catalogue de données de la mission COPERNICUS S2.

Aucune donnée externe n'a été utilisée. Tous les paramètres d'analyse, y compris les indices spectraux (NDVI, SAVI, NDWI, NDMI, NDBI), ont été générés à partir des bandes spectrales des images Sentinel-2. Les classes d'occupation du sol ont été définies à l'aide d'échantillons dessinés manuellement dans l'environnement GEE.

Les données produites (images classifiées, résultats d'évaluation, surfaces par classe, carte de prédiction pour 2028) peuvent être reproduites en suivant le code scripté sur GEE, disponible sur demande auprès des auteurs.

References

Chowdhury, Md. Sharafat. "GIS-based Method for Mapping Actual LULC by Combining Seasonal LULCs." *MethodsX*, vol. 11, 2023, p. 102472. doi: 10.1016/j.mex.2023.102472. CC BY 4.0 License.

Karmaoui, Ahmed, Ben Salem, Abdelkrim, el Jaafari, Samir, García-Álvarez, David, Camacho Olmedo, María Teresa, Paegelow, Martin, Mas, Jean François. "Exploring the Land Use and Land Cover Change in the Period 2005-2020 in the Province of Errachidia, the Pre-Sahara of Morocco." November 2022. Mohammed V University, Université Moulay Ismail de Meknes.

Land Use Cover Datasets and Validation Tools: Validation Practices with QGIS. Edited by David García-Álvarez, María Teresa Camacho Olmedo, Martin Paegelow, and Jean François Mas.