



ZCI TOPOGRAPHIE

JUIN 2025

Rapport du projet de recherche

Exploration de l'algorithme SAM en apprentissage profond
pour l'extraction des toitures de bâtiments à partir de
l'imagerie satellitaire

Réalisé par :

Hte Soumaya N°37

EL MOADINE Amina N°26

SAMMOUD Fatima Zahra N°53

RYAHI Yazid N°51

WALI Soufyane N°57

Encadrés par :

Mme SBIKI hajar

Mme SEBARI imane

Mme AIT ELKADI kenza

Mme MOUSSAOUI Asmae



Remerciements

Nous tenons à remercier vivement nos professeurs, Mme SEBARI, Mme AIT ELKADI et Mme Moussaoui, qui n'ont épargné aucun effort pour nous mettre sur les rails d'utilisation et d'exploitation des algorithmes d'apprentissage profond appliqués à l'analyse d'images satellitaires.

Nous tenons également à exprimer notre profonde gratitude à toute l'équipe pédagogique ayant réfléchi à cette approche d'apprentissage dynamique, qui a grandement enrichi notre apprentissage.

Un immense merci à notre chère encadrante, Mme Sbiki, qui nous a suivi tout au long de notre recherche et nous a apporté tous les conseils et l'accompagnement nécessaires à la réussite de ce projet.



Sommaire

Introduction.....	4
Contexte de l'étude.....	4
Problématique.....	4
Objectif du projet	5
Revue de littérature	5
Le SAM.....	5
Architecture.....	5
Limites connues dans le cadre d'images satellitaires.....	6
Démarche méthodologique	6
Première phase : Approche initiale : test du modèle SAM en zero-shot (sans entraînement)	6
Phase 2 : Entraînement personnalisé avec annotations manuelles (polygones).....	9
Explication du code utilisé.....	9
Résultat obtenu	9
Analyse des résultats.....	10
Phase 3 : Entraînement ciblé sur une seule image de haute qualité	11
Explication du code utilisé.....	11
Introduction de bounding box	11
Résultat obtenu	12
Analyse de résultats	12
Phase 3 : Entraînement ciblé sur une image de haute qualité en utilisant le critère de surface ..	13
Préparation de l'image	13
Détection des bâtiments avec YOLO	13
Segmentation précise avec SAM	13
Filtrage par critère de surface	13
Résultats.....	14
Analyse des résultats.....	14
Problèmes techniques et stratégies de résolution	15
Validation et évaluation	15
Critères retenus pour l'évaluation	15
Résultats obtenus et interprétation.....	16
Limites de la validation à petite échelle	18
Perspectives d'amélioration	18

Recommandations et remarques	19
Conclusion générale	20
Webographie	21

INTRODUCTION

Contexte de l'étude

Ces dernières années, l'explosion de la disponibilité des images satellite a révolutionné la **télédétection** et l'analyse spatiale. L'une des applications les plus importantes dans ce domaine est l'**extraction d'objets géographiques** à partir d'images satellitaires, comme les routes, les bâtiments, les zones agricoles ou les toitures.

En milieu urbain, l'identification précise des **toitures des bâtiments** est indispensable pour de nombreuses applications :

- La **modélisation 3D** des villes
- L'**extraction des toitures de bâtiments**
- La **gestion urbaine et cadastrale**,
- Les **études d'ensoleillement** ou la planification de **panneaux solaires**,

Problématique

L'extraction automatique des **toitures de bâtiments** à partir d'images satellitaires constitue un défi dans le domaine de la **télédétection urbaine**.

Bien que les images disponibles soient de plus en plus précises, plusieurs facteurs rendent cette tâche complexe :

- La **diversité morphologique** des toitures (formes, matériaux, couleurs),
- Les **obstructions visuelles** (ombres, végétation, objets environnants),
- Et la **variabilité des conditions d'acquisition** (résolution, angle de prise de vue, illumination).

Les méthodes classiques d'analyse d'image atteignent rapidement leurs limites dans ces contextes hétérogènes. Par ailleurs, les algorithmes récents d'**apprentissage profond** aient démontré de bonnes performances en segmentation sémantique cependant leur application aux images satellites nécessite souvent un **entraînement préalable complexe et coûteux en ressources**, notamment en matière de **jeu de données**.

L'apparition du modèle **Segment Anything (SAM)**, capable de réaliser une **segmentation d'objets sans entraînement préalable** (zero-shot), ouvre de nouvelles perspectives. Cependant, ce modèle a été initialement conçu et testé sur des images classiques (photographies du quotidien, objets naturels) et non sur des **images satellitaires à composantes spectrales et résolution spécifiques**.

Il est légitime donc de poser les problématiques suivantes :

- ✚ Le modèle SAM, conçu pour une segmentation universelle d'objets, peut-il être efficacement appliqué à l'extraction des toitures de bâtiments à partir d'images satellitaires ?
- ✚ Quelles adaptations, optimisations ou entraînements spécifiques sont nécessaires pour améliorer sa performance dans ce contexte particulier ?

Objectif du projet

Dans ce projet, nous explorons l'applicabilité de l'algorithme **SAM** pour la tâche spécifique d'**extraction des toitures de bâtiments à partir d'images satellitaires**. L'objectif est de :

- Évaluer les performances de SAM dans ce contexte
- Identifier ses limites dans un environnement sans GPU performant
- Étudier la possibilité d'un **entraînement supervisé personnalisé**
- Et proposer des pistes d'**amélioration** pour optimiser ses résultats sur ce type de données

Ce rapport initial détaillera donc la démarche suivie, les expérimentations réalisées, les obstacles rencontrés ainsi que les solutions envisagées et les perspectives de recherche futures.

REVUE DE LITTÉRATURE

Le SAM

Le **Segment Anything Model (SAM)** est un modèle de segmentation développé par **Meta AI Research** en 2023. C'est une nouvelle génération d'algorithmes capables d'**isoler automatiquement des objets dans n'importe quelle image**, indépendamment de leur nature, sans nécessiter d'entraînement spécifique sur une tâche donnée.

La particularité de SAM réside dans son approche "**promptable segmentation**", c'est-à-dire qu'il peut produire un masque **de segmentation** en réponse à différents types d'entrées (prompts) :

- **points** (positifs ou négatifs),
- **boîtes englobantes** (bounding boxes),
- **contours approximatifs** (masks),
- ou même **aucun prompt explicite** (mode automatique).

Architecture

L'architecture de SAM repose sur une combinaison de **trois composants principaux** :

1. Image Encoder (Encodeur d'image)

- Utilise un **transformer puissant** (par défaut, une version optimisée de ViT-H – Vision Transformer-Heavy).
- Transforme toute l'image en un **espace d'embeddings riches** qui encodent l'information spatiale et visuelle.
- Produit une représentation universelle de l'image (indépendamment du prompt utilisé ensuite).

2. Prompt Encoder

- Encode les **instructions de l'utilisateur** (comme les points ou boîtes) en vecteurs adaptés à la tâche de segmentation.
- Permet une flexibilité exceptionnelle dans l'interaction avec l'image.

3. Mask Decoder

- Combine les embeddings de l'image et les instructions du prompt pour **générer un masque de segmentation**.
- Produit **plusieurs masques candidats** accompagnés de scores de confiance, permettant une sélection du meilleur résultat.

Limites connues dans le cadre d'images satellitaires

- Inadéquation du modèle pré-entraîné aux images satellites
- Performance limitée en mode zero-shot
- Dépendance à des ressources matérielles puissantes
- Sensibilité à la qualité des annotations d'entraînement
- Problèmes liés à l'optimisation des images
- Difficulté à intégrer des critères géométriques ou topologiques

DÉMARCHE MÉTHODOLOGIQUE

Première phase : Approche initiale : test du modèle SAM en zero-shot (sans entraînement)

Avant de procéder à l'extraction ciblée des toits, une première étape a consisté à tester le fonctionnement général du modèle SAM (Segment Anything Model) de Meta AI sur notre machine locale. L'objectif était de vérifier que l'installation était correcte, que les dépendances étaient bien configurées et que le modèle pouvait effectuer des segmentations de base.

Pour cela, nous avons utilisé directement l'image du projet, c'est-à-dire celle que nous comptons utiliser pour l'extraction des toits. Aucun guidage ou instruction spécifique n'a été fourni au modèle : l'idée était simplement d'observer comment SAM réagit de manière autonome à cette image, sans ciblage particulier.

Cette première manipulation avait pour objectifs de :

- Vérifier la compatibilité entre le modèle et notre environnement de travail (matériel, version de Python, support GPU, etc.)
- Confirmer que le modèle génère bien des masques de segmentation

- Évaluer la vitesse d'exécution et les ressources consommées
- Se familiariser avec le format des résultats produits par SAM (masques, coordonnées, etc.)

Bibliothèques utilisées :

Sur le plan technique, nous avons utilisé l'environnement Python pour exécuter le modèle. Les principales bibliothèques mobilisées sont :

- **Segment-anything** : Il s'agit du package officiel développé par Meta AI. Il contient l'implémentation du modèle SAM, les fichiers de configuration, ainsi que des fonctions utiles pour charger le modèle, préparer les images d'entrée, générer les masques de segmentation, et visualiser les résultats.
- **torch (PyTorch)** : PyTorch est la bibliothèque principale utilisée pour le calcul scientifique et l'exécution de réseaux de neurones profonds. Elle permet de charger les poids du modèle SAM, de faire des inférences sur des images, et de tirer parti du GPU (via CUDA) pour accélérer les calculs. Sans PyTorch, SAM ne peut pas fonctionner.
- **opencv-python** : OpenCV est une bibliothèque spécialisée dans le traitement d'images. Dans notre cas, elle a servi à charger les images depuis le disque, à les redimensionner, et à effectuer des conversions de formats nécessaires avant l'entrée dans le modèle.
- **matplotlib** : Cette bibliothèque est utilisée pour créer des visualisations. Nous l'avons utilisée pour afficher les images originales avec les masques générés par SAM superposés, ce qui permet d'analyser visuellement la qualité des segmentations produites.
- **numpy** : Numpy est une bibliothèque fondamentale pour le traitement numérique. Elle a été utilisée pour manipuler les masques de segmentation, qui sont représentés sous forme de matrices. Elle permet aussi de réaliser des opérations sur les tableaux d'images (dimensions, fusion de canaux, etc.).

Problèmes rencontrés

Au cours de cette première prise en main du modèle SAM, plusieurs problèmes ont été rencontrés liés aux performances de notre machine :

- Charge excessive liée à la taille de l'image :
Lors du premier test, l'image d'entrée (celle du projet) avait une résolution élevée. Cela a entraîné un ralentissement important de la machine, allant jusqu'à des blocages

temporaires. Pour remédier à ce problème, nous avons décidé de **redimensionner l'image** en réduisant sa taille, ce qui a permis d'assurer une exécution plus fluide du modèle.

- Problème de surcharge avec certains poids du modèle :

Lors du téléchargement des fichiers de poids nécessaires au fonctionnement de SAM, nous avons constaté que le fichier **sam_vit_h_4b8939.pth** posait des problèmes de performance. Bien que ce fichier corresponde à une version plus puissante du modèle (ViT-H), il n'a pas été utilisé, car il causait un ralentissement significatif de la machine.

À la place, nous avons opté pour **sam_vit_b_01ec64.pth**, une version plus légère du modèle (ViT-B), qui s'est avérée beaucoup plus adaptée aux capacités de notre matériel.

✓ À propos de sam_vit_h_4b8939.pth :

Le fichier sam_vit_h_4b8939.pth correspond aux **poids préentraînés du modèle SAM** utilisant l'architecture **ViT-H (Vision Transformer – Huge)**. Ce type de fichier est indispensable au fonctionnement du modèle, car il contient les paramètres appris lors de l'entraînement sur un très grand nombre d'images.

Application de SAM



Image d'entrée utilisée pour l'extraction automatique des toits.



Résultat de la segmentation automatique avec SAM sur l'image test

Analyse du résultat

Le modèle SAM a produit des résultats globalement satisfaisants sur l'image test. Les toits des bâtiments ont été majoritairement bien segmentés, avec une bonne délimitation des formes géométriques, en particulier pour les structures rectangulaires. D'autres éléments comme les terrains de sport, espaces verts et certaines voitures ont également été correctement identifiés. Chaque objet segmenté est représenté par une couleur distincte, ce qui facilite leur distinction visuelle.

Malgré l'utilisation d'une image redimensionnée à 512×512 pixels, la qualité de la segmentation reste bonne. Cela témoigne de la robustesse du modèle, même en conditions de résolution réduite.

Cependant, certaines limites ont été observées :

- Toits non détectés : plusieurs bâtiments visibles dans l'image n'ont pas été segmentés. Cela représente une faiblesse importante dans le cadre d'un projet d'extraction automatique des toitures.
- L'apparition de masques très petits ou irréguliers, parfois sans correspondance claire avec des objets réels.

Phase 2 : Entraînement personnalisé avec annotations manuelles (polygones)

Lors de la première phase d'utilisation du modèle SAM pré-entraîné, nous avons rencontré des problèmes de performance, notamment à cause des ressources limitées de nos ordinateurs, et la qualité des segmentations sur nos images spécifiques (captures Google Maps) n'était pas satisfaisante.

Pour améliorer les résultats, nous avons décidé de faire une phase d'entraînement personnalisé. Cela consiste à dessiner manuellement des polygones autour des bâtiments sur 10 images satellite de Google Maps, en utilisant un outil interactif MakeSense.ai. Ces polygones représentent précisément les contours des bâtiments.

Ensuite, nous avons utilisé un code qui charge le modèle SAM pré-entraîné et applique ces annotations (sous forme de fichiers JSON au format COCO) pour générer automatiquement les masques de segmentation. Chaque polygone dessiné sert de guide pour extraire un masque précis du bâtiment correspondant.

Au total, ce processus a permis de générer 60 masques, c'est-à-dire 60 images en niveaux de gris où chaque masque correspond à un bâtiment segmenté précisément. Ces masques sont sauvegardés individuellement sous forme d'images.

Explication du code utilisé

- Le script charge le modèle SAM pré-entraîné pour la segmentation d'images.
- Il lit une image satellite à segmenter.
- Il charge un fichier JSON contenant des annotations manuelles sous forme de boîtes englobantes (bounding boxes) des bâtiments.
- Pour chaque annotation, le script utilise le modèle pour prédire un masque de segmentation correspondant à la boîte.
- Chaque masque est converti en image binaire (noir et blanc) et sauvegardé dans un fichier PNG.
- Le script produit ainsi plusieurs masques, chacun correspondant à un bâtiment annoté dans l'image.
- Cette méthode permet d'automatiser la génération de masques précis à partir des annotations manuelles.

Résultat obtenu

Le code a donné 60 masques parmi ces masques on trouve les images suivantes :



Tableau 1 : Image 1



Tableau 2: Image 2




Tableau 3: Image 3



Tableau 4: Image 4

Analyse des résultats

On remarque que les masques présentés sont des images binaires en niveaux de gris, où :

Le bâtiment est représenté en blanc (valeur 255),

Et le fond est entièrement noir (valeur 0).

Cette représentation permet donc de distinguer visuellement la zone segmentée (le bâtiment), mais on constate que :

- La forme blanche est irrégulière et floue, elle ne suit pas fidèlement la géométrie du bâtiment réel.
- Les contours sont déformés, ce qui rend difficile l'interprétation précise de l'objet détecté.
- Le contraste noir/blanc est censé mettre en évidence la séparation entre l'objet et l'arrière-plan, mais ici, la détection semble bruitée, avec des bords peu nets.

→ En résumé, le masque est lisible, mais la précision est insuffisante pour une délimitation fiable des bâtiments dans un contexte cartographique ou SIG. Un post-traitement ou une amélioration de la méthode d'entrée (annotations, qualité d'image, modèle utilisé) est nécessaire.

Phase 3 : Entraînement ciblé sur une seule image de haute qualité

Dans cette phase, nous avons utilisé une seule image satellite de très haute résolution, fournie par notre encadrante, dans le but de tester les performances du modèle SAM dans un contexte plus contrôlé. Contrairement aux images Google Maps précédentes, cette image présente une meilleure qualité spatiale et des objets plus nets.

Nous avons appliqué les annotations manuelles (au format COCO) sur cette image, en utilisant des boîtes englobantes pour déclencher la segmentation automatique par le modèle. Le code utilisé charge le modèle SAM pré-entraîné, lit l'image, applique les annotations, et génère les masques de segmentation correspondants.

Explication du code utilisé

- L'image satellite a été chargée en mode RGB afin de préserver la richesse colorimétrique nécessaire à une bonne segmentation.
- Les annotations manuelles, fournies au format COCO, contiennent des boîtes englobantes (bounding boxes) précises autour des bâtiments présents sur l'image.
- À partir de ces boîtes, le modèle SAM a été sollicité pour générer automatiquement un masque de segmentation pour chaque bâtiment.
- Export des masques sous forme d'images binaires (.png), où les pixels du bâtiment sont en blanc (valeur 255) et le fond en noir (valeur 0).

Introduction de bounding box

Les bounding boxes sont importantes car elles délimitent précisément les zones où se trouvent les bâtiments, ce qui permet au modèle de segmentation de se concentrer uniquement sur ces parties. Cela rend la segmentation plus rapide, plus précise et réduit la charge de calcul en évitant d'analyser toute l'image inutilement.

Résultat obtenu



Tableau 5: Image en niveau de gris



Tableau 6: Image en RGB

Analyse de résultats

On remarque que deux types de résultats ont été produits :

- ❖ Une image en niveaux de gris, où le bâtiment segmenté apparaît en blanc (valeur 255) sur un fond noir (valeur 0).
- ❖ Une image en couleurs (RGB), où les masques segmentés sont superposés à l'image d'origine en vert, pour une meilleure visualisation de la zone détectée.

Ensuite on constate que les **masques sont bien visibles** et couvrent largement la zone des bâtiments annotés.

Ainsi l'utilisation de la superposition verte dans l'image RGB facilite la **visualisation directe** des zones segmentées.

Toutefois, **certains objets ne sont pas détectés**, notamment les **arbres** ou les petits détails non inclus dans les boîtes englobantes. De plus, **les masques occupent parfois une trop grande portion de l'image**, dépassant la zone réelle des bâtiments. Cela crée une **sur-segmentation** qui nuit à la précision.

Les **contours** manquent de régularité, et certaines formes segmentées ne suivent pas fidèlement les limites des bâtiments.

→ Cette approche a montré l'intérêt d'utiliser une image de haute qualité, mais elle met également en évidence certaines **limites du modèle SAM en zero-shot**, même lorsqu'on travaille dans des conditions optimales

Phase 3 : Entraînement ciblé sur une image de haute qualité en utilisant le critère de surface

Préparation de l'image

Pour commencer, nous avons utilisé la même image de haute qualité qu'auparavant. Cette image a été redimensionnée à une taille standard de 640x640 pixels. Ce redimensionnement est nécessaire pour assurer la compatibilité avec les modèles de détection et de segmentation que nous avons employés, tout en optimisant le temps de calcul.

Détection des bâtiments avec YOLO

Nous avons appliqué le modèle YOLO (You Only Look Once) pour détecter les bâtiments dans l'image.

Importance de YOLO :

YOLO est un modèle de détection d'objets réputé pour sa rapidité et son efficacité. Il permet d'identifier rapidement des zones d'intérêt sous forme de boîtes englobantes (bounding boxes). Cette étape est essentielle car elle limite la zone d'analyse pour la segmentation, ce qui améliore la précision et réduit le temps de calcul global.

Segmentation précise avec SAM

Une fois les bâtiments détectés par YOLO, nous utilisons le modèle SAM (Segment Anything Model) pour segmenter précisément chaque bâtiment.

Rôle de SAM :

SAM génère des masques binaires précis qui différencient les pixels du bâtiment de ceux du fond. Cette segmentation fine est indispensable pour obtenir une cartographie détaillée des bâtiments, utile dans diverses applications comme l'urbanisme ou l'analyse environnementale.

Filtrage par critère de surface

Afin d'améliorer la qualité des masques, nous avons ajouté un critère basé sur la surface des segments.

Nous avons fixé un seuil maximal de surface à 17 000 pixels.

Seuls les masques dont la surface est inférieure ou égale à ce seuil sont conservés.

Importance du critère de surface :

Ce filtrage permet d'éliminer les segments trop grands, qui peuvent correspondre à des erreurs ou des segments imprécis. Ce contrôle améliore la fiabilité des résultats.

Note importante :

Le seuil choisi ici est expérimental et ne repose pas sur une étude approfondie. Il a été fixé à 17 000 pixels pour tester son effet sur la segmentation, et pourra être ajusté selon les besoins futurs du projet.

Résultats



Tableau 7: Résultat avec critère de surface

Analyse des résultats

- L'image représente un masque binaire obtenu après détection et segmentation des bâtiments à partir d'une image haute résolution.
- Les zones blanches correspondent aux bâtiments détectés, tandis que les zones noires représentent le fond ou les objets filtrés.
- La détection a été faite avec YOLO, puis la segmentation précise avec SAM.
- Un filtrage par surface a permis de garder uniquement les petits bâtiments ($\leq 17\,000$ pixels).

→ Le résultat est propre, avec des formes bien séparées et peu d'erreurs visibles. Donc ce masque est prêt à être utilisé pour des analyses ou dans un SIG.

PROBLÈMES TECHNIQUES ET STRATÉGIES DE RÉOLUTION

Choix méthodologique	Problèmes rencontrés	Décision (solution adoptée)
Application directe du modèle SAM (zero-shot)	Résultats imprécis, mauvaise détection des toitures	Tester la capacité initiale du modèle sans entraînement ; approche rapide et simple
Entraînement personnalisé sur captures Google Maps (annotations en polygones)	Blocage durant l'entraînement à cause de la taille des images et des ressources limitées	Adapter SAM au contexte des images satellitaires ; fine-tuning avec des données spécifiques
Entraînement ciblé sur une seule image haute qualité (10 copies + bounding boxes)	Résultat non généralisable, impact limité, détection partielle	Réduire les besoins en ressources ; observer l'impact d'un entraînement minimaliste
Ajout de critère de superficie minimale	Amélioration locale mais exclusion de petites toitures	Optimiser les résultats en filtrant les faux positifs ou objets parasites
Augmentation ciblée avec base de données d'images satellites	Entraînement bloqué (grande taille, machine limitée)	Accroître la robustesse du modèle via la diversité des données c'est-à-dire essayer de simuler un apprentissage à plus grande échelle
Redimensionnement des images pour optimisation	Perte de qualité, mauvaise segmentation	Réduire la charge mémoire et permettre l'entraînement sur machines locales

VALIDATION ET ÉVALUATION

Critères retenus pour l'évaluation

Dans le cadre de cette étude, nous avons évalué les performances des quatre méthodes adoptées proposés pour la détection automatique des toits à partir d'images satellites. L'évaluation a été réalisée à l'aide d'une méthode basée sur le calcul manuel d'indicateurs classiques de classification binaire, permettant de mesurer la pertinence des résultats obtenus.

Trois métriques ont été utilisées :

Le rappel (Recall) : il mesure la capacité du modèle à détecter l'ensemble des toits présents. Il s'agit du rapport entre le nombre de toits correctement détectés (vrais positifs) et le total des toits existants (vrais positifs + faux négatifs).

La précision (Precision) : elle évalue la proportion de toits détectés qui sont réellement corrects. Elle se calcule comme le rapport entre le nombre de vrais positifs et l'ensemble des entités détectées comme des toits (vrais positifs + faux positifs).

Le F-facteur (F1-score) : il s'agit de la moyenne harmonique entre le rappel et la précision. Cette mesure globale permet de synthétiser la performance de la classification en tenant compte à la fois des omissions et des erreurs de détection.

Les formules utilisées sont les suivantes :

$$\text{Rappel} = \frac{TP}{TP + FN} \quad ; \quad \text{Précision} = \frac{TP}{TP + FP} \quad ; \quad F1 = \frac{2 \cdot \text{Rappel} \cdot \text{Précision}}{\text{Rappel} + \text{Précision}}$$

Avec :

TP (True Positive) : nombre de toits correctement détectés par le modèle.

FN (False Negative) : toits présents dans la réalité mais non détectés par le modèle.

FP (False Positive) : éléments incorrectement détectés comme des toits alors qu'ils ne le sont pas.


Ces indicateurs permettent de comparer objectivement les résultats obtenus par les 4 méthodes, en mettant en évidence leur capacité à détecter précisément et exhaustivement les toits présents sur les images satellites.

Résultats obtenus et interprétation

En effectuant les calculs, on obtient les résultats suivants

		TP	FN	FP	Rappel	Précision	F1
Méthode	SAM	76	12	55	0,86	0,58	0,69
	YOLO+SAM	84	84	102	0,50	0,45	0,47
	YOLO+SAM+Surface	36	52	31	0,41	0,54	0,46
	SAM+Augmentation	76	12	55	0,86	0,58	0,69

Tableau 8: Résultats des métriques de validation (Rappel, Précision, F1-score) pour les quatre méthodes de détection des toits



Interprétation :

Les performances des quatre méthodes de détection de toits à partir d'images satellites ont été évaluées à l'aide des métriques classiques de rappel, de précision et de F1-score.

Voici les observations principales :

1. SAM (Segmentation Anything Model seul)

Rappel : 0,86 — Excellente capacité à détecter la majorité des toits présents (très peu d'omissions).

Précision : 0,58 — Résultats modérés : une partie significative des objets détectés ne sont pas réellement des toits.

F1-score : 0,69 — Score global satisfaisant, mais la précision pourrait être améliorée.

Conclusion : SAM seul est très sensible (détecte presque tout) mais manque de sélectivité.

2. YOLO + SAM

Rappel : 0,50 — Moyenne : une grande partie des toits sont manqués (FN = 84).

Précision : 0,45 — Faible : beaucoup de faux positifs (FP = 102).

F1-score : 0,47 — Plus bas F1-score parmi les quatre méthodes.

Conclusion : L'entraînement préalable avec YOLO seul ne semble pas améliorer les performances globales ; cette méthode est peu efficace.

3. YOLO + SAM + Surface

Rappel : 0,41 — Très faible capacité à détecter tous les toits (FN élevé : 52).

Précision : 0,54 — Légère amélioration de la précision par rapport à YOLO+SAM.

F1-score : 0,46 — Comparable à YOLO+SAM, mais pas meilleur.

Conclusion : Ajouter une contrainte de surface améliore la précision mais réduit fortement le rappel, ce qui nuit à la détection globale.

4. SAM + Augmentation (filtrage par base de données entraînée)

Rappel : 0,86 — Identique à SAM seul, montrant que la capacité de détection brute reste inchangée.

Précision : 0,58 — Également identique, ce qui suggère que le filtrage par le classifieur n'a pas eu d'impact visible.

F1-score : 0,69 — Inchangé par rapport à SAM seul.

Conclusion : Bien que cette méthode soit conçue pour améliorer les résultats de SAM via un filtrage automatique des masques à l'aide d'un modèle entraîné, les performances restent les mêmes. Cela s'explique probablement par **la taille réduite du jeu de données d'entraînement (200 images seulement)**, qui ne permet pas au classifieur d'apprendre efficacement à distinguer les bâtiments des autres objets.

Il est donc probable qu'une **augmentation de la taille et de la diversité de l'ensemble d'entraînement** conduirait à des résultats plus différenciés et meilleurs que ceux de SAM seul.

Limites de la validation à petite échelle

La validation des méthodes de détection a été réalisée à partir d'un échantillon relativement restreint de données (notamment **200 images** utilisées pour l'entraînement du classifieur dans la méthode **SAM + Augmentation**). Bien que cela permette d'obtenir une première estimation des performances des workflows proposés, plusieurs limites doivent être soulignées :

- **Capacité de généralisation réduite** : Un petit jeu de données ne couvre pas suffisamment la diversité des toits (formes, tailles, couleurs, contextes urbains ou ruraux), ce qui limite la capacité du modèle à généraliser à de nouveaux cas ou à des images issues d'autres régions.
- **Évaluation biaisée** : Les performances observées peuvent ne pas être représentatives de la réalité à grande échelle. Le modèle peut sembler performant sur ce petit jeu, alors qu'il échouerait sur des images plus variées.
- **Filtrage inefficace** : Dans le cas du workflow **SAM + Augmentation**, la **non-amélioration des résultats** par rapport à SAM seul indique que le classifieur entraîné sur seulement 200 images **n'a pas eu un impact significatif** sur le filtrage des masques. Cela montre que **le potentiel du filtrage supervisé n'a pas été pleinement exploité**, faute de données suffisantes.

PERSPECTIVES D'AMÉLIORATION

Augmentation de données à large échelle

Pour améliorer significativement la performance du modèle SAM, on peut recourir à une stratégie d'**augmentation massive des données d'entraînement**. Cela inclurait :

- La constitution ou l'utilisation de **bases de données d'images satellites à grande échelle**, couvrant divers environnements (urbain, rural, mixte).
- L'application de techniques d'**augmentation automatique des données** (rotation, zoom, transformation géométrique, variation d'éclairage, etc.) pour enrichir la diversité des cas rencontrés sans devoir collecter manuellement toutes les annotations.

Fine-tuning avec base de données adaptée

Réentraîner le SAM sur un jeu de données spécifique à notre cas mais cela nécessite des bases de données adaptées:

- Contenant **des images similaires à celles que nous ciblons** (satellite, aériennes...).
- Annotées avec **précision et pertinence** (polygones, bounding boxes, etc.).
- Assez **variée et volumineuse** pour assurer une **généralisation robuste**.

Renforcement des critères géométriques dans la post-segmentation

Vient comme **étape complémentaire** appliquée **après la segmentation automatique** visant à **filtrer ou affiner les résultats** en se basant sur des **caractéristiques géométriques** des objets détectés.

- ❖ Surface minimale Ratio
- ❖ Largeur/hauteur
- ❖ Compacité / circularité Orientation

RECOMMANDATIONS ET REMARQUES

L'approche adoptée, combinant autonomie, expérimentation, et co-encadrement par des doctorants, a grandement enrichi notre apprentissage tant sur le plan technique que méthodologique et scientifique.

Dans le cadre de cette dynamique innovante, nous souhaitons formuler quelques recommandations visant à optimiser encore davantage cette expérience formatrice

Conserver cette approche pédagogique et l'étendre à d'autres enseignements :

Nous recommandons vivement d'adopter ce modèle dynamique d'apprentissage par projet dans d'autres modules, notamment ceux liés à la **photogrammétrie** et cela en remplacement ou en complément des cours purement théoriques. Nous estimons que cela permettrait de mieux comprendre les concepts à travers des recherches et des cas concrets.

Mettre à disposition un environnement de calcul adapté :

L'entraînement de modèles comme SAM étant très exigeant en ressources (GPU), un accès à des machines puissantes et à des environnements cloud serait un avantage pour éviter les blocages techniques.

CONCLUSION GÉNÉRALE

Ce projet de recherche a permis d'explorer l'apport du **modèle SAM** dans le cadre d'une tâche complexe : l'extraction des toitures de bâtiments à partir d'images satellitaires.

Pour mener cette recherche nous avons suivi une démarche logique, commençant par test en zero-shot et passant à une annotation manuelle, un entraînement ciblé, puis tentatives d'augmentation du modèle.

Les résultats obtenus sont encourageants mais limités, en raison de contraintes techniques (matériel, temps, bases d'images ...)

Ce projet a mis en lumière les **forces du modèle SAM** mais aussi ses **limites** (manque de robustesse pour des fins spécifiques sans grand entraînement, dépendance à la qualité des images et des annotations).

Des perspectives plus encourageantes s'ouvrent avec un accès à des bases de données à grande échelle, une infrastructure adaptée (GPU/TPU), et une meilleure intégration de critères géométriques et sémantiques dans la post-segmentation.

Enfin, cette approche pédagogique a favorisé efficacement un apprentissage actif, valorisant l'esprit de groupe, l'expérimentation, l'autonomie et la collaboration inter-niveaux.

WEBOGRAPHIE

Meta AI Research. (2023). *Segment Anything Model (SAM)*.
<https://segment-anything.com/>

Kirillov, A., Mintun, E., Ravi, N., Mao, H., Rolland, A., Gustafson, L., ... & Dollár, P. (2023). *Segment Anything*.
<https://arxiv.org/abs/2304.02643>

PyTorch : bibliothèque open-source pour le deep learning.
<https://pytorch.org>

Visual Studio Code
<https://code.visualstudio.com>

Jupyter Notebooks
<https://jupyter.org>

<https://github.com>